人工智能技术及应用

二三级考试知识点详解

依据上海市高等学校信息技术水平考试

2025年版考纲编排

17 个知识领域 50 个知识单元 93 个知识点

开放教材选读与编者讲解

2026年10月整理

编写说明

本书供人工智能技术及应用（二三级）考试复习使用，内容边界来自用户提供的《上海市高等学校信息技术水平考试 人工智能技术及应用（二三级）考试大纲（2025年版）》（38.pdf，印刷页124—140）。一级标题对应知识领域，二级标题对应知识单元，三级标题对应知识点。基础模块8个领域40个知识点，综合模块9个领域53个知识点，均按原表保留。

本书采用读者确认的“开放教材原文＋明确标注的补充讲解”方式。标有“原文选读”的段落是已经核对的引文；“编者讲解”“例题与解析”“辨析与自测”等内容是围绕考纲另行编写的解释、例子和推导。英文引文保留英文原貌，其后的中文解释不冒称原作者的中文原话。没有合适短引文的知识点直接提供编者讲解及所依据的来源。

考纲推荐的两本教材为刘垚主编《大学信息技术4—人工智能基础与实践（第四版）》（华东师范大学出版社，2024）和吴飞、潘云鹤编著《人工智能引论》（高等教育出版社，2024）。本次未获得这两本书的正文，故没有把它们列作已经逐页核对的引文来源，也没有将编者文字标作这两本书的原话。

主要开放教材来源包括《动手学深度学习》在线版。其作者为 Aston Zhang、Zachary C. Lipton、Mu Li 和 Alexander J. Smola，中文项目包含社区翻译与修订贡献。正文许可为 CC BY-SA 4.0；对应的摘录保留该许可，围绕这些摘录形成的改编说明亦按相同许可提供。独立引用的其他教材、论文、官方文档和考纲各自保留原有权利，不因收录而改变许可。

Poole与Mackworth的 Artificial Intelligence: Foundations of Computational Agents 第三版HTML文本版权为©2023两位作者，许可为CC BY-NC-ND 4.0。本书保留其英文短引原貌、作者与章节链接；中文独立讲解不冒称其授权译本。其他版权保留教材只采用必要短引及独立编写的解释。

本书的改动包括：按考试层级重新组织选段、增加中文解释、独立例题、演算、代码和辨析。作者及来源机构没有参与本书编写，也不构成推荐或背书。本书是个人学习资料，不是考试主管部门发布的教材或2026年考试大纲。逐节来源编号对应书末参考资料；网页核对日期为2026年10月12日。

正文许可与项目声明：CC BY-SA 4.0；D2L 中文项目版权声明；Poole与Mackworth第三版版权页。

阅读与复习方法

考核层次 表中“知道”与备注中的“了解”对应最低层次，重点是能辨认概念、特点和用途；“理解”要求能说明核心知识及使用方法；“掌握”要求能运用方法解决问题。正文严格保留表中的要求，不将基础模块简单等同于二级、综合模块简单等同于三级。

阅读顺序 先学习第1至4章的数据、学习与神经网络基础，再读第5至8章任务与应用概念；接着进入第9至13章的推理、算法和安全问题，最后学习第14至17章的技术方案与应用。基础和综合中的同名主题分别承担入门与深化作用。

学习方法 每个知识点先读原文选段与讲解，再遮住例题答案自行推演。掌握级内容至少完成一次手算或代码流程解释。辨析题应说清错误发生的条件，例如标准化只在训练集上拟合、分类器预测类别而回归器预测数值。

代码与版本 考纲环境为 Python 3.8、Anaconda3-2021.05，额外安装 TensorFlow 2.5.0；NumPy、Pandas、Matplotlib、scikit-learn、Pillow 未分别列版本。书中代码以该语境为基础，示意片段中的变量应结合上下文使用。本文代码完成语法检查和人工审校，但未在完整的原考场软件环境执行训练；不据此声称全部程序已通过考场运行验证。

原文与拓展 来源编号用于追溯概念，不表示整节均为原文。公式后的符号说明和数值例题属于编者讲解。少量超出最低要求的推导用于帮助理解，不代表新增官方考点。考纲缩写LDA未写全称，本书按线性判别分析展开并说明其与主题模型的区别。

查阅方法 目录列出全部三级标题并提供页码；PDF书签按三个层级展开。正文每个知识点末尾给出来源编号，书末有可点击链接。正文页码与PDF物理页一致，便于电子阅读和打印定位。

目录

编写说明 2

阅读与复习方法 3

第1章 人工智能概述 10

1.1 人工智能基本概念 10

1.1.1 人工智能定义、起源 10

1.2 人工智能的发展历史 11

1.2.1 人工智能研究方向 11

1.2.2 人工智能流派 11

1.3 智能计算系统 12

1.3.1 智能计算系统定义与组成 12

1.4 人工智能应用 13

1.4.1 人工智能典型应用领域与场景 13

第2章 人工智能数据处理基础 14

2.1 Numpy 数据类型 14

2.1.1 多维数据的处理基础 14

2.2 Pandas 数据类型 15

2.2.1 表格数据的处理基础 15

2.3 数据可视化 15

2.3.1 Matplotlib 绘图基础 15

2.3.2 常见图表类型绘制（2D散点图、3D散点图、折线图、条形图、箱型图、饼图等） 16

第3章 机器学习基础 18

3.1 机器学习基本概念 18

3.1.1 机器学习定义及原理 18

3.1.2 无监督学习（聚类、特征降维）概念 19

3.1.3 有监督学习（分类、回归）概念 19

3.1.4 数据预处理（含特征工程） 20

3.1.5 模型训练基本概念 . . . 21
3.1.6 性能评估 . . . 22
3.2 机器学习基础方法 . . . 23
3.2.1 线性回归 . . . 23
3.2.2 K 近邻算法 . . . 24
3.2.3 K-Means 聚类 . . . 25
3.2.4 PCA . . . 26

第4章 深度学习基础 . . . 27
4.1 神经网络基本概念 . . . 27
4.1.1 人工神经网络基础 . . . 27
4.1.2 前向传播 . . . 28
4.1.3 激活函数 . . . 29
4.1.4 损失函数 . . . 30
4.1.5 过拟合与欠拟合 . . . 30
4.2 典型神经网络基础 . . . 31
4.2.1 序贯模型（Sequential） . . . 31
4.2.2 Transformer 基础 . . . 32

第5章 计算机视觉基础 . . . 34
5.1 计算机视觉方法基础 . . . 34
5.1.1 图像分割与分类 . . . 34
5.1.2 目标检测与识别 . . . 34

第6章 语音处理基础 . . . 36
6.1 语音处理方法基础 . . . 36
6.1.1 语音识别（说话人、关键词、认证、增强） . . . 36
6.1.2 语音合成（如文本到语音） . . . 36

第7章 自然语言处理基础 . . . 38
7.1 自然语言处理方法基础 . . . 38
7.1.1 垂直任务类（机器翻译、问答系统、信息抽取等） . . . 38

第8章 人工智能应用基础 . . . 39

8.1 智能社会基础 . . . 39
8.1.1 智能社会概念 . . . 39
8.2 智能交通基础 . . . 39
8.2.1 智能交通概念 . . . 39
8.3 智能医疗基础 . . . 40
8.3.1 智能医疗概念 . . . 40
8.4 智能制造基础 . . . 41
8.4.1 智能制造概念 . . . 41
8.5 智能创意基础 . . . 41
8.5.1 智能创意概念 . . . 41
8.6 智能推荐基础 . . . 42
8.6.1 智能推荐概念 . . . 42
8.7 智慧教育基础 . . . 42
8.7.1 智慧教育概念 . . . 42
8.8 机器人基础 . . . 43
8.8.1 机器人概念 . . . 43
8.9 智能驱动科学研究基础 . . . 43
8.9.1 AI4Science 概念 . . . 43

第9章 逻辑推理与知识图谱 . . . 45

9.1 逻辑推理 . . . 45
9.1.1 谓词逻辑表示法 . . . 45
9.1.2 推理规则 . . . 46
9.1.3 确定性与不确定性推理 . . . 46
9.2 专家系统与知识图谱 . . . 47
9.2.1 专家系统基本原理 . . . 47
9.2.2 知识图谱基本原理 . . . 48
9.2.3 本体知识表示 . . . 49

第10章 机器学习 . . . 51

10.1 机器学习补充方法 . . . 51
10.1.1 逻辑回归 . . . 51
10.1.2 决策树 . . . 52

10.1.3 支持向量机 53
10.1.4 层次聚类 54
10.1.5 集成模型（如 Boosting、随机森林） 55
10.1.6 LDA 56
10.1.7 朴素贝叶斯 57
10.2 强化学习基本概念 58
10.2.1 强化学习定义及原理 58
10.2.2 价值函数与 Q 学习 59

第11章 深度学习 60
11.1 神经网络补充概念 60
11.1.1 反向传播 60
11.1.2 梯度下降法 61
11.2 神经网络原理与实践 62
11.2.1 CNN 特点及经典模型（LeNet、ResNet） 62
11.2.2 RNN 特点及经典模型等（LSTM，GRU） 63
11.2.3 Transformer 64

第12章 人工智能前沿技术 66
12.1 数据增强技术 66
12.1.1 扩散模型基础 66
12.1.2 生成对抗网络（GAN）基础 66
12.2 多模态技术 67
12.2.1 多模态基础（感知、数据） 67
12.3 分布式机器学习与联邦学习 68
12.3.1 分布式机器学习基础 68
12.3.2 联邦学习基础 68
12.4 生成式大模型技术 69
12.4.1 基本三要素（数据、算法、算力） 69
12.4.2 预训练概念 70
12.4.3 检索增强生成（RAG）概念 70

第13章 人工智能安全与伦理 72
13.1 可信人工智能 72

13.1.1 可信人工智能的可解释性、安全性、公正性、隐私性 . . . 72
13.2 人工智能伦理 . . . 73
13.2.1 人工智能的伦理和安全挑战 . . . 73

第14章 计算机视觉 . . . 74
14.1 计算机视觉基础 . . . 74
14.1.1 特征表示与滤波 . . . 74
14.1.2 边缘检测与局部特征描述符 . . . 74
14.2 计算机视觉方法与应用 . . . 75
14.2.1 图像分割与分类 . . . 75
14.2.2 目标检测与识别 . . . 76
14.2.3 生物特征识别 . . . 77
14.2.4 行为分析 . . . 77

第15章 语音处理 . . . 79
15.1 语音处理基础 . . . 79
15.1.1 基本概念（响度、共振峰、掩蔽效应、基音等） . . . 79
15.1.2 声音信号预处理与量化 . . . 79
15.1.3 常用时域、频域、声学特征 . . . 80
15.2 语音处理方法与应用 . . . 81
15.2.1 常用模型（DNN-HMM、Attention、Transformer 等） . . . 81

第16章 自然语言处理 . . . 82
16.1 自然语言处理基础 . . . 82
16.1.1 词法（分词、词性标注、命名实体识别等） . . . 82
16.1.2 句法（句子成分分析、生成式句法、依存式句法等） . . . 82
16.2 自然语言处理方法与应用 . . . 83
16.2.1 词表示（n-gram 语言模型、word2vec 等） . . . 83
16.2.2 句子建模（RNN、LSTM、Transformer 等） . . . 84

第17章 人工智能应用 . . . 85
17.1 智能社会 . . . 85
17.1.1 智能社会技术、应用 . . . 85
17.2 智能交通 . . . 86

17.2.1 智能交通技术、应用 86
17.3 智能医疗 86
17.3.1 智能医疗技术、应用 86
17.4 智能制造 87
17.4.1 智能制造技术、应用 87
17.5 智能创意 88
17.5.1 智能创意技术、应用 88
17.6 智能推荐 88
17.6.1 智能推荐技术、应用 88
17.7 智慧教育 89
17.7.1 智慧教育技术、应用 89
17.8 机器人 90
17.8.1 机器人技术、应用 90
17.9 智能驱动科学研究 90
17.9.1 AI4Science 技术、应用 90

附录一 考纲样例的阅读与勘误 92

附录二 综合程序流程示例 93

参考资料 94

基础模块

第1章 人工智能概述

1.1 人工智能基本概念

1.1.1 人工智能定义、起源

考纲要求：理解

> Artificial intelligence, or AI, is the field that studies the synthesis and analysis of computational agents that act intelligently.

原文选读 [1] 1.1 What is Artificial Intelligence?

编者讲解 这段英文从**智能体**的角度界定**人工智能**。智能体是能够接收环境信息并采取行动的系统；“行动”既可以是机器人的移动，也可以是软件给出预测、建议或回答。人工智能研究如何使这些系统具有**感知、学习、推理、规划和决策能力**。判断一个系统是否具有智能，不能只看它是否长得像人、是否使用神经网络，而要看它能否在既定目标和资源约束下处理问题，并适应输入或环境的变化。人工智能是学科和技术集合，机器学习是其中利用经验改进性能的一类方法，深度学习又是机器学习中的重要分支。

编者讲解 其思想基础来自逻辑学关于推理形式化的研究、计算理论关于可计算性的研究，以及控制论、神经科学和统计学。1950年**图灵**讨论机器智能与模仿游戏，1956年**达特茅斯**夏季研究项目通常被视为人工智能学科形成的标志。这里的“起源”应分清思想先驱、理论条件与学科命名：1956年并不意味着此前没有机器推理或人工神经元研究。图灵测试关注外显交流行为能否与人区分，也不直接提供构造智能系统的算法。

编者讲解 把固定税率代入公式计算税额，与从历史图像学习识别零件缺陷，都是计算机任务，但后者需要在未见样本上处理模式变化。进一步说，AI也可以依据人工编写的知识与搜索规则完成复杂规划，所以“只有会训练模型的程序才是AI”过窄。人工智能能在某项任务上超过人，并不推出它拥有人的全部常识、意识或跨任务能力。

辨析与自测 自测：某导航程序根据路网搜索最短路径，没有神经网络，是否必然不属于人工智能？答案：不是；搜索与规划本来就是AI的重要研究内容。再问：**机器学习**、人工智能与**深度学习**谁的范围最大？答案：在通常学科划分中，**人工智能包含机器学习，机器学习包含深度学习。**

本节来源：[1] [2]。完整书目信息与链接见书末。

1.2 人工智能的发展历史

1.2.1 人工智能研究方向

考纲要求：知道

编者讲解 人工智能的研究方向可以沿着“获取信息—形成表示—作出判断—采取行动”来组织。**计算机视觉**处理图像和视频，语音处理处理声音，**自然语言处理**研究文本与语言；**知识表示与推理**研究怎样表达事实、关系和规则并推出结论；搜索与规划研究如何从候选方案中找到满足目标的行动序列。机器学习则提供从数据或交互经验改进模型的方法，能够为上述多个方向服务。

编者讲解 研究方向与应用行业不是同一分类层级。例如医疗是应用领域，而医学图像分割属于计算机视觉，病历实体抽取属于自然语言处理，药物相互作用分析可能使用知识图谱。同一系统也可以同时采用多个方向：语音助手先识别声音中的词语，再理解用户意图，查询知识或调用工具，最后合成语音。把所有人工智能功能都统称为“识别”会遗漏生成、推理和行动规划。

编者讲解 从历史看，研究重心经历过规则与搜索、知识工程、统计学习、深度学习以及大规模预训练等阶段，但新方法出现不意味着旧方法失去用途。资源有限、规则明确的场景仍可能采用规则系统；有大量样本而关系复杂的任务常用学习方法。复习时应能由输入、输出和任务目标识别方向，而不必把某个产品永久归入唯一类别。

辨析与自测 自测：输入仓库地图并输出机器人取货路线属于什么方向？核心是**搜索与规划**；若机器人还要从摄像头识别障碍物，则同时涉及视觉感知。输入一段文字并输出朗读音频属于语音合成。

本节来源：[2] [3] [4]。完整书目信息与链接见书末。

1.2.2 人工智能流派

考纲要求：知道

编者讲解 教材常用**符号主义**、**连接主义**和**行为主义**概括人工智能的三种代表性研究思想。符号主义把知识表示为概念、命题、规则等符号结构，再用逻辑推理或搜索处理这些结构。它适合表达可陈述的事实和约束，例如“完成先修课程后才能选修后续课程”。其优势是规则较容易核查；困难在于大量常识不容易完整写出，噪声感知数据也不容易直接变成可靠符号。

编者讲解 连接主义通过大量相互连接的计算单元和可调参数表示映射关系，人工**神经网络**是其代表。训练使连接权重适应数据，不需要人逐条写出图像与类别之间的规则。它能够学习复杂的统计模式，但效果受数据分布、目标函数和模型规模影响，对单次输出的内部原因也未必能用简洁规则说明。“模仿神经元”是一种启发，并不表示现有网络等同于真实大脑。

编者讲解 行为主义强调智能体在环境中的行为、反馈和适应，常联系感知—动作闭环、机器人控制以及通过交互学习策略的方法。三种流派是理解研究思想的框架，不是互斥的软件标签。仓

储机器人可以用神经网络识别货物，用符号规则检查危险区域，再依据环境反馈调整运动。强化学习强调交互与奖励，但其策略可以用表格、树或神经网络表示。

辨析与自测 自测：以“如果故障灯亮且电压过低，则检查供电”为核心规则的系统，最直接体现符号主义；从大量图像调整网络权重的分类器体现连接主义；关注机器人如何通过环境反馈改善行动的研究体现行为与交互的思想。

本节来源：[1] [2] [14]。完整书目信息与链接见书末。

1.3 智能计算系统

1.3.1 智能计算系统定义与组成

考纲要求：理解

编者讲解 **智能计算系统**是围绕任务目标，将**信息获取**、**数据或知识表示**、智能算法、计算资源和结果使用环节组合起来的计算系统。一个训练完成的模型只是其中一部分：输入数据来自何处，缺失或异常数据如何处理，预测如何转化为行动，失败如何被发现，都决定系统是否真正可用。这里给出的是便于方案设计的通用组成框架，不把某一厂商的平台架构当成唯一标准。

编者讲解 从功能看，输入层负责传感器、文件、数据库或人机交互；处理层完成清洗、编码与特征构造；模型或知识层提供预测、推理、生成和规划；决策执行层把输出转为建议或操作；评估反馈层监测性能并记录新证据。从资源看，需要数据和知识、算法与软件、CPU/GPU等硬件及存储网络。训练阶段以数据优化参数，推理阶段使用已经确定的参数处理新输入；两者对算力、时延和内存的要求可以不同。

编者讲解 以校园门口的车辆通行系统为例，摄像头采集画面，预处理定位车牌，识别模型得到字符，授权数据库判断是否允许通行，控制器驱动道闸，日志记录结果。即使字符识别准确率很高，若授权库更新滞后或者道闸没有防夹检测，整个系统仍不能达到要求。这说明应按完整的输入—处理—决策—反馈链条分析，而不是仅列举一个算法名称。

辨析与自测 评价系统需要同时看**任务质量与运行条件**。识别任务可测准确率，实时控制还须考虑响应时间、稳定性和异常处置；训练集上的高分不能替代现场测试。自测：GPU是否是每个智能系统必备组件？答案：不是，小规模规则推理或轻量模型可在CPU上运行。在线推理是否必然边使用边训练？答案：不是；是否更新参数由系统设计决定。

本节来源：[1] [3] [4]。完整书目信息与链接见书末。

1.4 人工智能应用

1.4.1 人工智能典型应用领域与场景

考纲要求：知道

编者讲解 人工智能应用应从“用什么信息解决什么问题”来理解。交通领域可根据道路图像检测车辆，根据历史流量预测拥堵；医疗领域可辅助识别影像异常和整理病历；制造领域可检测表面缺陷、预测设备故障并优化生产调度；教育领域可分析学习记录、检索知识和提供个性化练习。这些场景分别对应**分类、回归、检测、排序或规划**等可计算任务。

编者讲解 生活服务中的商品推荐，需要把用户兴趣和商品特征映射为候选排序；智能创意可依据文字条件生成图像或音频；机器人需要把感知结果与行动控制连接起来；AI4Science把学习方法用于科学数据分析、模型近似和候选方案搜索。应用名称并不能说明技术细节，方案题应至少明确**输入**、**输出**、训练或知识来源以及**评价**办法。

编者讲解 同一行业可以存在多个不同任务。以维修服务为例，识别照片中的设备型号是分类，预测剩余寿命是回归，发现相似故障案例是检索，安排技师访问顺序是规划。可行性还取决于数据是否覆盖实际使用环境，错误后果是否可控制，以及结果能否进入既有流程。仅把“人工智能”添加在传统系统名称前面，并没有说明解决方案。

辨析与自测 自测：用消费记录给客户分群、但没有人工类别标签，是**聚类**；根据已标注记录预测客户是否流失，是**有监督分类**。二者都可服务客户管理，但学习条件和输出含义不同。

本节来源：[3] [4]。完整书目信息与链接见书末。

基础模块

第2章 人工智能数据处理基础

2.1 Numpy 数据类型

2.1.1 多维数据的处理基础

考纲要求：知道

编者讲解 NumPy的核心数组**ndarray**用于存放有规则维度的数值数据。数组的**shape**表示各轴长度，**ndim**表示轴数，size表示元素总数，dtype表示元素的数据类型。机器学习中常用形状(n,d)的二维数组表示n个样本、每个样本d个特征；灰度图像常用(H,W)，彩色图像常用(H,W,C)。轴的含义由数据约定决定，三维数组并不必然是一张彩色图，也可能是多个时间片组成的数据。

编者讲解 创建数组可用np.array、np.zeros、np.ones、np.arange；索引从0开始，**切片**通常左闭右开。若A是二维数组，A[:,0]取得第一列，A[0,:]取得第一行。axis=0表示沿第一轴聚合，因此A.mean(axis=0)得到每一列的均值；axis=1得到每一行的均值。reshape改变形状而保持元素个数，不会自动理解哪些元素本来属于同一条记录。

编者讲解 数组相加、相乘通常按元素计算，矩阵乘法使用@。**广播**允许形状在从末轴向前比较时相等或其中一个为1的数组共同计算，例如(3,2)矩阵减去(2,)列均值。要特别留意(3,)与(3,1)相减会广播成(3,3)，并非得到三个差。基本切片通常产生共享数据的视图；若需要独立副本，应明确调用copy，避免局部修改意外改变原数组。

```
import numpy as np
A = np.array([[1, 2], [3, 4], [5, 6]], dtype=float)
print(A.shape, A.ndim, A.size)  # (3, 2), 2, 6
print(A.mean(axis=0))          # [3. 4.]
print(A[:, 0])                # [1. 3. 5.]
B = A - A.mean(axis=0)        # 每列分别中心化
```

辨析与自测 自测：把含12个元素的数组reshape为(3,4)是否可行？答案：可行；改为(5,3)不行。两个形状均为(2,2)的数组使用*得到**逐元素积**，使用@得到**矩阵乘积**，不能互换。

本节来源：[5]。完整书目信息与链接见书末。

2.2 Pandas 数据类型

2.2.1 表格数据的处理基础

考纲要求：知道

编者讲解 Pandas把表格分析中的“值”和“标签”放在一起处理。**Series**是一维带**索引**的数据，**DataFrame**是带行索引和列名的二维表；同一DataFrame的不同列可以采用不同类型。姓名列可以是文本，成绩列可以是数值。读取CSV后应先查看head、shape、dtypes与缺失情况，确认列名、编码和类型符合预期，再进行筛选、统计和建模。

编者讲解 **loc**按标签选择，**iloc**按整数位置选择；二者不能只按“都是下标”来混用。df['score']一般得到Series，df[['score']]保持DataFrame结构。条件筛选使用布尔数组，例如df[df['score']>=60]。多个条件通常使用&或|并为每个条件加括号。Series之间运算会先按索引标签对齐，这与NumPy仅按位置运算有重要区别；错误的索引可能引入**缺失值**。

编者讲解 常见表格操作包括isna识别缺失、dropna删除、fillna填补、drop_duplicates去重、**groupby**分组统计和merge按键连接。应根据业务含义决定处理方式：缺失成绩不能一律视为零；按学生编号合并时要检查重复键，否则可能产生多对多匹配使行数增加。将表格交给模型时，要明确特征列与目标列，并防止把姓名、学号等标识符误当成有效预测信息。

```
import pandas as pd
df = pd.DataFrame({'class': ['A', 'A', 'B'],
                   'score': [80.0, None, 90.0]})
print(df['score'].isna())
print(df.groupby('class')['score'].mean())
print(df.loc[df['score'].notna(), ['class', 'score']])
```

辨析与自测 自测：一列缺失值应在分割训练集和测试集前统一用全部数据的均值填补吗？答案：用于模型评估时不应这样做；**均值等拟合统计量应只由训练数据得到，再应用到测试集，以免泄露测试信息。**

本节来源：[6] [8]。完整书目信息与链接见书末。

2.3 数据可视化

2.3.1 Matplotlib 绘图基础

考纲要求：掌握

编者讲解 Matplotlib中的**Figure**表示整张画布，**Axes**表示画布中的一块绘图区，**Axis**则负责刻度等坐标轴元素。掌握绘图应先建立“数据—图形对象—坐标说明”的对应关系。plt.subplots返回Figure和Axes，随后调用ax.plot、ax.scatter等方法把数据画在指定区域；设置标题、坐标名称、单位和图例后，读者才能准确解释图像。一个Figure可以包含多个Axes，用于比较不同变量或方法。

编者讲解 plot(x,y)将对应的点按提供的顺序连接，不会自动把无序x排序；scatter(x,y)强调各观测点的位置。颜色、线型、标记符号和透明度控制视觉编码，不改变原始数据。label参数为系列命名，但通常还要调用legend才显示**图例**。loc='upper right'是图例位置，不会把散点移动到图的右上方。坐标范围由set_xlim和set_ylim控制，缩小范围可能隐藏异常点，必须避免形成误导。

编者讲解 多图绘制应明确每次操作的Axes。状态式plt.plot依赖当前绘图区，短程序可以使用，但复杂图更适合显式调用ax的方法。常见流程为导入库、准备等长数据、建立画布、绘制、添加说明、调整布局、**保存**和显示。保存可用fig.savefig；bbox_inches='tight'有助于避免文字被裁切。中文显示需要计算机已有的中文字体，字体设置失败通常是环境问题，而非数据问题。

例题与解析 例题：给定训练轮数[1,2,3,4]，训练损失[0.9,0.6,0.4,0.3]，验证损失[1.0,0.7,0.6,0.65]，在同一绘图区画两条折线，标记轮数并把图例放在右上方。应以轮数为x，损失为y，给每条线不同label；代码如下。观察可知训练损失持续下降，但验证损失在第4轮回升，提示需要继续检查泛化情况。不能只凭四个点认定发生了严重过拟合。

```
import matplotlib.pyplot as plt
x = [1, 2, 3, 4]
fig, ax = plt.subplots(figsize=(6, 4))
ax.plot(x, [0.9, 0.6, 0.4, 0.3], 'o-', label='train')
ax.plot(x, [1.0, 0.7, 0.6, 0.65], 's--', label='validation')
ax.set_xlabel('Epoch')
ax.set_ylabel('Loss')
ax.set_title('Learning curves')
ax.set_xticks(x)
ax.legend(loc='upper right')
ax.grid(alpha=0.3)
fig.tight_layout()
plt.show()
```

辨析与自测 阅读代码时，应先确认x与y长度一致、数组维度正确，再检查函数和参数。若plot传入二维y，可能生成多条线；若希望图例显示两类散点，就应分别绘制并提供两次label，或明确构造图例。自测：把ax.set_xlabel('Loss')误写在本例中会怎样？程序可能仍运行，但图意错误，因此“**可运行**”不等于“可读且正确”。

本节来源：[7]。完整书目信息与链接见书末。

2.3.2 常见图表类型绘制（2D散点图、3D散点图、折线图、条形图、箱型图、饼图等）

考纲要求：掌握

编者讲解 图表应由问题决定。**二维散点图**以两个坐标表现两项数值特征，可用颜色表示类别；**三维散点图**增加第三个数值坐标，但透视和遮挡可能使距离难判断。**折线图**适合展示具有时间或顺序意义的变化；条形图比较离散类别的数值；箱型图展示一组数据的中位数、四分位数及离散程度；饼图展示同一个整体的非负组成比例。条形图中的类别不需要连续，折线连接却会暗示相邻关系。

编者讲解 **箱型图**尤其容易混淆。箱体从第一**四分位数**Q1到第三四分位数Q3，箱内线通常为中位数，IQR=Q3−Q1。Matplotlib默认须线延伸到落在Q1−1.5IQR和Q3+1.5IQR范围内的最远数据点，范围外点单独标出。因此须线不总是最小值和最大值，**离群点**也不自动等于错误数据。饼图各扇区的角度由占比决定；如果类别不是互斥组成或分母不同，用饼图比较会失真。

例题与解析 例题：三种课程报名人数为20、30、50。**条形图**高度分别为20、30、50；若表示全部100名报名者的构成，**饼图**占比应为20%、30%、50%，对应圆心角为72°、108°、180°。另有三名学生的学习时长为1、2、3小时，成绩为55、70、88，练习次数为2、4、7，可分别画二维和三维散点图。二维散点呈正向变化并不证明增加学习时间必然造成相应成绩提升，还需考虑其他因素。

```
import matplotlib.pyplot as plt
fig = plt.figure(figsize=(10, 7))
x, y, z = [1, 2, 3], [55, 70, 88], [2, 4, 7]
a = fig.add_subplot(231)
a.scatter(x, y); a.set_title('2D scatter')
a = fig.add_subplot(232, projection='3d')
a.scatter(x, y, z); a.set_title('3D scatter')
a = fig.add_subplot(233)
a.plot(x, y, 'o-'); a.set_title('Line')
a = fig.add_subplot(234)
a.bar(['A', 'B', 'C'], [20, 30, 50]); a.set_title('Bar')
a = fig.add_subplot(235)
a.boxplot([[2, 3, 4, 5, 20], [3, 4, 5, 6, 7]])
a.set_title('Boxplot')
a = fig.add_subplot(236)
a.pie([20, 30, 50], labels=['A', 'B', 'C'], autopct='%1.0f%%')
a.set_title('Pie')
fig.tight_layout()
plt.show()
```

编者讲解 操作时应补齐各图坐标和单位，示例为了集中展示六种API只保留了标题。三维绘图区必须以projection='3d'创建，不能把第三列数据直接当作二维scatter的第三个位置参数，因为那个参数表示点的面积s。直方图hist统计连续变量落入区间的频数，条形图bar比较指定类别，两者不能仅因外观相似而互换。

辨析与自测 自测：对[2,3,4,5,20]，采用通常四分位计算得Q1=3、Q3=5，IQR=2，上界为8，因此20会作为离群点显示；它不是被自动删除。若要比较两班成绩分布的集中位置和分散程度，箱型图比仅画两个均值条形更有信息。

本节来源：[7]。完整书目信息与链接见书末。

基础模块

第3章 机器学习基础

3.1 机器学习基本概念

3.1.1 机器学习定义及原理

考纲要求：理解

机器学习（machine learning，ML）是一类强大的可以从经验中学习的技术。

原文选读 [4] 第1章 引言

编者讲解 学习问题需要明确**任务、经验和性能**三个要素。例如识别邮件是否为垃圾邮件，任务是二分类，经验是历史邮件及其标签，性能可用精确率、召回率等衡量。“经验”可以是已采集的数据，也可以是智能体与环境交互产生的反馈。机器学习不是让程序无目标地积累数据，而是通过某种学习规则，使模型在选定性能标准下改进。数据量增加也不保证效果必然提高，错误标签和**分布偏移**都可能损害结果。

编者讲解 一个常见的学习流程是：把实际问题转化为输入x和目标y，选定模型族f(x;θ)，规定损失函数L，利用训练数据寻找合适**参数**θ，再在未参与训练的数据上评估。θ表示模型内部可学习量，如线性模型权重；模型类型、邻居数K、学习率等通常属于**超参数**。训练是求参数，预测是在参数固定后把新输入代入模型。二者在代码中常对应fit和predict，但不同算法的内部训练形式并不相同。

编者讲解 核心目标是**泛化**，即在未见数据上仍表现良好。假设用过去学生的学习记录预测下一次测验是否达标，直接背下每个学生的姓名与成绩可能把训练集做得很好，但对新学生无帮助。需要选择与目标相关且预测时能获得的特征，并用合理划分的数据检查泛化。训练和实际使用若来自不同分布，例如只用清晰白天照片训练而用于雨夜，测试结论就可能不再适用。

辨析与自测 自测：调整神经网络权重与选择隐藏层数分别属于什么？前者通常是参数学习，后者是超参数或模型结构选择。一个程序保留全部训练样本后按最近邻预测，是否算学习？算；学习并不要求一定用梯度下降拟合少量参数。

本节来源：[4] [12] [15]。完整书目信息与链接见书末。

3.1.2 无监督学习（聚类、特征降维）概念

考纲要求：理解

编者讲解 **无监督学习**使用没有指定目标标签的数据，试图发现其中的结构。没有标签不等于没有目标：算法仍需要**优化准则**，例如让同一簇内样本更相似，或让低维表示保留更多变化信息。常见输入是**特征矩阵X**，输出可能是簇编号、低维坐标、密度估计或异常分数。使用者应根据任务验证结构是否有意义，不能把算法输出的任意编号直接解释为真实类别。

编者讲解 **聚类**把样本分成若干组，强调组内相似、组间不同。若只有用户浏览次数、停留时长和购买频率，没有人工给出的客户类型，聚类可以探索行为群体。距离或相似性的定义决定“像不像”：按消费总额聚类与按消费品类比例聚类，可能得到不同分组。因此特征选取、尺度处理和簇数设定属于实质性的建模决策，不是绘图之后才补充的细节。

编者讲解 特征**降维**把原来的d维表示转换为较小的k维表示。它可以减少冗余、便于可视化或降低后续计算成本，但会丢失部分信息。特征选择保留原有的一部分列，特征提取则构造新坐标；PCA属于后者。聚类主要回答“哪些样本归为一组”，降维主要回答“用较少坐标怎样表达样本”，二者可以串联使用，但并不相同。

辨析与自测 例如，把每个城市的12个月平均气温压缩为两个综合方向，是降维；再把气温变化模式相近的城市分组，是聚类。若先用人工定义的气候类别作标签训练分类器，就变成监督学习。自测：忽略手写数字标签，仅根据像素模式分组，是无监督聚类；得出10个簇也不能保证每簇恰好对应一个数字，因为书写风格可能比数字身份更显著。

本节来源：[10] [11]。完整书目信息与链接见书末。

3.1.3 有监督学习（分类、回归）概念

考纲要求：理解

分类问题的目标是预测数据属于一组类别中的哪一个。

原文选读 [12] 3.1 线性回归

编者讲解 有**监督**学习的训练样本同时具有**输入特征**x和**目标标签**y，算法利用输入与标签的对应关系学习预测函数。标签可以由人工标注，也可以来自可靠的历史记录或测量结果。所谓“监督”指训练过程有目标信号，不是指必须有人逐次监督程序运行。模型评估时同样需要真实目标，但测试标签只能用于最后评价，不能进入特征或训练过程。

编者讲解 **分类**的输出是类别，如合格与不合格、花的品种、邮件类型；**回归**的输出是有数值意义的量，如温度、等待时长和用电量。类别即使编码为0、1、2，也不会因此变成回归问题，因为编号间的差值通常没有距离含义。反过来，一个数值目标即使只显示整数，仍可作为回归目标；判断依据是任务意义而非数据是否带小数点。

编者讲解 分类模型常先输出各类别分数或概率，再通过阈值或最大值选择类别。二分类可以使用阈值0.5，但不同误判代价可能需要不同阈值；多分类通常取最大概率类别。回归一般直接输出预测数值，常用平方误差或绝对误差评价。若把数值温度转成“低、中、高”三个区间再预测，就改变了任务和评价标准，损失了区间内的细节。

辨析与自测 例：同一份学生数据，预测期末具体分数是回归；预测是否达到60分是二分类；预测优、良、中、差是多分类。自测：只输入X、不提供y运行聚类，随后给各簇命名，是否等同于监督分类？答案：不是；训练时没有利用类别标签。模型给出“80%概率合格”是否保证每个这样的学生都合格？答案：不是，概率表达不确定程度，还需要校准与群体统计验证。

本节来源：[4] [12] [13]。完整书目信息与链接见书末。

3.1.4 数据预处理（含特征工程）

考纲要求：掌握

编者讲解 **数据预处理**解决格式和质量问题，**特征工程**则把原始信息转成适合模型的表示，二者常有交叉。清洗时应检查重复、**缺失**、异常范围、单位和标签错误；特征构造时应考虑预测时能获得的信息。例如预测订单交付前是否延误，可以使用下单地点与当时库存，却不能使用最终签收时间，因为这直接泄露答案。先确定目标与数据采集时点，再决定哪些列可进入X。

编者讲解 数值缺失可用**训练集**均值、中位数或模型估计填补；分类缺失可设“未知”类别。异常值应先辨认是录入错误还是罕见真实事件，不能看到偏离均值就删除。无序类别常用**独热编码**，使每个类别对应一个指示列；把城市编码为1、2、3后直接计算距离，会引入不存在的顺序。**标准化**使每列减去训练均值再除以训练标准差，常用于KNN、PCA等对尺度敏感的方法。

$z = (x - \mu_train) / \sigma_train$。$\mu_train$、$\sigma_train$只由训练集计算；Min-Max缩放为$(x-min_train)/(max_train-min_train)$。常数列需避免除以零。

例题与解析 例题：某训练特征为[10,20,30]，均值20，按总体标准差计算$\sigma=\sqrt{(200/3)}\approx8.165$，三个标准化结果约为−1.225、0、1.225。测试样本40应变成$(40-20)/8.165\approx2.449$，不应重新把测试集居中为0。原因是模型学习的是以训练均值和尺度定义的坐标，测试输入必须使用同一坐标系统。

编者讲解 可靠流程是先分割数据，再在训练集上fit预处理器，在训练和测试集上分别transform。Pipeline可把预处理与模型组合，并让交叉验证每一折都只使用该折训练部分拟合预处理，减少泄露风险。特征选择、降维和缺失填补同样遵循这一原则。文本词表也应在训练资料上学习，不能把测试集信息悄悄注入模型。

```
from sklearn.pipeline import make_pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
pipe = make_pipeline(SimpleImputer(strategy='median'),
                     StandardScaler(),
                     KNeighborsClassifier(n_neighbors=3))
# X_train、X_test已由原始数据先行划分
# pipe.fit(X_train, y_train)
# y_pred = pipe.predict(X_test)
```

辨析与自测 自测：先对全部数据运行PCA再划分训练测试是否妥当？通常不妥，主成分已利用测试集分布。特征缩放是否总让树模型更准确？不一定，树按阈值分割，对单调尺度变换通常不敏感；预处理要依据算法而定。

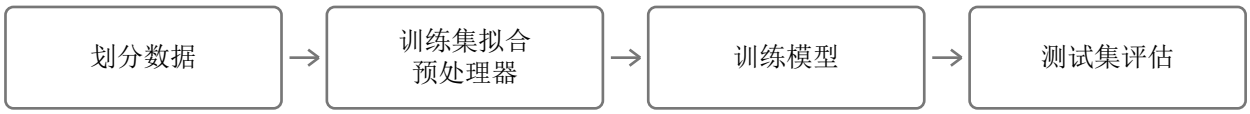


图3-1 防止数据泄漏的基本顺序

本节来源：[5] [6] [8]。完整书目信息与链接见书末。

3.1.5 模型训练基本概念

考纲要求：掌握

编者讲解 训练的目的，是在既定模型族和目标函数下确定可用于预测的模型状态。线性回归学习权重与截距，神经网络学习各层**参数**，KNN主要保存样本或建立近邻索引。参数由训练过程确定，**超参数**由使用者设定或通过验证选择，如邻居数K、正则化强度和网络层数。不能把fit理解为所有算法都执行同一套梯度更新。

编者讲解 **训练集**用于拟合参数，**验证集**用于选择模型、超参数或停止时机，**测试集**用于对最终方案作独立评价。若反复查看测试结果并据此调整模型，测试集实际上承担了验证集职责，报告的成绩就可能偏乐观。数据量较小时可使用交叉验证：将训练资料分成K折，每次用K−1折拟合、剩余一折评价，汇总各折结果后选择方案。最后测试集仍应保持独立。

编者讲解 神经网络训练中，batch是一次计算所用的样本小批量，epoch表示完整遍历训练数据一次，step通常表示一次参数更新。学习率决定每一步移动幅度，过大可能震荡，过小可能训练缓慢。初始化和样本打乱可影响结果，因此比较实验应记录随机种子、数据划分、参数和版本，但随机种子也不意味着在所有硬件上绝对得到相同结果。

例题与解析 例题：共有1000个样本，先留20%作测试，剩余训练资料中再留25%作验证。最终测试200、验证200、实际拟合600。若batch_size=64且不丢弃末批，每轮需要ceil(600/64)=10次更新，

10个epoch共100次更新。不能把1000/64直接当作每轮训练批数，因为测试和验证样本不参与参数更新。

```
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.datasets import load_iris
X, y = load_iris(return_X_y=True)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=8, stratify=y)
model = make_pipeline(StandardScaler(),
                      KNeighborsClassifier(n_neighbors=3))
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

辨析与自测 上例stratify=y用于近似保留类别比例，并不适合所有划分场景。时间序列要防止未来信息进入过去的训练；同一患者、设备或用户有多条记录时，也可能需要按实体分组，避免高度相似记录跨越训练与测试。自测：model.fit(X_test,y_test)之后再报告该测试集准确率是否有效？不能作为独立**泛化**评价，因为已用它训练。

本节来源：[4] [8] [15]。完整书目信息与链接见书末。

3.1.6 性能评估

考纲要求：掌握

编者讲解 评估首先要匹配任务和错误代价。分类常使用**混淆矩阵**，按真实类别和预测类别统计数量；二分类中把关注类别作为**正类**，TP表示真阳性，FP表示假阳性，FN表示假阴性，TN表示真阴性。**准确率**衡量全部样本中预测正确的比例，精确率关注被判为正的样本中有多少确实为正，召回率关注真实正例有多少被找出。报告时必须说明正类定义。

Accuracy=(TP+TN)/(TP+FP+FN+TN)；Precision=TP/(TP+FP)；Recall=TP/(TP+FN)；F1=2PR/(P+R)。分母为0时需说明所用实现的处理约定。

例题与解析 例题：100个样本中TP=18、FP=6、FN=12、TN=64。准确率82%，**精确率**18/24=75%，**召回率**18/30=60%，**F1**=2×0.75×0.60/1.35≈66.7%。模型漏掉40%的真实正例，不能只凭82%的准确率说它适合高召回需求。若数据中99%都为负类，始终预测负类也有99%准确率，却没有找出任何正例。

编者讲解 多分类可以对每类分别计算指标。macro平均给予各类别相同权重，weighted平均按各类样本数量加权，micro平均先汇总整体计数再计算。ROC曲线以假阳性率为横轴、真阳性率为纵轴，展示不同阈值的变化；AUC衡量排序区分能力，不是某个固定阈值下的准确率。正例稀少时，还应关注精确率—召回率曲线和实际阈值下的表现。

MAE=$(1/n)\Sigma|y_i-\hat{y}_i|$；MSE=$(1/n)\Sigma(y_i-\hat{y}_i)^2$；RMSE=$\sqrt{MSE}$；$R^2=1-\Sigma(y_i-\hat{y}_i)^2/\Sigma(y_i-\bar{y})^2$。

例题与解析 回归例：真实值[2,4,6]，预测[3,4,5]，绝对误差为[1,0,1]，故MAE=2/3，MSE=2/3，RMSE≈0.816；真实值均值为4，总离差平方和8，$R^2=1-2/8=0.75$。平方误差更强调大的偏差，MAE与RMSE保留目标单位，MSE单位为目标单位的平方。R^2 在某些测试集上可以小于0，表示比使用该测试集均值作为基准还差；不能把它机械解释为准确率。

```
from sklearn.metrics import classification_report, confusion_matrix
from sklearn.metrics import mean_absolute_error, mean_squared_error
print(mean_absolute_error([2, 4, 6], [3, 4, 5]))
print(mean_squared_error([2, 4, 6], [3, 4, 5]))
# 分类任务：
# print(confusion_matrix(y_test, y_pred))
# print(classification_report(y_test, y_pred, zero_division=0))
```

辨析与自测 自测：训练准确率可以代替测试准确率吗？不能。对同一测试集比较方案时，还应注意样本量、类别分布、置信程度与实际错误案例；一个总分无法解释模型对不同人群或不同环境是否同样有效。

本节来源：[13] [15]。完整书目信息与链接见书末。

3.2 机器学习基础方法

3.2.1 线性回归

考纲要求：掌握

回归（regression）是能为一个或多个自变量与因变量之间关系建模的一类方法。

原文选读 [12] 3.1 线性回归

编者讲解 线性回归以输入特征的**加权和**加上**截距**预测数值目标。单变量时是一条直线，多变量时是高维空间中的仿射超平面。**权重**表示其他特征固定时，相应特征改变一个单位所带来的预测变化；这种解释依赖模型和数据，不能直接当成因果效应。截距允许整体平移，否则直线被迫经过原点，往往不符合实际关系。

$\hat{y}=b+w_1x_1+\cdots+w_dx_d$。常用目标$J=(1/n)\Sigma(\hat{y}_i-y_i)^2$。单变量且$\Sigma(x_i-\bar{x})^2>0$时，$w=\Sigma(x_i-\bar{x})(y_i-\bar{y})/\Sigma(x_i-\bar{x})^2$，$b=\bar{y}-w\bar{x}$。

例题与解析 例题：观测点为(1,2)、(2,3)、(3,5)。x均值为2，y均值为10/3；分子为3，分母为2，所以w=1.5，b=1/3。得到$\hat{y}=1.5x+1/3$。三点预测分别为11/6、10/3、29/6，误差分别为−1/6、1/3、−1/6，误差平方和1/6，**均方误差**1/18≈0.0556。当x=4时，预测为19/3≈6.333。这个数值是模型外推，不能仅因公式能计算就认为同样可靠。

编者讲解 **最小二乘**法选择使误差平方和最小的参数，也可通过梯度下降近似求解。多变量时如果特征之间高度相关，不同权重组合可能给出接近的预测，参数解释会不稳定；正则化可以约束

过大的权重。线性回归并不要求每个输入量都天然线性，加入x^2等构造特征后，模型仍可对待学习系数保持线性，但过多构造特征会提高过拟合风险。

```
import numpy as np
from sklearn.linear_model import LinearRegression
X = np.array([[1.0], [2.0], [3.0]])
y = np.array([2.0, 3.0, 5.0])
model = LinearRegression().fit(X, y)
print(model.coef_)       # 约 [1.5]
print(model.intercept_)  # 约 0.333333
print(model.predict([[4.0]]))
```

辨析与自测 自测：若所有x相同，上述单变量公式会怎样？分母为0，无法唯一确定斜率。若预测房价，能否把房屋编号作为连续数值特征直接期待得到规律？通常不能，编号的数值差异缺少相应业务含义。阅读程序时注意X通常为二维，单特征也用(n,1)，而y通常为(n,)。

本节来源：[12] [13]。完整书目信息与链接见书末。

3.2.2 K 近邻算法

考纲要求：掌握

编者讲解 **K近邻**的核心是假设特征空间中接近的样本具有相近目标。预测新样本时，计算它到训练样本的距离，选出最近的K个；分类通常**多数投票**，回归通常求目标均值，也可以按**距离加权**。这里K是邻居数量，与类别数量无关。算法不要求先拟合一条全局分界线，但预测可能需要检索大量训练样本，存储和查询成本不能忽略。

> 欧氏距离$d(x,z)=\sqrt{\Sigma_j(x_j-z_j)^2}$。等权分类选K个邻居中出现次数最多的类别；等权回归取$\hat{y}=(1/K)\Sigma$邻居目标。

例题与解析 例题：查询点q=(2,2)，训练点A=(1,1)，类别0；B=(2,1)，类别0；C=(3,2)，类别1；D=(5,5)，类别1。距离分别为√2、1、1、√18。当K=3时选B、C、A，类别0有两票，类别1有一票，所以预测0。如果用同样邻居作回归且目标分别是10、14、20，则预测(14+20+10)/3≈14.667。应先选邻居再处理标签，不是先看目标值相近程度。

编者讲解 K很小时模型容易受噪声和局部异常影响，K很大时局部边界被过度平滑，可能忽略小群体。K应通过训练资料内的验证选择，不能用测试集寻找最佳值。**欧氏距离**受量纲影响，例如收入以元计、年龄以岁计时，收入差异可能主导距离，因此常先**标准化**。特征越多，距离区分能力可能越差，无关特征会干扰邻居选择。

```
from sklearn.neighbors import KNeighborsClassifier
X = [[1, 1], [2, 1], [3, 2], [5, 5]]
y = [0, 0, 1, 1]
model = KNeighborsClassifier(n_neighbors=3)
model.fit(X, y)
print(model.predict([[2, 2]]))  # [0]
print(model.kneighbors([[2, 2]])[0])
```

编者讲解 分类投票平局、邻居距离恰好相同和零距离点都需要明确实现规则；不能笼统认为K取奇数就能避免全部平局，因为多分类仍可能平票。按距离加权时近点影响更大，但也更容易受近处错误标签影响。若训练集中只有4点，不能要求预测时寻找5个邻居。

辨析与自测 自测：KNN是无监督算法吗？用于带标签分类或回归的KNN属于监督学习；仅查询邻居关系本身可以不使用标签。KNN与K-Means都含K，但前者K指邻居数，后者K指簇数，训练目标也完全不同。

本节来源：[8] [9]。完整书目信息与链接见书末。

3.2.3 K-Means 聚类

考纲要求：掌握

编者讲解 K-Means把n个样本划分为K个**簇**，并用每个簇的均值作为**中心**，目标是降低样本到所属中心的**平方距离总和**。它主要适用于数值特征与欧氏距离场景。聚类标签只是区分簇的编号，0号簇并不天然比1号簇更好，也没有自动的业务含义；通常要根据簇中心和样本特征再解释各组。

$J=\Sigma_i \| x_i-\mu_{(c_i)} \|^2$。$c_i$为样本$i$所属簇，$\mu_k$为簇$k$中心；更新时$\mu_k=(1/|C_k|)\Sigma_{(i\in C_k)}x_i$。

编者讲解 算法先给出K个初始中心，再交替执行分配与更新：把每个样本分给最近中心，然后以簇内样本均值替换中心，直到分配稳定或满足停止条件。分配固定时均值最小化该簇平方距离和；中心固定时选最近中心最小化每个样本的贡献。因此目标通常不增，但不能保证得到全局最优，初始中心不同可能形成不同结果。

例题与解析 例题：一维样本[1,2,8,9]，K=2，初始中心1和8。第一次分配得到{1,2}与{8,9}，更新中心为1.5和8.5。再次分配不变，最终平方距离和为0.25+0.25+0.25+0.25=1。如果K=1，中心为5，平方距离和为16+9+9+16=50。K增加通常能降低训练内的平方误差，但不能因此无限增大K；K=n时误差可为0，却失去概括分组的意义。

```
import numpy as np
from sklearn.cluster import KMeans
X = np.array([[1.0], [2.0], [8.0], [9.0]])
model = KMeans(n_clusters=2, random_state=0, n_init=10)
labels = model.fit_predict(X)
print(model.cluster_centers_)
print(model.inertia_)  # 约为1；簇编号顺序可能不同
```

编者讲解 实际使用时，应检查尺度、异常值、簇数和稳定性。K-Means倾向于得到围绕均值、近似凸形的簇，对大小密度差异明显、月牙形等结构可能不合适。离群值会拉动均值中心。k-means++提供更合理的**初始化**，多次初始化可降低偶然落入较差局部解的概率。空簇需要由实现采用重置中心等策略处理，不可对空集合直接求均值。

辨析与自测 自测：输入训练标签y是K-Means必需条件吗？不是。若把同一数据的第二列乘1000而不缩放，聚类可能改变，因为距离几何改变了。聚类好坏可结合**轮廓系数**、稳定性与实际任务解释，不能只看图形漂亮与否。

本节来源：[5] [10]。完整书目信息与链接见书末。

3.2.4 PCA

考纲要求：知道

编者讲解 PCA即**主成分分析**，是常见的线性降维方法。它寻找**相互正交**的方向，使数据投影到第一个方向时具有尽可能大的**方差**，在与前面方向正交的限制下继续寻找后续方向。保留前k个方向，把原来d个特征转成k个主成分坐标。**主成分是原特征的线性组合，因此PCA通常属于特征提取，而不是简单删除若干列。**

编者讲解 计算前通常将各列中心化；若单位或尺度差异显著，还应考虑标准化。可以通过**协方差**矩阵的特征分解或数据矩阵的奇异值分解求主方向。解释方差比例反映各主成分保留的变化量，累计解释方差可辅助选择维数。scikit-learn的PCA会中心化但不会自动把各列标准化，使用者应根据含义决定是否加入StandardScaler。

编者讲解 例如二维数据大多沿对角线展开，横纵坐标高度相关，沿对角线的一维投影可能保留主要变化，垂直方向只留下少量残差。但“方差大”不等于“对预测标签最有用”：某个变化很小的方向可能恰好区分类别，而PCA不看标签，可能将它丢弃。因此降维后应重新评价下游任务，不能把保留95%方差解释为保留95%分类准确率。

辨析与自测 自测：对测试集单独重新拟合PCA是否合理？不合理，应使用**训练集**学到的均值和主方向转换测试集。主成分方向符号取反会改变坐标正负，却不改变所代表的投影子空间。二维变一维后一般无法无损恢复原始数据，只有被舍弃方向无变化等特殊情形例外。

本节来源：[5] [11]。完整书目信息与链接见书末。

基础模块

第4章 深度学习基础

4.1 神经网络基本概念

4.1.1 人工神经网络基础

考纲要求：掌握

> 多层感知机在输出层和输入层之间增加一个或多个全连接隐藏层，并通过激活函数转换隐藏层的输出。

原文选读 [14] 4.1.3 小结

编者讲解 人工神经网络由相互连接的计算单元构成。一个基本神经元先把输入按**权重**加总并加上**偏置**，再用**激活函数**得到输出。权重决定输入的相对作用，偏置调整响应位置，激活函数提供非线性。输入层表示观测特征，隐藏层产生中间表示，输出层的结构由任务决定。网络“学习”的是使训练目标改善的参数，不是把每个计算单元直接解释为人脑中某个神经元。

> 单元输出a=φ(Σ_jw_jx_j+b)。全连接层有d个输入、h个输出且每个输出带一个偏置时，参数数目为d×h+h。

例题与解析 例题：输入有4个特征，**隐藏层**含5个神经元，**输出层**含3个神经元。第一层参数为4×5+5=25，第二层参数为5×3+3=18，总计43。若一批有10个样本，输入形状(10,4)，隐藏输出(10,5)，最终输出(10,3)。批量大小改变中间数据的行数，不改变43个可学习参数。**输入层**通常不计入可学习层数，因此这是一个含两个参数层的网络。

编者讲解 如果所有层都只做线性或仿射变换，多层连乘仍等价于一个仿射变换，增加深度无法自动带来非线性能力。引入ReLU等函数后，网络才能构造更复杂的决策边界。二分类常用一个sigmoid输出，多分类互斥类别常用多个softmax输出，回归常用线性输出。多标签任务允许多个类别同时成立，不能机械套用总和为1的softmax。

```
import tensorflow as tf
model = tf.keras.Sequential([
    tf.keras.layers.Dense(5, activation='relu', input_shape=(4,)),
    tf.keras.layers.Dense(3, activation='softmax')
])
model.summary()  # 参数总数应为43
```

编者讲解 建立网络之后还需要数据、损失函数、优化器和评价方法，只有结构不能完成学习。隐藏单元越多，表达能力通常越强，但也提高存储计算需求和过拟合风险。图像展平为向量会保留像素值，却不再显式保留二维邻接结构，这也是后续卷积网络使用局部连接的重要动机。

辨析与自测 自测：把批量从10改成20，总参数会翻倍吗？不会。把第一层隐藏单元从5改成6，则参数为4×6+6+6×3+3=51。**参数量计算必须包括偏置，并检查输出层也随隐藏维数改变。**

本节来源：[14] [18] [26]。完整书目信息与链接见书末。

4.1.2 前向传播

考纲要求：掌握

> 前向传播（forward propagation或forward pass） 指的是：按顺序（从输入层到输出层）计算和存储神经网络中每层的结果。

原文选读 [16] 4.7.1 前向传播

编者讲解 **前向传播**回答“给定输入和现有参数，网络会产生什么输出”。从输入开始，按依赖顺序计算加权和、偏置、激活值，直到预测结果；训练时还会把预测与标签结合计算损失。它本身不要求修改权重。**参数更新**还需要**反向传播**计算梯度，再由优化器执行更新。**因此predict进行前向计算，不等同于再训练模型。**

> 采用行向量/批量记法：$H=\mathrm{ReLU}(XW_1+b_1)$，$O=HW_2+b_2$。若需分类概率，再计算$P=\mathrm{softmax}(O)$；矩阵相乘的内侧维数必须一致。

例题与解析 例题：单样本$X=[1,2]$，$W_1=[[1,-1],[2,1]]$，$b_1=[0,-1]$。先得$XW_1=[5,1]$，加偏置得$[5,0]$，ReLU后$H=[5,0]$。设$W_2=[[1,-1],[0,2]]$，$b_2=[0,1]$，则$O=[5,-4]$。softmax可先减去最大值5，得到$\exp([0,-9])$后归一化，概率约为$[0.999877,0.000123]$，故预测类别0。这个计算展示了数据流向，数值大并不证明模型训练得好。

```
import numpy as np
X = np.array([[1.0, 2.0]])
W1 = np.array([[1.0, -1.0], [2.0, 1.0]])
b1 = np.array([0.0, -1.0])
W2 = np.array([[1.0, -1.0], [0.0, 2.0]])
b2 = np.array([0.0, 1.0])
H = np.maximum(X @ W1 + b1, 0)
O = H @ W2 + b2
E = np.exp(O - O.max(axis=1, keepdims=True))
P = E / E.sum(axis=1, keepdims=True)
print(H, O, P, P.argmax(axis=1))
```

编者讲解 批量计算并不是把不同样本相互混合。X的每一行代表一个样本，矩阵乘法同时处理多行，各样本共享同一组权重；偏置沿批量轴广播。softmax通常应沿类别轴进行归一化，若误沿样本轴归一化，会让不同样本的输出互相竞争。保留keepdims=True能够使广播维度更清晰。

辨析与自测 某些层在**训练和推理**时行为不同，例如**Dropout**训练时随机屏蔽部分活性值，而推理时使用相应的确定性行为；因此前向传播还需指定当前模式。自测：已有正确输出后，把学习率从0.01改为0.1但不更新参数，本次普通网络的预测会改变吗？不会；学习率作用于参数更新，不直接进入这一前向公式。

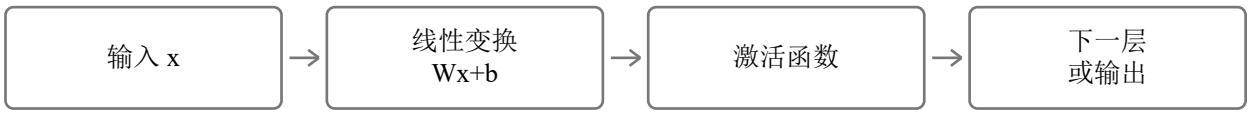


图4-1 一层神经网络的前向计算

本节来源：[14] [16] [26]。完整书目信息与链接见书末。

4.1.3 激活函数

考纲要求：理解

常用的激活函数包括ReLU函数、sigmoid函数和tanh函数。

原文选读 [14] 4.1.3 小结

编者讲解 激活函数通常接收神经元的加权和与偏置结果，再输出活性值。其关键作用是引入**非线性**，使网络不再只是多个线性映射的合并。选择激活函数还会影响**输出范围**、梯度传播和训练稳定性。隐藏层需要形成有用表示，输出层需要符合目标含义，这两处的选择依据并不完全相同。

ReLU(z)=max(0,z)；sigmoid(z)=1/(1+e^(−z))；tanh(z)=(e^z−e^(−z))/(e^z+e^(−z))。

softmax(z)_j=e^(z_j)/Σ_ke^(z_k)。

编者讲解 **ReLU**把负输入变成0，正输入保持不变，计算简单；正区间导数为1，负区间为0，0点数学上不可导，框架使用约定值。若某单元总落在负区间，它可能长期收不到有效梯度。**sigmoid**输出位于0到1之间，适合二分类概率；**tanh**位于−1到1之间并以0为中心。sigmoid和tanh在输入绝对值很大时趋于饱和，导数接近0，多层连乘可能造成梯度变小。

辨析与自测 **softmax**对整组类别分数共同归一化，输出非负且和为1，适合**互斥多分类**；每个sigmoid输出则可以独立变化，适合多个标签同时为真的情形。例：z=0时sigmoid为0.5，tanh为0，ReLU为0；二分类概率0.5表示在模型当前输出下两类没有明显优势，不表示输入“没有信息”。自测：十个输出神经元是否必须softmax？不必须，要看任务是十个互斥类别、十个独立标签还是十个连续值。

本节来源：[14] [26]。完整书目信息与链接见书末。

4.1.4 损失函数

考纲要求：理解

编者讲解 **损失函数**把预测与真实目标之间的差异转化为可优化的数值。单样本损失描述一次预测的代价，训练目标通常是全体或小批量损失的平均，有时再加**正则化项**。损失越小只说明在当前定义的目标下更好，不保证所有业务指标都更好。**准确率**是离散判断，参数小幅改变时可能完全不变，因此分类训练通常使用更适合梯度优化的交叉熵，而把准确率作为评价指标。

平方损失：$(\hat{y}-y)^2$。二分类交叉熵：$-[y \ln p+(1-y)\ln(1-p)]$。多分类交叉熵：$-\Sigma_j y_j \ln p_j$，独热标签时等于$-\ln p_{true}$。

编者讲解 回归中**均方误差**重视较大的偏差，平均绝对误差则按误差大小线性惩罚。分类**交叉熵**鼓励把较高概率分配给真实类别。例：真实类别为1，一个模型给该类概率0.8，其损失为$-\ln 0.8\approx 0.223$；另一个给0.2，损失≈1.609。再如两个模型给真实类别的概率分别为0.3与0.2且都误分类，准确率同为0，但交叉熵分别约1.204与1.609，仍能区分错误的严重程度，为训练提供连续反馈。

编者讲解 使用TensorFlow时，整数类别**标签**配sparse_categorical_crossentropy，独热标签配categorical_crossentropy；二分类单输出常配binary_crossentropy。若输出层已做softmax或sigmoid，损失通常接收概率；若输出未归一化分数，应使用相应损失对象并正确设置from_logits=True，避免重复归一化或把任意实数误当概率。标签编码、输出维数和损失函数是一个整体约定。

辨析与自测 自测：三分类标签为整数2，输出概率[0.1,0.2,0.7]，交叉熵为多少？答案：$-\ln 0.7\approx 0.357$。更换为均方误差后程序也许能计算，但优化含义已经改变，不能只凭“不报错”认定损失选择正确。

本节来源：[12] [18] [26]。完整书目信息与链接见书末。

4.1.5 过拟合与欠拟合

考纲要求：理解

如何发现可以泛化的模式是机器学习的根本问题。

原文选读 [15] 4.4 模型选择、欠拟合和过拟合

编者讲解 **欠拟合**表示模型尚未充分表达或学到数据中的主要规律，常表现为训练和验证效果都不理想。原因可能是模型过于简单、特征缺少关键信息、**正则化**过强，也可能只是训练不足。**过拟合**表示模型过度适应训练样本中的偶然性和噪声，训练效果很好而独立验证明显较差。应比较训练与验证曲线及错误案例，而不能只看模型是否复杂或训练轮数是否很多。

编者讲解 假设真实趋势近似弯曲，用直线只能粗略拟合，就可能欠拟合；用极高次多项式穿过每个含噪样本，曲线在样本之间剧烈摆动，则可能过拟合。增加参数通常提高表达能力，却不自

动提高**泛化**能力；增加有代表性的数据、限制复杂度、加入正则化或数据增强可帮助控制过拟合。**早停**是在验证表现不再改善时保存较好的模型，不能用测试集决定停止时刻。

编者讲解 诊断还要排除其他原因。**训练与验证**差距很大，可能因为两者分布不同或划分方式错误；两者都差，也可能因为标签错误、特征缩放不当或优化未收敛。训练损失和验证损失若采用不同正则化计算或Dropout模式，数值也可能不直接可比。因此应先确保评价条件一致，再针对原因调整。

辨析与自测 例：某模型训练准确率99%、验证70%，减少网络规模后变为94%与82%，虽然训练分下降，泛化可能更好。自测：训练、验证准确率均为55%，应优先加更强正则化吗？通常不是，应先检查数据、特征、容量与训练是否充分。**训练损失继续下降而验证损失持续上升，是过拟合的典型信号，但结论仍需结合独立数据与波动情况。**

本节来源：[8] [15]。完整书目信息与链接见书末。

4.2 典型神经网络基础

4.2.1 序贯模型（Sequential）

考纲要求：掌握

> A Sequential model is appropriate for a plain stack of layers where each layer has exactly one input tensor and one output tensor.

原文选读 [18] When to use a Sequential model；正文原句去除网页内联代码样式

编者讲解 **Sequential**按给定顺序把层连接起来，上一层的输出成为下一层输入，适合简单的**单输入、单输出**层链。它是组织网络的API方式，不是一种独立的学习算法，也不表示只可处理时间序列。残差连接、多分支、多输入等结构一般应使用**函数式API**或自定义模型。考纲环境为TensorFlow 2.5，本节使用tf.keras命名空间，避免照搬当前独立Keras的新写法。

编者讲解 模型使用可分成构建、编译、训练、评估和预测。构建确定层与形状；**compile**指定优化器、损失和评价指标；**fit**使用训练数据更新参数；evaluate在提供的数据上计算损失和指标；**predict**输出预测值。保存用model.save，读取用tf.keras.models.load_model。对多分类概率矩阵，使用argmax(axis=1)得到类别。TensorFlow 2.5仍保留predict_classes，但已标记弃用，宜避免依赖该接口。

例题与解析 例题：输入两个数，隐藏层4个ReLU单元，输出2个softmax单元，目标是整数0或1。参数量为2×4+4+4×2+2=22。若送入4个样本，输出概率形状为(4,2)，类别向量形状为(4,)；loss应选稀疏类别交叉熵。下面使用4个合成样本演示调用流程，这种极小数据仅用于检查程序组织，不能证明模型具备可靠泛化性能。

```
import numpy as np
import tensorflow as tf
X = np.array([[0, 0], [0, 1], [1, 0], [1, 1]], dtype=np.float32)
y = np.array([0, 1, 1, 0], dtype=np.int32)
model = tf.keras.Sequential([
    tf.keras.layers.Dense(4, activation='relu', input_shape=(2,)),
    tf.keras.layers.Dense(2, activation='softmax')
])
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.fit(X, y, epochs=2, batch_size=2, verbose=0)
prob = model.predict(X, verbose=0)
pred = np.argmax(prob, axis=1)
print(prob.shape, pred.shape)  # (4, 2), (4,)
# 实际评价请另用独立X_test、y_test：
# model.evaluate(X_test, y_test, verbose=0)
```

编者讲解 在图像任务中，Flatten只改变每个样本的维度组织，不具有可训练参数。例如28×28灰度图展平为784维，接40个神经元的Dense层时参数为784×40+40=31400。validation_split用于从传入训练数组中保留一部分作验证，验证数据不参与梯度更新；但具体划分是否符合时间顺序、分组要求仍需使用者负责。

辨析与自测 自测：compile会自动训练吗？不会；summary打印层和参数信息，也不会训练。若标签是整数而误写categorical_crossentropy，通常会出现形状或含义不匹配；若改成独热标签，则要同时检查输出类别数。

本节来源：[14] [18] [26]。完整书目信息与链接见书末。

4.2.2 Transformer 基础

考纲要求：知道

Transformer模型完全基于注意力机制，没有任何卷积层或循环神经网络层

原文选读 [17] 10.7 开篇；摘录原句中的完整连续分句

编者讲解 这里的原文描述原始**Transformer**架构。Transformer以**注意力机制**建立序列**位置**之间的联系，使一个位置能够根据当前内容汇聚其他位置的信息。输入先转成向量表示，并加入位置信息，因为单纯自注意力不自动知道词语先后。自注意力的查询、键和值来自同一序列，多头机制则让多个注意力计算并行学习不同关联。

编者讲解 原始结构包含**编码器**与**解码器**。编码器把输入序列转换为上下文表示；解码器利用已经生成的目标内容及编码器表示产生后续输出。每个模块还包含前馈网络、残差连接和规范化。因果掩码阻止生成位置访问未来目标词，避免训练时提前看到答案。后续模型可以只采用编码器、只采用解码器，或保留编码器—解码器结构，不能认为所有Transformer都必须包含两部分。

编者讲解 它适用于语言、视觉和语音等数据。与按时间递推的RNN相比，许多训练计算可以在序列位置上**并行**，也更容易直接联系相距较远的位置；但标准全注意力需要计算位置两两关系，序列长度增加时成本较高。自回归生成仍通常逐步输出词元，不能把“训练可并行”理解为任意生成过程都能一次完成。

辨析与自测 自测：Transformer是否天然拥有知识库？不是，结构提供信息处理方式，知识与能力来自数据、训练和使用方式。位置编码是为了表达顺序或位置，softmax注意力权重也不能直接当作完整的因果解释。更深入的计算将在综合模块Transformer知识点中展开。

本节来源：[17]。完整书目信息与链接见书末。

基础模块

第5章 计算机视觉基础

5.1 计算机视觉方法基础

5.1.1 图像分割与分类

考纲要求：知道

它重点关注于如何将图像分割成属于不同语义类别的区域。

原文选读 [52] 13.9 导言

编者讲解 **图像分类**以整幅图像或预先截取的图像区域为输入，输出类别，例如把一张产品照片判成“合格”或“缺陷”。**图像分割**的输出则保留**空间位置**：它把像素分成若干区域。语义分割给每个像素赋予道路、车辆、背景等类别；实例分割还会区分属于同一类别的不同个体。对于一幅同时含三辆汽车的照片，语义分割可以把三辆车涂成同一种颜色，实例分割要分别标记三辆车。

编者讲解 从数据准备看，分类常用一张图对应一个标签；**语义分割**需要与原图大小对应的标签图，标注费用通常更高。传统分割可按照亮度阈值、颜色或相邻**像素**相似性划分区域；学习式分割根据带标签的样本学习像素与语义的关系。亮度相似并不保证物体相同，因此仅按颜色分出的区域不一定具有“车辆”这样的语义。

辨析与自测 例如校园草坪照片的任务若是“这张照片是否有杂草”，属于分类；若是“哪些像素是杂草”，属于分割；若还要“把每株杂草分别计数”，则需要实例区分。自测：把图像缩成一个类别标签后，能否直接得到杂草面积？答案是不能，因为面积需要像素位置或其他空间测量。基础阶段应能根据输出形式识别任务，不必把所有视觉任务都叫作图像分类。

本节来源：[52] [53]。完整书目信息与链接见书末。

5.1.2 目标检测与识别

考纲要求：知道

在目标检测中，我们通常使用边界框（bounding box）来描述对象的空间位置。

原文选读 [53] 13.3.1 边界框

编者讲解 **目标检测同时回答“是什么”和“在哪里”**。典型输出是一组类别、位置和**置信分数**，而不是整幅图只有一个标签。位置常用**边界框**表示；若左上角为(10,20)、右下角为(50,80)，则框宽40、高60，中心为(30,50)。像素坐标的横轴一般向右、纵轴向下，不能不加说明地套用纵轴向上的平面直角坐标。

编者讲解 识别是含义较宽的术语，可指判断对象类别，也可指确认具体对象身份。考试若写“**目标检测**与识别”，应结合题目输出判断：检测车辆并给出矩形是定位与分类；读出车牌字符是字符识别；判断两张人脸是否属于同一人又是身份验证。检测器常先把图像变为特征，再预测候选框及类别，最后消除围绕同一目标的重复框。

辨析与自测 以货架盘点为例，图像分类可报告“这是饮料货架”，检测可报告五个瓶子的框，**细粒度识别**进一步判断每瓶的品牌。遮挡、远处的小目标、低照度和相似外观都可能造成**漏检**或**误检**。自测：检测结果有八个框就一定有八个物体吗？答案是否定的，同一物体可能被重复框住，也可能存在误检；置信分数也不等于经过严格校准的真实正确概率。

本节来源：[53]。完整书目信息与链接见书末。

基础模块

第6章 语音处理基础

6.1 语音处理方法基础

6.1.1 语音识别（说话人、关键词、认证、增强）

考纲要求：知道

编者讲解 **语音识别**通常指把声音波形转成词或文字序列，即识别“说了什么”。考纲括号中的项目涉及不同任务：**说话人识别**关心“是谁在说”；**关键词检测**关心指定词是否出现；说话人认证判断当前声音是否与声称身份相符；语音增强则尽量抑制噪声、改善信号质量，输出往往仍然是声音。它们可以组合在同一系统中，但标签、输出和评价指标不同。

编者讲解 语音系统先由麦克风采样得到随时间变化的数字信号，再划分短时片段并形成频谱等表示，由模型预测文字、身份或其他目标。语言内容会受口音、语速、词汇、环境噪声影响；身份特征也会随设备、疾病和情绪变化。因此，在安静环境训练的模型不能未经测试就假定适用于嘈杂会议室。增强后声音更悦耳，也不自动意味着识别错误更少。

辨析与自测 例如语音门禁可先检测唤醒词，再提取说话人特征，与登记模板比对；高风险操作还需其他认证措施。自测：“请把音乐关掉”被正确转成文字，能否证明说话者是账户本人？不能，内容识别与身份认证是两项能力。关键词检测应同时关注漏唤醒和误唤醒；认证应区分**错误接纳**冒用者与**错误拒绝**本人，不能只报告一个含糊的准确率。

本节来源：[57] [59]。完整书目信息与链接见书末。

6.1.2 语音合成（如文本到语音）

考纲要求：知道

编者讲解 文本到语音简称**TTS**，其输入是**文字**，输出是可播放的**声音波形**。**它与语音识别的输入输出方向相反**。一个典型流程先处理文字，把数字、日期、缩写转换为适合朗读的形式，确定多音字或词的读音，再规划停顿、重音、语速等韵律，最后由声学模型与波形生成模块产生声音。端到端模型可能把多个步骤联合学习，但这些功能仍然需要完成。

编者讲解 声音能被听清是可懂度，听起来像自然说话是**自然度**，与目标说话者相似是音色相似度，这三项不能互相替代。例如播报“3.5”时，应根据语境区分小数、版本号或日期；只把字符逐个读出可能发音清楚，却表达错误。语音合成用于导航播报、无障碍阅读和对话系统，通常还需控制响应时间以及专业名称的发音。

辨析与自测 设系统要读“会议在2025年5月3日举行”。文本处理应先确定日期读法，再安排自然停顿，而不应把所有数字当作同一个大整数。自测：有字幕的视频一定使用了语音合成吗？不一定，字幕可能来自语音识别，合成的结果是声音。评价时可请听者评分或做听写测试；不能只凭波形看起来平滑就认定语音自然。涉及特定个人音色的应用还应获得相应授权，并让听众能辨认合成内容。

本节来源：[59]。完整书目信息与链接见书末。

基础模块

第7章 自然语言处理基础

7.1 自然语言处理方法基础

7.1.1 垂直任务类（机器翻译、问答系统、信息抽取等）

考纲要求：知道

编者讲解 **自然语言处理**把人类语言转化为计算机可分析或生成的表示。垂直任务强调明确的输入输出和应用目标：**机器翻译**把源语言表达转换为目标语言表达；**问答系统**针对问题返回答案；信息抽取把文本中的实体、关系、事件等转成结构化记录。三者可能使用相同的神经网络结构，但并不是同一个任务，也不应仅以文字是否流畅判断质量。

编者讲解 例如“甲公司于周一收购乙公司”可以译成另一种语言，可以回答“谁收购了乙公司”，也可以抽取“收购方=甲公司、被收购方=乙公司、时间=周一”。抽取时要保留原文支持的事实，不可擅自补全未给出的金额；问答时还应说明依据来自哪段材料。领域术语、代词指代、否定和时间表达都会影响结果，例如“未收购”与“收购”不能抽成同一事实。

辨析与自测 任务设计通常包括准备样本、规定输出格式、划分测试集并选择指标。翻译可结合自动指标和人工语义检查；抽取可比较实体边界、类别或关系是否正确；问答应检查答案正确性与**证据支持**。自测：模型回答得很长是否就说明问答质量高？答案是否定的。若题目要求从给定公告抽出开会日期，输出一段通顺但没有依据的解释仍然是不合格结果。

本节来源：[17] [59] [63] [64]。完整书目信息与链接见书末。

基础模块

第8章 人工智能应用基础

8.1 智能社会基础

8.1.1 智能社会概念

考纲要求：知道

编者讲解 **智能社会**可理解为人工智能与数据基础设施进入**公共服务**、生产和日常生活后形成的社会运行形态。它不仅包含单个智能产品，还涉及服务如何协同、人与系统怎样分工以及决策如何接受**监督**。智能城市是重要场景，但社会还包括乡村、社区、教育、就业等更广范围，因此二者不能简单视为同义词。

编者讲解 公共服务通常经历感知、分析、决策与反馈。例如水位传感器提供城市积水信息，预测模型估计风险，调度系统辅助安排抢修，处置结果再返回平台。传感器联网使数据能够流动，而人工智能帮助从数据中识别规律；只是把纸质表格搬到网络上，并不等于已经建立了智能决策能力。

辨析与自测 假设社区用模型安排独居老人探访，输入可包含经过授权的服务需求和历史安排，输出是待人工确认的探访建议。评价不能只有处理速度，还要考虑漏掉真正需要帮助的人、不同群体的**可及性**和纠错途径。自测：智能社会是否意味着所有公共决策都由算法自动决定？不是。明确责任、允许**人工复核**、保留非数字服务渠道，是让系统真正服务人的必要条件；数据越多也不自动代表治理越好。

本节来源：[68]。完整书目信息与链接见书末。

8.2 智能交通基础

8.2.1 智能交通概念

考纲要求：知道

编者讲解 智能交通把**交通感知、通信、计算与控制**结合，用于提升出行安全、通行效率和交通服务质量。应用包括拥堵预测、公交到站预测、信号灯控制、辅助驾驶和自动驾驶。自动驾驶只是其中一个部分；一个不具备无人驾驶车辆的城市，也可以拥有智能信号调度和公交服务系统。

编者讲解 交通数据可能来自摄像机、道路检测器、车辆定位和车路通信。**感知**模块识别车辆、行人或道路状态，**预测**模块估计流量、速度或未来运动，决策模块给出路线和控制方案，执行后

继续监测。车路协同强调车辆与道路设施交换信息，但通信信息也可能延迟或缺失，不能把联网等同于绝对安全。

辨析与自测 例如地图估计从学校到车站需要二十分钟，实质上可能使用历史交通规律与实时路况做旅行时间预测；路口根据排队长度调整绿灯，则涉及控制决策。自测：车辆识别准确率高，是否足以证明**自动驾驶**系统安全？不能，定位、预测、**规划**、执行以及异常情况下的处置都影响安全。基础复习应能把具体场景对应到感知、预测或决策环节，并识别数据质量和实时性的重要性。

本节来源：[53] [69]。完整书目信息与链接见书末。

8.3 智能医疗基础

8.3.1 智能医疗概念

考纲要求：知道

编者讲解 智能医疗是将人工智能用于医疗服务及相关健康活动，以帮助完成信息整理、**影像分析**、**风险评估**、**辅助决策**或研究等任务。它关注特定场景中的能力，例如在影像上标出疑似异常区域，而不是笼统地宣称机器“会看病”。输入可以是影像、检验数值、病历文本或时间序列，输出的含义必须随任务明确。

编者讲解 预测结果与临床诊断不同。模型学习的是给定数据中的统计关联，而诊疗还需要结合病史、检查、专业判断和患者具体情况。训练资料主要来自某一种设备或人群时，换到其他医院可能产生性能变化。医疗数据同时具有敏感性，收集目的、授权范围、访问权限和错误纠正都应进入系统设计。

辨析与自测 例如系统把一百份影像中的十份排到优先复核队列，其作用是辅助工作排序；它并不因此确认十人患病，也不保证其余九十人正常。自测：诊断模型准确率很高，是否可以省略对**漏诊率**的分析？不能，尤其在类别比例悬殊时，总体准确率可能掩盖关键错误。评价应围绕具体用途和**错误后果**展开，并由合适的专业人员复核。

本节来源：[70]。完整书目信息与链接见书末。

8.4 智能制造基础

8.4.1 智能制造概念

考纲要求：知道

编者讲解 **智能制造**把生产装备、过程数据、模型和管理活动连接起来，使生产系统能够更及时地感知状态、分析问题并辅助优化。它可覆盖产品设计、加工、**质量检测**、设备维护、排产和供应链。**自动化**强调按既定规则执行任务，智能化更强调利用数据和模型适应变化；工厂装有机器人不等于已经完成所有智能制造环节。

编者讲解 典型系统从传感器和生产记录取得数据，经过时间对齐与质量检查形成特征，再预测缺陷、设备故障风险或生产需求。模型输出还必须与生产约束结合，例如设备可用性、交货时间和安全限值。仅在离线数据上得到好成绩，却不能稳定连接实际工艺流程，难以产生可靠收益。

辨析与自测 例如振动信号变化可用于提示轴承异常，视觉模型可筛查外观缺陷，排产算法可减少设备闲置。自测：在机器停机以后才发出故障提示，属于有效的**预测性维护**吗？不一定。应区分**故障检测**与提前预测，并规定需要提前多久提示、误报导致多少检查成本。基础学习的重点是理解数据、设备与人的协同，不把智能制造缩成一种算法或一台机器。

本节来源：[71]。完整书目信息与链接见书末。

8.5 智能创意基础

8.5.1 智能创意概念

考纲要求：知道

编者讲解 **智能创意**是利用人工智能辅助构思、表达和制作内容的过程，内容可以是文字、图像、音乐、视频或设计方案。常见能力包括生成候选草稿、改变风格、补全局部内容和检索素材。人的**目标设定**、**审美判断**与编辑仍然决定作品的用途和质量。模型生成了新文件，并不保证其中每个元素都没有与已有作品相似的部分。

编者讲解 风格迁移是一个便于理解的例子：系统让输出图像保留一幅内容图的结构，同时接近另一幅图的纹理或色彩统计。它不是简单把两张图做透明度叠加，而是在特征表示中平衡不同目标。文本生成也需要约束受众、事实依据、长度和语气，否则语言流畅的草稿仍可能偏离实际需求。

辨析与自测 例如为校园节能活动制作海报，可以先列明主题和必须出现的信息，再生成若干构图，最后检查文字、事实、可读性和素材使用条件。自测：生成式系统能迅速给出十个方案，是否意味着无需筛选？不是。重复、错字、事实错误和不适合目标读者的表达仍需检查。评价创意应用应同时考虑**任务完成度**、审美与人的**可控**性，而不仅比较生成速度。

本节来源：[72] [74]。完整书目信息与链接见书末。

8.6 智能推荐基础

8.6.1 智能推荐概念

考纲要求：知道

> Recommender systems are therefore powerful information filtering tools that can facilitate personalized services and provide tailored experience to individual users.

原文选读 [73] 正文概述

编者讲解 **智能推荐**根据用户、物品及情境的信息，从候选集合中选择或**排序**可能有价值的**内容**，帮助用户减少查找成本。物品可以是电影、书籍、课程、商品或新闻。推荐通常在用户没有明确输入完整查询时主动提供候选，与围绕显式查询返回结果的搜索有所区别，但两种系统可以共享检索与排序技术。

编者讲解 内容推荐利用物品属性与用户兴趣的匹配，例如喜欢历史课程的人收到同主题课程；**协同过滤**利用群体交互规律，例如与某用户偏好相似的人还喜欢哪些课程。评分、收藏是显式或较强的偏好线索，点击、停留时间是间接行为信号。没有点击可能只是未被展示，不应直接解释成不喜欢。

辨析与自测 例如图书馆向新生推荐读物，系统可先根据入学兴趣提供候选，再根据借阅行为调整。自测：点击率最高的列表一定最好吗？不一定，标题可能吸引点击却不能满足需要；同类内容过多也会损害**多样性**。新用户或新物品缺少交互记录称为**冷启动**，常需要属性信息、合理的热门内容和适度探索。推荐质量应兼顾**相关性**、新颖性与长期体验。

本节来源：[73]。完整书目信息与链接见书末。

8.7 智慧教育基础

8.7.1 智慧教育概念

考纲要求：知道

编者讲解 智慧教育是在**教学目标**指导下，利用数据、人工智能和数字环境支持**教、学、评**与管理。应用包括学习资源推荐、自动反馈、作业辅助批改、**知识状态分析**和教学资源组织。其核心不是把所有课程交给机器，而是帮助教师和学习者看见问题、选择资源并得到及时反馈。

编者讲解 一个学习系统可以根据答题记录估计学生对某知识点的掌握情况，再推荐适当练习。这里的“掌握程度”是由模型和观测数据推断的状态，不等同于直接读取学生的真实理解；粗心、猜测、题目难度和先前知识都会影响结果。评价系统应检查学习效果，而不是只统计登录次数或屏幕使用时长。

辨析与自测 例如学生连续做错含负号的运算题，系统可提示重新检查符号规则，并安排一题能区分概念错误与粗心失误的练习。自测：生成式工具给出完整答案是否总能促进学习？不一定，缺少独立思考可能降低诊断价值。合理使用应突出**解释、提示和反思**，同时保护学习者数据，考虑不同设备和能力条件下的**可及性**，并让教师能够纠正错误建议。

本节来源：[74]。完整书目信息与链接见书末。

8.8 机器人基础

8.8.1 机器人概念

考纲要求：知道

编者讲解 机器人是通过**传感**、**计算**和**执行机构**与物理世界交互的系统。它可以是工业机械臂、移动平台或服务机器人，不必具有人的外形。典型组成包括机械本体、传感器、驱动器、控制器以及必要的能源和通信部分。纯软件聊天程序虽可能被称作“机器人”，但本单元主要关注能够产生物理动作的系统。

编者讲解 感知回答环境与自身处于什么状态，规划选择通向目标的行动，控制把期望运动转成电机或其他执行机构的指令。闭环控制还会用反馈修正误差。例如移动机器人绕开桌子，既需要知道桌子的位置，也要规划可行路线，并通过速度控制让实际运动接近路线。

辨析与自测 机械臂抓取积木时，要估计积木姿态、选择夹持位置、求出关节运动并检查碰撞。自测：机械臂能重复同一个动作，是否说明它能在任意环境自主抓取？不能。重复精度与环境理解是不同能力；光照变化、物体滑动、定位误差都会影响结果。基础学习应能描述“**感知—规划—控制—反馈**”的关系，并理解执行器的速度、力度和工作空间对行动存在真实约束。

本节来源：[75]。完整书目信息与链接见书末。

8.9 智能驱动科学研究基础

8.9.1 AI4Science 概念

考纲要求：知道

编者讲解 **AI4Science**指利用人工智能支持科学研究，包括从数据中发现规律、加速模拟、预测性质、提出候选以及辅助**实验设计**。科学任务与一般内容生成的关键区别在于，结论需要接受**可重复**的观测、实验或理论检验。**模型输出的是待验证的预测或候选，并不会因为使用了复杂网络就自动成为科学事实。**

编者讲解 蛋白质结构预测是典型例子：给定氨基酸序列及相关信息，模型预测空间结构，为后续研究提供线索。其他场景包括预测材料性质、建立物理过程的快速近似模型、选择更有价值的

下一次实验。数据、领域知识和评价方法必须共同设计；如果测试样本与训练样本过度相似，表面成绩可能高估发现新规律的能力。

辨析与自测 假设实验室有一千种候选材料而只能测十种，模型可以根据预测性能与不确定性帮助筛选，但最终还需实验测量。自测：预测某种材料性能优异，能否跳过制备和验证直接宣布发现？不能，还需考虑可制造性、实验条件以及模型适用范围。理解AI4Science应抓住“**预测、验证、反馈**”的循环，而不是将其简化为用聊天工具写一篇科学论文。

本节来源：[76]。完整书目信息与链接见书末。

综合模块

第9章 逻辑推理与知识图谱

9.1 逻辑推理

9.1.1 谓词逻辑表示法

考纲要求：掌握

编者讲解 **命题逻辑**把整句事实当成真或假的原子，**谓词逻辑**进一步描述对象的性质和对象之间的关系。例如“李明是学生”可写为Student(Li)，其中Li是指向特定个体的**常量**，Student是一元谓词；“李明选修人工智能课”可写为Takes(Li,AI)，Takes是二元谓词。变量x代表论域中的任意对象，函数符号如MotherOf(x)表示一个对象，谓词表达式则形成可判断真假的语句。

编者讲解 连接词包括否定¬、合取∧、析取∨、蕴含→和等价↔；量词∀表示对**论域**内所有对象成立，∃表示至少存在一个对象使条件成立。表示前必须说明论域和谓词含义，尤其不能混淆关系参数次序：Teaches(老师,课程)与Teaches(课程,老师)是不同表达。自然语言中的“所有学生”一般要用条件限制，而不能把论域中每个对象都直接断言为学生。

所有学生都是人：∀x(Student(x)→Person(x))。

存在学生选修AI：∃x(Student(x)∧Takes(x,AI))。

每位学生都选某门课：∀x(Student(x)→∃y(Course(y)∧Takes(x,y)))。

例题与解析 例题：设学生只有李、王，课程有AI、Math，已知Takes(李,AI)、Takes(王,Math)。命题“每位学生都选了一门课程”成立；命题“有一门课程被每位学生选修”则不由这些事实保证。前者是先任取学生再找一门课，课程可以随学生改变；后者把**存在量词**放外面，要求同一个课程适合所有学生。**量词顺序**改变的正是对象之间的依赖关系。

编者讲解 否定量词时要同时翻转量词与内部条件：¬∀xP(x)等价于∃x¬P(x)，¬∃xP(x)等价于∀x¬P(x)。因此“并非所有学生都通过”是“至少有学生没有通过”，不是“所有学生都没有通过”。**变量**被量词覆盖称为约束变量，否则为自由变量；写出含自由变量的公式时，它的真值仍依赖变量赋值，不能贸然当成已封闭的完整命题。

辨析与自测 自测：将“有的机器人不具备视觉传感器”形式化。答案：∃x(Robot(x)∧¬HasVision(x))。若误写为∃x(Robot(x)→¬HasVision(x))，可能只因论域中存在一个不是机器人的对象就成立，表达强度不足。再把“只有登记用户能借书”写成CanBorrow(x)→Registered(x)，而不是反过来；“只有”引出的是必要条件。

本节来源：[19] [20]。完整书目信息与链接见书末。

9.1.2 推理规则

考纲要求：掌握

编者讲解 推理规则规定在什么前提下可以得到什么结论。最常见的是**假言推理**：已知P与P→Q，就能推出Q；**合取消去**允许从P∧Q得到P；**全称实例化**允许从∀xP(x)得到具体对象a的P(a)。逻辑蕴含说的是在所有满足前提的解释中结论都成立，证明过程则是依据规则一步步构造结论。可靠的规则不会把真前提推出假结论，完备性还涉及是否能推出相应语言中所有被蕴含的结论。

假言推理：P，P→Q ⟹ Q。

全称实例化：∀xP(x) ⟹ P(a)。

归结的一种形式：P∨Q，¬P∨R ⟹ Q∨R。

编者讲解 谓词规则使用前常要做匹配或合一，寻找使表达式一致的变量替换。例如Student(x)与Student(Li)可通过x=Li匹配；Parent(x,y)与Parent(Li,Wang)可用{x=Li,y=Wang}匹配。替换必须在同一规则中一致，不能一处把x代成Li、另一处又代成Zhang。存在量词消去时引入的见证对象也必须按规则使用新符号，不能随意认定已经存在的某人就是该对象。

例题与解析 例题：事实Student(Li)、HasCard(Li)；规则R1为Student(x)→Person(x)，R2为Person(x)∧HasCard(x)→CanBorrow(x)。先由R1并令x=Li推出Person(Li)，再将它与HasCard(Li)合并，由R2推出CanBorrow(Li)。这是从事实出发的正向推理。如果问题是“Li能否借书”，先寻找结论为CanBorrow的R2，再把Person(Li)与HasCard(Li)列成子目标，是反向推理。两者方向不同，但都必须检查规则前提。

编者讲解 正向推理适合持续接收新事实并发现可得结论，反向推理适合针对特定目标寻找支持证据。多个规则同时可用时，系统可能根据优先级、特异性或其他策略选择执行顺序。知识库存在环时要避免重复推导导致无限循环；记录已推出事实是常见办法。现实规则若含默认、例外或不确定度，需要说明额外语义，不能直接套用所有经典逻辑等价变换。

辨析与自测 自测：已知“下雨→路湿”和“路湿”，能否推出下雨？不能，洒水也可使路湿，这是**肯定后件**的错误。在经典逻辑中，若已知路不湿，则由该严格蕴含可推出未下雨；但若原句只是“下雨通常使路湿”，就不是同一个严格逻辑规则。

本节来源：[19] [20]。完整书目信息与链接见书末。

9.1.3 确定性与不确定性推理

考纲要求：理解

编者讲解 **确定性推理**在事实和规则的真假已经明确、且规则按既定语义成立的条件下推出结论。例如“所有已缴费用户都可进入”与“某用户已缴费”可支持进入权限判断。这里的确定性是相对于知识库和模型假设，并不保证输入事实在现实中永不出错。传感器会有误差，知识也可能不完整，因此应用中还需要处理**不确定**信息。

编者讲解 不确定性推理对多个可能解释保留程度不同的支持，常见形式包括概率推理、模糊推理及带置信度规则。概率处理事件或命题的不确定程度，通过证据更新信念；模糊集合的隶属度处理“高温”“较近”等概念边界的渐变。温度属于“高温”的程度0.7，与“明天高温的概率0.7”含义不同，不能因为都位于0到1之间就直接互换。

贝叶斯公式：P(H|E)=P(E|H)P(H)/P(E)。二元假设时P(E)=P(E|H)P(H)+P(E|¬H)P(¬H)。

例题与解析 例：设备故障**先验**概率2%，故障时报警概率90%，未故障时误报概率5%。观察到报警后，故障**后验**为0.9×0.02/[0.9×0.02+0.05×0.98]≈26.9%。它没有达到90%，因为90%描述“故障条件下报警”，而现在问的是“报警条件下故障”；低故障基率和非零误报都会影响结论。该例数字是教学假设，不是某类设备实测指标。

辨析与自测 决策还需考虑后果。即使某解释概率不是最高，若忽略它的代价很大，也可能值得进一步检查。自测：知识库没有记录某学生会游泳，能否确定其不会游泳？在**开放世界**语义下不能，**未知不等于假**；只有明确采用**封闭世界**假设的特定系统，才会对未能推出的事实作相应否定处理。

本节来源：[19] [21]。完整书目信息与链接见书末。

9.2 专家系统与知识图谱

9.2.1 专家系统基本原理

考纲要求：理解

编者讲解 专家系统把特定领域的专家知识组织为可由计算机处理的形式，并利用**推理机**制对具体问题给出结论或建议。经典组成包括**知识库**、推理机、**工作记忆**或事实库、解释机制、人机接口以及知识获取与维护环节。知识库保存较稳定的领域规则，工作记忆保存当前案例事实；推理机选择适用规则并推进求解。把知识与推理程序分离，有助于更新规则而不重写整个执行过程。

编者讲解 规则型专家系统常采用“如果条件，则结论或行动”的产生式表示。正向推理从已有事实触发规则，反向推理从目标寻找必要前提；系统可以在缺少相关事实时向使用者提问。例如设备启动失败时，先询问电源灯状态，再根据回答检查供电或控制模块。提问应与当前诊断目标有关，避免让使用者一次填写大量无关信息。

编者讲解 例：规则R1为“电源灯灭且插座无电→检查外部供电”，R2为“电源灯亮且风扇不转→检查内部风扇或控制回路”。若当前事实只有“电源灯灭”，系统还不能直接套用R1；它需要进一步获取插座状态。**解释机制**应能够回答为何提出该问题、哪条规则支持建议、哪些事实尚未确认。这种可追溯推理链是专家系统的重要特征。

辨析与自测 局限包括**知识获取**困难、规则数量膨胀、相互冲突和跨领域迁移弱。专家经验可能含例外或不确定性，需要对应的表示方法与更新机制。系统没有自动学习能力并不妨碍它属于AI；同时，加入一个语言模型也不会自动保证知识正确。自测：知识库增加新规则就一定改善效果吗？不一定，要检查冲突、覆盖范围和原有案例回归测试。诊断建议也应区分已证实结论与待检查假设。

本节来源：[20] [22]。完整书目信息与链接见书末。

9.2.2 知识图谱基本原理

考纲要求：掌握

编者讲解 知识图谱以**实体**、**关系**和**属性**组织相互关联的知识。实体表示具体对象或概念，关系表示对象之间的联系，属性表示名称、数值、日期等信息。常见基本表达是三元组（主体、关系、客体），例如（李明、选修、人工智能）与（人工智能、授课教师、王老师）。把同一实体作为多条事实的共同节点，可以支持跨事实查询，而不只是在一张表中查找关键词。

编者讲解 在RDF中，主体和谓词按规范使用资源标识，客体可以是资源或字面量，空白节点用于表示未命名资源。现实工程也常采用属性图，节点和边可带属性。两者都是图表示方式，不能把知识图谱等同于某一种数据库产品。图谱不只是画出的网络图，还包括实体身份、关系语义、数据来源和更新管理；一条边是否可信，需要看其证据与生成方法。

编者讲解 构建通常经历模式设计、数据获取、信息抽取、实体对齐、知识融合、存储与质量检查。文本中“华师大”和完整校名可能指同一实体，而两个同名“王老师”可能是不同人。对齐错误会把本不相关事实连接起来，影响之后所有路径**查询**。关系方向也要保持一致，“课程由教师讲授”与“教师讲授课程”可以互相对应，却不是随意交换主客体就相同。

例题与解析 例题：已有（小林，选修，AI）、（AI，授课教师，陈老师）、（AI，所属学院，计算机学院）。问“小林所选课程的授课教师是谁？”沿“选修→授课教师”两跳可得陈老师。若另有规则Takes(s,c)∧TaughtBy(c,t)→LearnsFrom(s,t)，还能推出LearnsFrom(小林,陈老师)。这里路径查询找已有事实的连接，规则**推理**则依据明确规则产生新事实；不能看到任意两条边就凭直觉补全新关系。

> 三元组示例：(Xiaolin, takes, AI)、(AI, taughtBy, Chen)。查询模式：(Xiaolin, takes, ?course) 与 (?course, taughtBy, ?teacher)，共享变量?course完成连接。

编者讲解 知识图谱可用于语义检索、问答、推荐、关系分析与信息整合。质量指标包括实体一致性、事实准确性、覆盖率、时效性和来源可追溯性。若图谱由模型抽取，应保留原文证据和置信度，并区分经过确认的事实与模型提出的候选关系；图结构本身不会消除抽取错误。

辨析与自测 自测：图谱没有“小林选修数学”的边，能否断言小林未选数学？通常不能，可能只是数据不完整。图谱中路径越长是否代表关系越可靠？不一定，路径的语义、规则与证据决定可解释结论，边数只是结构属性。



图9-1 知识图谱中的一个事实三元组

本节来源：[20] [23] [24]。完整书目信息与链接见书末。

9.2.3 本体知识表示

考纲要求：掌握

编者讲解 **本体**为一个领域建立共享的概念、关系与**约束**，使不同数据和系统采用相容的语义。它通常包含**类、个体、属性及公理**。类表示一组对象，如学生、课程；个体表示具体对象，如小林、AI课程；对象属性连接两个个体，如选修；数据属性连接个体与字面量，如年龄。知识图谱侧重存放相互连接的事实，本体侧重说明这些事实所用词汇的含义和允许推导的关系，二者可以配合使用。

编者讲解 类之间可定义**子类**、等价类和互斥关系。Student是Person的子类意味着所有学生都是人；小林属于Student则进一步推出属于Person。它不意味着所有人都是学生，也不意味着Student这个类本身就是某个具体的人。属性可以规定定义域、值域、逆关系或传递性，但只有在领域含义适合时才应添加。例如“祖先”具有传递性，“朋友”通常不具有传递性，不能为了多推出关系而随意设定。

Student $\subseteq$ Person；Xiaolin $\in$ Student $\Longrightarrow$ Xiaolin $\in$ Person。

若partOf具有传递性：partOf(A,B)$\wedge$partOf(B,C) $\Longrightarrow$ partOf(A,C)。

类不相交：Student $\sqcap$ Course = 空集。

例题与解析 例题：定义GraduateStudent是Student的子类，Student是Person的子类；事实为小周属于GraduateStudent。推理可得小周属于Student与Person。又定义Person与Course互斥，若数据同时断言小周属于Course，则在这些公理共同作用下出现不一致，需要检查实体标识或类型数据。不能为消除冲突就任意删去一个事实而不追查来源。

编者讲解 OWL通常采用开放世界语义，缺少某条信息不等于该信息为假。还需注意定义域和值域常用于推导类型：若enrolledIn的定义域是Student，断言某人enrolledIn某课程后，推理器可能据此推出该人是Student，而不是像数据库表单那样首先拒绝输入。若目标是检查必填字段、限定列表等数据合规性，应采用明确的验证规则，不能把所有本体公理都理解为数据库约束。

辨析与自测 设计时先列出希望回答的能力问题，再确定最必要的概念和属性，例如“哪类人员可选哪些课程”“哪门课程有先修要求”。过度复杂的本体增加维护成本；缺少定义又会造成同词异义。自测：**实例关系**type与子类关系subClassOf可否互换？不可以，“小周是学生”是个体属于类，“研究生是学生的一类”是类包含关系。只知某课程有一位教师而不知道姓名，并不与开放世界下存在某教师的限制矛盾。

本节来源：[23] [24] [25]。完整书目信息与链接见书末。

综合模块

第10章 机器学习

10.1 机器学习补充方法

10.1.1 逻辑回归

考纲要求：掌握

编者讲解 逻辑回归是有监督的**概率分类**方法。以是否购买为例，输入是价格、浏览次数等特征，输出是属于购买类别的概率。它先计算线性得分 z，再用 **sigmoid** 函数压到0与1之间。这里“线性”指**对数几率**与输入特征呈线性关系，并不意味着概率随特征作直线变化。在不额外构造非线性特征时，二分类的决策边界是超平面；加入平方项、交互项后，在原特征空间中也能得到非线性边界。

z = w • x + b；p = 1/(1 + exp(−z))；log[p/(1−p)] = w • x+b。x为特征向量，w为权重，b为偏置，p为类别1的预测概率。

编者讲解 训练时，每条样本的真实标签 y 取0或1。二元**交叉熵**惩罚与真实标签不一致的概率：对正样本预测越接近0，损失越大。最小化所有训练样本的平均损失，相当于最大化观测标签的条件似然。**正则化**在损失中增加参数大小的惩罚，抑制用过大权重迎合少数训练样本。scikit-learn 的 LogisticRegression 默认含正则化，C越小通常表示惩罚越强；这与直接用 λ 表示惩罚强度的写法方向相反。

单样本损失 L = −y log p − (1−y)log(1−p)；对权重的梯度为 (p−y)x，对偏置的梯度为 p−y。

例题与解析 设一个特征 x=2，初始 w=0、b=0，标签 y=1，学习率0.1，暂不加正则化。初始 z=0、p=0.5，损失约0.693。梯度为 dw=(0.5−1)×2=−1，db=−0.5；更新得 w=0.1、b=0.05。重新前向计算 z=0.25，p约0.562，说明正确类别的概率上升。若决策**阈值**为0.5，p≥0.5判为类别1；将阈值提高到0.7，会减少判为正类的数量，通常牺牲召回率换取较少误报。

编者讲解 实际流程是先划分训练集和测试集，只在训练集上拟合标准化参数，再训练分类器。predict返回类别，predict_proba返回按classes_排列的各类概率；不能把它的任意一列未经核对就叫“正类概率”。下例展示训练接口，不把训练集上的正确率当作泛化能力。多分类可使用一对其余方式或多项逻辑回归，应按题目和环境设定理解。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
model = make_pipeline(StandardScaler(), LogisticRegression(max_iter=1000))
model.fit([[0.0], [1.0], [2.0], [3.0]], [0, 0, 1, 1])
prob = model.predict_proba([[1.5]])
label = model.predict([[1.5]])
```

辨析与自测 “逻辑回归用于预测连续房价”为什么不合适？本节方法拟合的是类别条件概率，不是连续金额本身。若考试问模型训练语句，第二个参数应为 y_train，而非 X_test；训练使用未来测试数据会破坏评估的独立性。输出0.8也不代表对某个样本有可验证的80%确定性，概率是否可靠还需校准与独立测试。

本节来源：[27]。完整书目信息与链接见书末。

10.1.2 决策树

考纲要求：掌握

> Decision Trees (DTs) are a non-parametric supervised learning method used for classification and regression.

原文选读 [28] 1.10 Decision Trees，首段

编者讲解 决策树把预测过程组织成连续判断。**根节点**包含全部训练样本，**内部节点**按某个特征条件划分，分支对应条件结果，**叶节点**给出预测。在分类任务中，叶节点常用多数类别或类别频率；在平方误差回归任务中，叶节点常用目标均值。每条从根到叶的路径都可以转成一条“若……且……则……”规则，多个预测同一类别的路径之间则是“或”的关系。

编者讲解 训练时需要比较候选划分。直观目标是让划分后的节点更加纯净，即同一节点内类别尽量一致。信息熵衡量不确定性，**信息增益**等于划分前熵减去子节点熵的加权平均；**基尼**不纯度也可用于比较。连续特征通常在相邻取值之间尝试阈值。贪心算法每一步选择当前较好的划分，不能保证得到所有可能树中的全局最优树。

> $H = -\Sigma\, p_k \log_2 p_k$；$Gini = 1 - \Sigma\, p_k^2$。p_k为节点内第k类比例；划分后不纯度必须按子节点样本占比加权。

例题与解析 某节点有8条样本，其中4正4负，基尼值为$1-0.5^2-0.5^2=0.5$。候选条件把它分为两个各4条的子节点，左侧3正1负、右侧1正3负；两侧基尼均为$1-(3/4)^2-(1/4)^2=0.375$，加权结果0.375，下降0.125。另一个划分得到4正0负与0正4负，下降0.5，因此若没有其他约束，第二个划分更好。若某路径依次要求“翅膀数=2”“无断翼”“存活”“翼面积体重比≥2.5”，则四条件以逻辑与连接；任一条件失败就走向其他叶节点。

编者讲解 树越深，越容易记住噪声、罕见样本和偶然组合。预**剪枝**在生长时限制max_depth、min_samples_leaf等；后剪枝先生成较复杂树，再依据误差与复杂度的权衡移除分支。应在验证

数据或交叉验证中选复杂度，最终测试集只用于独立评估。特征缩放一般不改变同一特征上样本的次序，因此树通常不像距离模型那样依赖标准化；但这不等于缺失值、类别编码、数据泄漏可以忽略，尤其不能套用新版本才支持的缺失值行为。

```
from sklearn.tree import DecisionTreeClassifier
X = [[0], [1], [2], [3], [4], [5]]
y = [0, 0, 0, 1, 1, 1]
model = DecisionTreeClassifier(max_depth=2, random_state=0)
model.fit(X, y)
print(model.predict([[1.5], [4.5]]))
```

辨析与自测 自测：分类树是否只能做二分类？否，叶节点可以包含多个类别的分布。是否每个特征只能使用一次？否，连续特征可以在不同深度再次设阈值。训练准确率100%是否证明规则可靠？否，它可能恰好反映**过拟合**；还需检查未参与建树的数据。

本节来源：[28]。完整书目信息与链接见书末。

10.1.3 支持向量机

考纲要求：掌握

编者讲解 **支持向量**机在分类时寻找能区分类别且间隔较大的决策边界。设标签为−1和+1，线性分类器用 w·x+b 的符号判断类别。与只要求“分对训练点”不同，**最大间隔**思想还要求边界尽量远离两侧最近的样本；这些约束边界位置的关键样本称为支持向量。非支持向量在一定范围内移动时，最优边界可能不变，这说明模型并非平均地依赖所有训练样本。

> 决策边界：$w \cdot x+b=0$；规范化约束：$y_i(w \cdot x_i+b)\geq 1$；两条间隔边界间的距离为$2/\|w\|$。硬间隔训练最小化 $\|w\|^2/2$。

编者讲解 现实数据往往不能完全线性分开。**软间隔**引入松弛量，允许样本进入间隔甚至被分错，同时在目标中处罚这些违例。常用形式为 $\|w\|^2/2+C\Sigma\xi_i$，其中$\xi_i\geq 0$。较大的C更重视惩罚训练违例，较小的C允许更多违例以换取较平滑边界，但泛化效果须验证。支持向量机的得分不是天然概率；需要概率时还涉及额外校准。

例题与解析 一维训练点中，−2和−1属负类，1和2属正类。边界x=0等距于最近两点−1、1。取w=1、b=0可使这两点满足y(wx+b)=1，所以它们是支持向量，间隔宽度为2。对新点x=0.4，得分0.4，判正类；x=−0.6则判负类。若把正类点移到−0.2，原硬间隔结论不再能直接使用，应重新判断可分性并考虑软间隔。注意把w、b同时乘2不改变边界，却改变函数得分，因此比较几何间隔必须除以||w||。

编者讲解 核方法通过**核函数**计算映射空间中的内积，使模型能在原空间形成非线性边界，不必显式展开高维特征。线性核适合近似线性问题；RBF核按样本距离衡量相似性，gamma较大时单个样本影响范围较窄，边界可能更曲折。C与gamma需联合验证，不能仅凭训练准确率决定。由

于距离和内积对尺度敏感，应在训练集上**标准化**，测试集复用同一变换。核SVM在样本数量很大时可能训练昂贵，不能从“适合高维”推出“适合任意数据规模”。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
model = make_pipeline(StandardScaler(), SVC(kernel='rbf', C=1.0, gamma='scale'))
model.fit([[-2.0], [-1.0], [1.0], [2.0]], [0, 0, 1, 1])
print(model.predict([[-0.6], [0.4]]))
```

辨析与自测 自测：删除离边界很远的点是否一定改变边界？不一定；但删除支持向量可能改变它。核函数是否就是增加神经网络层？不是，它表达特征空间内积。SVC中的C增大是否总提高测试成绩？否，减少训练违例可能同时加重过拟合。

本节来源：[29]。完整书目信息与链接见书末。

10.1.4 层次聚类

考纲要求：掌握

编者讲解 层次聚类用嵌套结构表示数据的群组关系。**凝聚式**方法从“每个样本一个簇”开始，每次合并最相近的两个簇；**分裂式**方法则从一个总簇逐步拆开。**树状图**记录合并过程，叶子是样本，节点的高度表示合并时的距离或所用准则值。选定切割高度或期望簇数后，才得到一组平坦的聚类结果，因此同一棵树可以支持不同粒度的观察。

编者讲解 样本之间的距离和簇之间的连接准则是两层不同选择。欧氏距离衡量两个点之间的直线距离；单连接取两簇中最近点对的距离，容易因“桥接点”出现链状簇；全连接取最远点对距离，更偏向紧凑簇；平均连接使用跨簇点对距离的平均值。**Ward**法选择使簇内平方误差增加最小的合并，在常用实现中须配合欧氏距离，不能把它直接解释为最短点对距离。

例题与解析 有一维样本A=0、B=1、C=4、D=6，采用欧氏距离和单连接。初始最小距离为AB=1，先得到{A,B}；此时该簇到C的距离=min(4,3)=3，到D的距离=min(6,5)=5，而CD=2，因此第二次合并{C,D}。最后两簇距离为min(4,6,3,5)=3。若保留两个簇，结果为{0,1}和{4,6}。换成全连接，最后距离=max(4,6,3,5)=6；层级的高度发生变化，说明“先计算距离”不能替代明确连接准则。

编者讲解 层次聚类属于无监督学习，簇编号只标记分组，不具有天然顺序或真实类别含义。收入、年龄等量纲悬殊时，应先根据业务选尺度处理，否则距离会被数值较大的特征主导。异常值可能单独成簇或影响合并；在高维空间中还需审视所选距离是否有意义。凝聚过程中，一旦合并通常不会自动回退，因此早期错误会沿树传播。它不要求一开始固定簇数，但计算树和距离矩阵仍会产生时间与内存成本。

```
from sklearn.cluster import AgglomerativeClustering
X = [[0.0], [1.0], [4.0], [6.0]]
model = AgglomerativeClustering(n_clusters=2, linkage='single')
labels = model.fit_predict(X)
print(labels)
```

编者讲解 以上代码避免依赖不同版本间发生变化的距离参数名称；默认欧氏距离足以完成该例。读输出时，重点是A与B编号相同、C与D编号相同而两组不同，不要要求第一簇一定编号0。模型的fit_predict对参与聚类的样本分组，不等同于已有监督分类器对任意新样本调用predict。

辨析与自测 自测：树状图相邻绘制的叶子是否必然是最近点？不一定，绘制时分支可左右交换。能否仅凭聚成两簇就断言数据有两种自然类别？不能；切割方式、特征、距离和领域依据都需要审查。

本节来源：[30]。完整书目信息与链接见书末。

10.1.5 集成模型（如 Boosting、随机森林）

考纲要求：掌握

编者讲解 **集成学习**将多个**基学习器**的输出组合，期望改善单一模型的**泛化能力**。有效组合需要个体既有一定预测能力，又不能总在相同样本上犯同样错误。分类可用多数投票或概率平均，回归常取平均或加权和。不能把“模型数量多”本身当作有效证据：若所有模型完全相同，复制一百份也不会增加信息；若弱模型的误差高度相关，平均收益也有限。

编者讲解 **随机森林**通过自助采样和特征随机性产生不同决策树。自助采样从原训练集有放回地抽取样本，同一条样本可能重复，另一些未被抽中；每个节点划分时仅考察随机选定的部分特征，从而减少树之间的相关性。不同树通常可并行训练。其主要收益之一是降低高方差决策树的波动；对明显欠拟合的基础设定，仅增加树数未必解决问题。scikit-learn 分类森林平均各树的类别概率，不能机械地把每棵树硬投票作为所有实现的唯一规则。

编者讲解 **Boosting**按顺序建立学习器，后续模型针对已有组合的不足继续学习。AdaBoost提高被误分类样本的相对权重，使下一轮更关注它们；梯度提升则拟合当前损失对预测的负梯度。在平方**误差**回归中，负梯度与残差对应，因而可以理解为不断补上尚未预测好的部分。学习率缩小每轮贡献，树数、树深和学习率需共同调节；顺序依赖意味着它不像独立树那样容易直接并行。

加法模型：$F_m(x)=F_{m-1}(x)+\eta h_m(x)$。$F_m$是第m轮组合预测，$h_m$是新增学习器，$\eta$为学习率。

例题与解析 某样本真实值为10，当前集成预测6，残差10−6=4。若新增回归树对该样本预测残差3，学习率$\eta=0.5$，则新预测为$6+0.5\times3=7.5$，残差降为2.5。另有三个分类器给正类概率0.8、0.6、0.1，等权平均为0.5，最终类别还取决于明确的阈值和边界处理规则；不可把0.8+0.6+0.1=1.5直接当作概率。若按硬投票，前两者投正、第三者投负，则正类以2比1获胜，说明两种组合机制并非数值上相同。

编者讲解 实际应用应比较单棵树与集成在相同数据划分上的成绩，并关注类别不平衡和概率校准。随机森林可利用未被某棵树抽中的袋外样本估计性能，但这不能消除其他环节的数据泄漏；Boosting可能对噪声标签和过深基学习器较敏感。特征重要性是预测关联的说明，不能自动证明因果影响。

```
from sklearn.ensemble import RandomForestClassifier, GradientBoostingClassifier
forest = RandomForestClassifier(n_estimators=100, max_depth=4, random_state=0)
boost = GradientBoostingClassifier(n_estimators=100, learning_rate=0.1, max_depth=2, random_sta
    te=0)
# 对已经正确划分的训练数据分别使用 forest.fit(X_train, y_train)
# 与 boost.fit(X_train, y_train)，再在同一验证集比较。
```

辨析与自测 自测：随机森林中的随机性是否意味着随机猜标签？不是，它随机抽样和选特征后仍学习预测规则。Boosting是否总优于随机森林？没有这种保证，应结合样本规模、噪声、调参和任务指标判断。

本节来源：[31]。完整书目信息与链接见书末。

10.1.6 LDA

考纲要求：理解

编者讲解 考纲只写缩写LDA，没有给出英文全称。本节按机器学习分类与降维语境中的**线性判别分析**（Linear Discriminant Analysis）讲授；它与主题模型**潜在狄利克雷分配**（Latent Dirichlet Allocation）不是同一算法。若课堂或指定教材明确采用后一含义，应另补主题模型内容，不能仅因缩写相同把两种机制混用。

编者讲解 线性判别分析利用类别标签寻找有利于区分类别的方向。直观要求是投影后不同类别的中心尽量分开，同一类别内部尽量紧凑。二分类中，**类间**散度描述两类均值的差别，**类内**散度汇总各类样本围绕自身均值的分散程度。它与PCA的关键差别在于：PCA追求总体方差较大，不看标签；LDA追求与类别区分相关的方向，使用标签，因此降维步骤本身也必须只在训练数据上拟合。

> Fisher准则 $J(w)=[w^{T}(\mu_1-\mu_0)]^2/(w^{T}S_Ww)$；S_W可逆时，最优方向与 $S_W^{-1}(\mu_1-\mu_0)$ 成比例。μ_k是第k类均值，S_W为类内散度矩阵。

例解 假设两个测量维度为长度和重量，两类均值分别为(0,0)与(2,0)，类内变化在重量方向很大。PCA可能先保留重量方向，因为总方差大；LDA更可能保留长度方向，因为两个类别在该方向分开，而重量变化不能有效区分类别。若两类各自沿长度方向也高度重叠，投影后的分类仍会有错误；选择判别方向不等于产生完美可分的数据。

编者讲解 从概率分类角度，经典LDA假设每一类的特征服从多元高斯分布，并共享同一**协方差**矩阵，类别均值可以不同。在比较各类的对数后验概率时，二次项抵消，因而得到线性决策面；若允许各类协方差不同，则对应二次判别分析QDA。先验类别概率也影响边界，不能把任何LDA

问题都简化为两类均值的中点。作为**监督**降维方法时，若有K类，判别子空间至多为K−1维，还受原特征维数限制。

辨析与自测 自测：三类、十个特征的数据，LDA降维最多得到几个有区分意义的**判别分量**？至多min(10,3−1)=2。样本少而特征多时，类内协方差估计可能不稳定或奇异，可采用适当求解方法或收缩估计；“标签已知”并不意味着可以把测试标签交给降维器。

本节来源：[32]。完整书目信息与链接见书末。

10.1.7 朴素贝叶斯

考纲要求：知道

编者讲解 朴素贝叶斯是基于**贝叶斯定理**的监督分类方法。它先估计各类别的**先验概率**，再估计“给定类别时观察到各特征”的概率，最后比较观察到新样本后各类别的**后验概率**。“朴素”指**给定类别后各特征条件独立**的简化假设，不是说特征在整个数据集中无条件独立。该假设使高维联合概率可以拆成多个容易估计的单特征概率。

> $P(y|x) \propto P(y)\prod_j P(x_j|y)$。分类时选使右侧最大的类别；因$P(x)$对所有类别相同，比较大小时可省略。

例解 例如先验上垃圾邮件占0.4、正常邮件占0.6；含“中奖”与“立即”两个词的条件概率，在垃圾类中分别为0.5和0.4，在正常类中分别为0.05和0.1。依**条件独立**假设，垃圾类得分为0.4×0.5×0.4=0.08，正常类为0.6×0.05×0.1=0.003，故判为垃圾邮件。需要归一化时，可算0.08/(0.08+0.003)约0.964，但这个数受模型假设和概率估计质量影响。

编者讲解 高斯朴素贝叶斯适合用高斯分布描述连续特征；多项式朴素贝叶斯常用于词频等非负计数；伯努利朴素贝叶斯适合词是否出现等二值特征。若某词在某类训练数据中从未出现，直接相乘会让该类得分变为零，常用拉普拉斯**平滑**缓解。实际计算常累加对数概率，避免许多小概率相乘导致数值下溢。

辨析与自测 自测：文本中两个近义词高度相关，模型是否无法运行？仍能运行，也可能有实用分类效果，但条件独立假设受违背，概率解释应更谨慎。该算法的训练和预测通常高效，适合作为**基线**，却不能由“名字中有贝叶斯”推出其自动具备因果推理能力。

本节来源：[33]。完整书目信息与链接见书末。

10.2 强化学习基本概念

10.2.1 强化学习定义及原理

考纲要求：掌握

A reinforcement learning (RL) agent acts in an environment, observing its state and receiving rewards.

原文选读 [34] 第13章首段

编者讲解 强化学习研究智能体在交互中学习如何行动，以提高**长期累计回报**。一个基本循环是：观察**状态**，按**策略**选择动作，环境发生转移，返回新状态与奖励，再据此改进策略。状态描述与后续决策相关的信息，动作是智能体可执行的选择，奖励是环境对一次转移的数值反馈，策略规定在某状态下如何选择动作。奖励通常并不直接告诉智能体“哪个动作才正确”，所以它与提供输入—正确标签对的监督学习不同。

编者讲解 马尔可夫决策过程常用来描述这类问题，包括状态集合、**动作**集合、状态转移规律、**奖励**规律及**折扣**因子。马尔可夫性质是：给定当前状态和动作后，预测下一步不再需要更早历史；若位置不足以描述任务，还可能要把速度、电量等纳入状态。环境规律已知时可以规划，未知时需要从经验学习；“强化学习”不等于每次都随机试，也不等于必须使用深度神经网络。

回报 $G_t=r_{t+1}+\gamma r_{t+2}+\gamma^2 r_{t+3}+\cdots$；$0\le\gamma\le1$。$\gamma$越小越重近期奖励，$\gamma$接近1时更重长期后果。无限期任务常取$\gamma<1$以控制回报规模。

例题与解析 机器人到终点有两条路径。路线甲第一步得2分并结束；路线乙第一步得0分，第二步到终点得5分。若$\gamma=0.9$，则甲回报2，乙回报$0+0.9\times5=4.5$，应选乙；若$\gamma=0.2$，则乙回报1，甲更好。该例说明奖励时机与折扣共同决定选择，不能只比较第一步即时奖励。若每多走一步有-0.1代价，应把每次实际获得的奖励按顺序计入，不能只扣一次总惩罚。

编者讲解 学习中存在**探索**与**利用**的矛盾。利用是按当前知识选择看起来最好的动作；探索是尝试不够了解的动作以获得信息。ε-贪心策略以大概率选择当前高价值动作，以小概率探索，其ε应根据任务与训练阶段设计。训练时允许适度探索，部署时仍须遵守安全约束；在真实设备上，不可把危险动作当作必须尝试的普通样本。奖励设计也很关键：如果只奖励“移动速度”，可能学会忽视碰撞，必须让目标和约束反映实际需要。

辨析与自测 对仓库机器人可这样建模：状态为位置、电量和是否载货，动作为可通行方向与充电，完成配送得正奖励、耗时与碰撞受惩罚，任务结束时停止累计该回合回报。评估应使用多个回合的总回报、成功率和安全指标，不能只报告某个动作的即时得分。自测：奖励越来越高是否一定代表用户目标被满足？不一定，智能体可能利用奖励设计漏洞，因此需要验证行为本身。

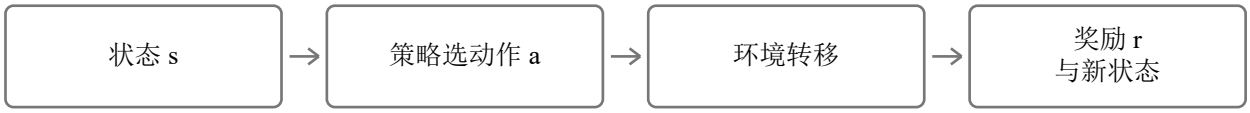


图10-1 智能体与环境交互的一步

本节来源：[34] [35]。完整书目信息与链接见书末。

10.2.2 价值函数与 Q 学习

考纲要求：理解

编者讲解 价值函数把一个状态或动作与未来的预期回报联系起来。**状态价值**Vπ(s)表示从状态s出发并始终按策略π行动时的**期望回报**；**动作价值**Qπ(s,a)表示在s先执行a，随后再按π行动时的期望回报。“价值”不是已经领取的奖励，而是对未来多步结果的预测。环境具有随机性时，必须使用期望概念；一次好运获得高回报，不足以证明该动作长期最好。

Vπ(s)=Eπ[G_t|s_t=s]；Qπ(s,a)=Eπ[G_t|s_t=s,a_t=a]。最优关系：V*(s)=max_a Q*(s,a)。

编者讲解 Q学习直接学习状态—动作价值，并用下一状态的最大估计值构造目标。一次交互获得(s,a,r,s′)后，把旧Q值向“即时奖励＋折扣后的未来最好价值”移动。目标与旧值的差叫**时序差分**误差。它能够在没有完整状态转移模型时更新，属于无模型方法；又因更新目标使用贪心动作，而采样行为可以带**探索**，属于**离策略**学习。

Q(s,a) ← Q(s,a)+α[r+γ max_a′ Q(s′,a′)−Q(s,a)]。α为学习率；若s′为真正终止状态，未来项取0。

例题与解析 设旧Q(s,a)=2，得到奖励r=1，下一状态两个动作的Q估计分别为3和4，γ=0.9，α=0.5。目标为1+0.9×4=4.6，时序差分误差为2.6，新Q=2+0.5×2.6=3.3。若这次转移已经结束任务，则目标只有1，新Q应为1.5；把**终止**状态仍接上价值估计会高估回报。这里取max用的是下一状态s′的动作价值，不是当前状态的最大值。

编者讲解 表格Q学习适合状态、动作数量有限且能够覆盖的情形。收敛到最优值需要足够探索、合适的学习率条件等假设，不能说“套公式就保证任何环境成功”。连续或极大的状态空间常用函数近似，但训练稳定性与理论条件会变化。与SARSA相比，Q学习目标使用下一状态的最大Q值，而SARSA使用实际选出的下一动作价值，因此对探索行为的处理不同。

辨析与自测 自测：Q学习训练时是否只能选最大Q的动作？否，可以探索；“离策略”正说明采样策略与目标策略可以不同。若奖励立刻为负，是否一定不应执行该动作？否，支付一步小代价可能到达长期价值更高的状态，应比较完整目标。

本节来源：[35]。完整书目信息与链接见书末。

综合模块

第11章 深度学习

11.1 神经网络补充概念

11.1.1 反向传播

考纲要求：掌握

反向传播（backward propagation或backpropagation）指的是计算神经网络参数梯度的方法。

原文选读 [16] 4.7.3 反向传播

编者讲解 **反向传播**解决“输出误差如何归因到各层参数”的计算问题。网络把输入经若干中间变量变成预测，再由损失函数比较预测与标签；每个参数都通过一条或多条路径影响损失。**链式法则**使我们能把沿途的**局部导数**相乘，同一变量通过多条路径影响损失时再把贡献相加。计算从最终损失往前传播，所以叫反向传播；它得到的是梯度，真正改变参数的是梯度下降等优化器。

若 $z=wx+b$，$h=\varphi(z)$，$\hat{y}=vh+c$，$L=(\hat{y}-y)^2/2$，则 $\partial L/\partial v=(\hat{y}-y)h$；$\partial L/\partial w=(\hat{y}-y)v\varphi'(z)x$；$\partial L/\partial b=(\hat{y}-y)v\varphi'(z)$。

编者讲解 前向阶段需要保存输入、激活值等中间结果，因为它们会在局部导数计算中再次使用。以上公式里，输出误差$\hat{y}-y$先乘输出权重v，再乘隐藏层激活函数导数$\varphi'(z)$，便得到隐藏节点对误差的敏感度；再乘输入x才得到w的**梯度**。多层网络只是把这一规则逐层重复。对矩阵和张量运算应同时核对形状，不能把标量公式中的乘法全部机械地当成逐元素乘法。

例题与解析 设x=2、y=1、w=1、b=0、v=3、c=0，隐藏激活为ReLU。前向得到z=2、h=2、$\hat{y}=6$，损失L=12.5。因为z>0，ReLU导数为1；于是$\partial L/\partial v=5\times2=10$，$\partial L/\partial w=5\times3\times1\times2=30$，$\partial L/\partial b=15$，$\partial L/\partial c=5$。若学习率0.01，所有参数使用同一次前向得到的旧梯度同步更新，得到v=2.9、w=0.7、b=−0.15、c=−0.05。不能先改v，再用新v重新代入本轮w的梯度，否则变成了另一种更新过程。

```
import tensorflow as tf
w = tf.Variable(1.0)
v = tf.Variable(3.0)
with tf.GradientTape() as tape:
    h = tf.nn.relu(w * 2.0)
    pred = v * h
    loss = 0.5 * (pred - 1.0) ** 2
dw, dv = tape.gradient(loss, [w, v])
# 本例只展示两个权重，理论梯度分别为30和10。
```

编者讲解 激活函数导数反复相乘可能使早期层的梯度极小或极大，分别称梯度消失和梯度爆炸；循环网络在时间维展开时也会出现这些问题。合适初始化、非饱和激活、残差连接、规范化和梯

度裁剪各有作用，不能混称为同一种方法。尤其梯度裁剪主要限制过大的梯度，并不直接恢复已经消失的梯度。

辨析与自测 自测：推理一个已训练网络是否每次都需要反向传播？通常不需要，前向计算即可给出预测。损失下降是否证明所有参数梯度都为负？不是，**参数更新**沿各自梯度的反方向，梯度正负取决于局部敏感度。框架的**自动微分**也不是数值试差，它按运算图应用导数规则。

本节来源：[16]。完整书目信息与链接见书末。

11.1.2 梯度下降法

考纲要求：掌握

学习率（learning rate）决定目标函数能否收敛到局部最小值，以及何时收敛到最小值。

原文选读 [36] 11.3.1.1 学习率

编者讲解 **梯度**是目标函数对各参数偏导数组成的向量，指向函数在局部上升最快的方向。梯度下降取反方向作小步移动，试图降低训练目标。**学习率**决定步长，但“沿**负梯度**”只是一种局部方向信息：步长过大会跨过有利区域，甚至使目标升高；太小则可能进展缓慢。对深度网络的非凸目标，不能保证从任何初始值都到达同一个全局最小值。

θ_(t+1)=θ_t−η∇J(θ_t)。θ为全部待训练参数，η为正学习率，J为目标函数。

编者讲解 批量梯度下降每次使用整个训练集计算梯度，方向相对稳定但一步计算较大；**随机梯度**下降每次使用一个样本，更新便宜但噪声明显；**小批量**梯度下降在两者之间折中，也能利用矩阵运算提高效率。一次epoch表示遍历一轮训练数据，一次step表示执行一次参数更新；若训练集1000条、batch size为100且不丢弃样本，一个epoch通常有10个step。改变批量大小时，不能把epoch数与更新次数混为一谈。

例题与解析 令$J(w)=(w-3)^2$，初始$w_0=0$。导数为$2(w-3)$。学习率$\eta=0.1$时，第一步$w_1=0-0.1\times(-6)=0.6$，第二步$w_2=0.6-0.1\times(-4.8)=1.08$，正逐步靠近3。写误差e_t=w_t−3，可得e_(t+1)=(1−2η)e_t；因此该特定二次函数在$0<\eta<1$时误差绝对值收缩。若$\eta=1.1$，则误差每步乘−1.2，来回跨越最优点且幅度增大。这个阈值只属于本例，不能套到所有损失函数。

编者讲解 不同特征量纲会让损失曲面在一些方向陡、另一些方向平，导致同一学习率难以兼顾，标准化可改善这类问题。**动量**法累积过去梯度方向，减弱来回震荡；Adam结合梯度的一阶、二阶矩估计，调整各参数更新尺度。学习率衰减使训练后期步子变小，但何时衰减应由训练目标与验证表现共同判断。优化器找低训练损失，正则化和数据设计则关系到泛化，两者职责不同。

```
w = 0.0
for step in range(5):
    grad = 2.0 * (w - 3.0)
    w = w - 0.1 * grad
    print(step + 1, w, (w - 3.0) ** 2)
```

辨析与自测 训练损失突然变成无穷或NaN时，应检查学习率、输入尺度、除零及指数运算等；训练损失下降而验证损失上升时，还要考虑过拟合，不能只继续降低学习率。自测：**梯度为零是否必然到达最小值？否，也可能是极大值、鞍点或平坦区域。**判断停止需结合梯度、损失变化、验证指标与预算。

本节来源：[16] [36]。完整书目信息与链接见书末。

11.2 神经网络原理与实践

11.2.1 CNN 特点及经典模型（LeNet、ResNet）

考纲要求：掌握

在残差块中，输入可通过跨层数据线路更快地向前传播。

原文选读 [38] 7.6.2 残差块

编者讲解 卷积神经网络保留图像的空间排列，通过**局部连接**处理邻近像素，同一卷积核在多个位置**共享权重**。一个核可以检测某类局部模式，不同**输出通道**学习不同模式；多层叠加使后层感受野扩大，组合出更复杂特征。共享权重显著减少参数，但不等于网络天然对所有旋转、尺度变化完全不变。卷积主要带来平移等变性，池化与数据增强等可增加一定容忍度；边界填充和下采样还会影响这一性质。

单个空间维的输出尺寸为 floor[(n+2p−k)/s]+1（膨胀率为1）。n为输入大小，p为两侧各自填充，k为核大小，s为步幅。含偏置的卷积参数数为(k_h×k_w×C_in+1)×C_out。

编者讲解 **LeNet**展示了“卷积提取局部特征—汇聚降采样—全连接分类”的经典结构。原始LeNet-5通常以32×32图像为输入，经过两组卷积与子采样，再进入后续分类部分；教材和实践常用简化变体。这里采用与D2L教学实现一致的28×28输入思路：6通道5×5卷积并保持尺寸，2×2平均**池化**；16通道5×5有效卷积，2×2平均池化；展平后接120、84和10个单元。要区分原模型与教学实现，不能把任意改用ReLU或最大池化的版本称为逐细节复现。

例题与解析 对上述教学网络，第一层输出28×28×6，池化后14×14×6；第二次卷积输出10×10×16，池化后5×5×16，展平为400维。第一层参数为(5×5×1+1)×6=156；第二层为(5×5×6+1)×16=2416。若误把输入高宽当作每个核的参数数，就会失去权重共享的意义。**残差**例：输入向量x=(1,2)，残差支路F(x)=(0.2,−0.5)，相加得到(1.2,1.5)，再按具体块定义应用激活。

编者讲解 **ResNet**的基本思想是让分支学习对输入的修正量F(x)，通过跨层连接形成F(x)+x，帮助深层网络优化。相加要求两支形状一致；若下采样或改变通道数，可用1×1卷积对捷径支路进行投影。它缓解随深度增加而训练困难的退化问题，不能把所有性能下降都解释成过拟合，也不能说残差连接让梯度问题彻底消失。LeNet强调简单层次特征提取，ResNet强调可训练的更深网络，两者都属于CNN结构。

```
import tensorflow as tf
model = tf.keras.Sequential([
    tf.keras.layers.Conv2D(6, 5, padding='same', activation='sigmoid', input_shape=(28, 28, 1))
    ,
    tf.keras.layers.AveragePooling2D(2),
    tf.keras.layers.Conv2D(16, 5, activation='sigmoid'),
    tf.keras.layers.AveragePooling2D(2),
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(120, activation='sigmoid'),
    tf.keras.layers.Dense(84, activation='sigmoid'),
    tf.keras.layers.Dense(10, activation='softmax')
])
```

辨析与自测 自测：输出通道增加是否一定让输出图像高宽增大？否，通道数与空间尺寸由不同参数决定。残差相加能否直接连接28×28×16和14×14×32？不能，先做相应尺寸与通道变换。分类的最终类别数应与输出单元数及损失函数的标签格式一致。

本节来源：[37] [38]。完整书目信息与链接见书末。

11.2.2 RNN 特点及经典模型等（LSTM，GRU）

考纲要求：掌握

重置门有助于捕获序列中的短期依赖关系；

原文选读 [41] 9.1.1 门控隐状态，小结

编者讲解 循环神经网络按顺序读取序列，在每个时间步用当前输入与上一时刻**隐状态**计算新状态。隐状态相当于压缩后的历史信息，使同一个输入在不同上下文下产生不同输出。权重在时间步之间**共享**，序列长度变化并不会要求每个位置重新学习一套参数。RNN可用于整段序列分类、逐步预测和序列到序列建模；输入通常含批量、时间、特征三个维度。

普通RNN：h_t=tanh(W_xx_t+W_hh_(t−1)+b)。x_t为当前输入，h_t为当前隐状态；同一W_x、W_h用于所有时间步。

例题与解析 设标量RNN的W_x=1、W_h=0.5、b=0、h_0=0，输入依次为1、0。第一步h_1=tanh(1)约0.762；第二步h_2=tanh(0.5×0.762)约0.363。尽管第二步输入为0，输出状态仍保留第一步影响。训练时沿时间展开运算图并反向传播，长链上的导数相乘可能消失或爆炸，所以普通RNN较难保持长距离依赖；截断反向传播减少计算，但也限制直接跨越的训练长度。

编者讲解 **LSTM**引入细胞状态c作为较稳定的信息通道。**遗忘门**f决定保留多少旧细胞状态，输入门i决定写入多少候选内容，输出门o决定把多少细胞信息暴露为隐状态。门通常经sigmoid落入0到1之间，逐元素调节信息，并非固定的开关。候选状态常用tanh。加法式更新减轻信息在长序列中的衰减，但性能仍受参数、数据和任务影响。

LSTM：c_t=f_t⊙c_(t−1)+i_t⊙ĉ_t；h_t=o_t⊙tanh(c_t)。⊙表示逐元素乘法。

例题与解析 若某一维旧c=0.8，遗忘门f=0.9，输入门i=0.2，候选ĉ=0.5，则新c=0.9×0.8+0.2×0.5=0.82。若输出门o=0.5，新h=0.5×tanh(0.82)约0.338。可见细胞状态保留了较大数值，而可见隐状态受输出门约束，两者不能混为一谈。

编者讲解 **GRU**以**更新门**与**重置门**控制隐状态，通常不单独维护LSTM式的细胞状态。按本节与D2L一致的约定，h_t=z_t⊙h_(t−1)+(1−z_t)⊙ĥ_t；z接近1时多保留旧状态，重置门控制旧状态参与候选状态计算的程度。某些资料把更新门写在候选项前，符号含义相反，应以公式为准。若旧h=0.6、候选ĥ=0.2、z=0.75，则新h=0.5。GRU参数通常更少，但不能据此断言在任何任务上都优于LSTM。

```
import tensorflow as tf
model = tf.keras.Sequential([
    tf.keras.layers.LSTM(16, input_shape=(20, 3)),
    tf.keras.layers.Dense(1)
])
# 每个样本有20个时间步，每步3个特征。
# 默认LSTM只输出最后时间步的16维表示。
```

辨析与自测 自测：return_sequences=True有什么意义？返回每个时间步的输出，方便堆叠循环层或逐时刻预测。**双向**RNN可同时利用前后文，但实时预测未来时不能悄悄使用尚未发生的数据。**时间序列评估还需按时间划分，随机打乱导致的未来信息泄漏不能靠更复杂网络弥补。**

本节来源：[39] [40] [41]。完整书目信息与链接见书末。

11.2.3 Transformer

考纲要求：理解

编者讲解 Transformer用注意力机制直接计算序列位置之间的关联，减少对按时间步串行传递隐状态的依赖。**自注意力**中，**查询Q**、**键K**、值V由同一序列的表示通过不同线性变换得到：查询表达当前需要寻找什么，键用于匹配，值承载被汇总的信息。匹配得分经缩放和softmax变成权重，再对值向量求加权和，使一个位置的表示可以依据整个允许访问的上下文更新。

Attention(Q,K,V)=softmax(QKᵀ/√d_k)V。d_k为键向量维度；softmax沿可关注的键位置归一化。

编者讲解 **多头**注意力把表示投影到不同子空间，分别计算关系再拼接；前馈网络对每个位置的表示作非线性变换；**残差**连接与层规范化支持稳定训练。没有**位置编码**或其他顺序机制时，单纯注意力无法充分表达位置顺序，因此输入还需加入绝对或相对位置信息。注意力权重是计算过程的一部分，不能直接当作严格的因果解释。

例解 若某查询对两个键的缩放后得分为0与log(3)，softmax权重就是1/4与3/4。若相应值为2与6，输出为0.25×2+0.75×6=5。假如第二个键对应未来词，生成任务使用**因果掩码**禁止当前位置访问它，则其权重为0，输出只依据第一个值。这说明掩码改变模型能够使用的信息，不能在训练时放开未来词而声称得到合格的下一词预测能力。

编者讲解 经典编码器—解码器Transformer中，编码器用自注意力理解输入，解码器用掩码自注意力处理已生成内容，再通过交叉注意力读取编码器输出。编码器型如BERT适于双向理解，解码器型可做**自回归**生成；并非所有Transformer都必须同时包含两部分。与RNN相比，训练时可更充分并行处理序列位置，并能直接建立长距离连接，但标准全注意力对长度n通常产生n×n的注意力矩阵，计算和内存成本会随长度增长。

辨析与自测 自测：训练可并行是否意味着自回归生成所有词也同时完成？不是，生成下一个词依赖先前已生成词，仍存在顺序依赖。是否只要叫Transformer就理解了事实？不是，架构提供表示与计算方式，知识可靠性还取决于训练、输入、评估与外部证据。

本节来源：[17] [48]。完整书目信息与链接见书末。

综合模块

第12章 人工智能前沿技术

12.1 数据增强技术

12.1.1 扩散模型基础

考纲要求：知道

编者讲解 扩散模型是一类**生成模型**。以图像为例，训练阶段先人为地向真实图像逐步加入**噪声**，形成不同噪声程度的样本，再训练神经网络学习相应的**去噪**规律。生成阶段从随机噪声出发，多次调用已学习的反向过程，逐步形成符合训练数据分布的图像。这里的“反向”是学习概率性的去噪转移，并不意味着能够从任意一份噪声中确定无误地找回唯一原图。

典型加噪形式：$x_t=\sqrt{\bar{\alpha}_t}\,x_0+\sqrt{(1-\bar{\alpha}_t)}\varepsilon$，其中$\varepsilon$为标准高斯噪声，$\bar{\alpha}_t$控制第$t$步保留的信号比例。

编者讲解 常见训练目标让网络根据带噪样本与时间步，预测所加入的噪声，再用预测误差更新参数。时间步是必要信息：轻微噪声与接近纯噪声时，需要的修复强度不同。有条件生成还可加入文字、类别或其他输入，引导生成内容。前向加噪主要负责构造学习任务，反向去噪模型承担生成能力，不能把随机加噪本身叫作已经训练好的生成器。

应用与边界 例如，为少量商品缺陷图像补充训练样本，可在已有合规图像上训练或适配生成模型，再筛选生成图；但须核实缺陷是否真实合理、标签是否正确，并用真实且独立的测试集检验分类效果。合成图像数量增加不保证信息增加，重复样式或不真实细节可能使下游模型学偏。

辨析与自测 自测：扩散模型与把图片加噪作为**数据增强**是否一样？不一样，普通增强只变换已有样本，扩散生成还学习从噪声得到新样本的概率过程。**多步采样**通常带来推理成本，生成质量、速度与多样性需要权衡；具体加速方法不改变本节需要掌握的基本机制。

本节来源：[42]。完整书目信息与链接见书末。

12.1.2 生成对抗网络（GAN）基础

考纲要求：知道

This framework corresponds to a minimax two-player game.

原文选读 [43] 摘要

编者讲解 GAN同时训练**生成器**G与**判别器**D。生成器把随机**潜变量**映射成合成样本，判别器根据真实与合成数据学习区分来源；生成器再利用判别器提供的梯度改进，使合成样本更难被区分。

两者的任务相互关联、训练交替进行，所以称对抗学习。判别器判断的是相对于训练分布的来源，不是承担道德意义上的真假鉴定。

经典目标：min_G max_D E_x[log D(x)]+E_z[log(1−D(G(z)))]。x是真实样本，z是随机潜变量；实际训练可使用更适合优化的生成器损失。

例解 例如生成器最初只输出模糊鞋子，判别器学会发现边缘与纹理差异；生成器逐步改进这些特征后，判别器又需要更新区分方式。训练到某一时刻判别准确率约50%，单看这一数值不能证明生成成功：也可能是判别器能力不足或训练失败，还应检查样本质量、多样性和任务指标。理论平衡条件不能直接当成有限网络训练必达的结果。

编者讲解 常见问题之一是**模式崩溃**：生成器只输出少数看似逼真的样式，未覆盖真实数据的多样性；另一个问题是两模型训练失衡、**梯度**不稳定。用于数据增强时，应检查少数类别是否得到真实补充，避免只复制训练样本特征。条件GAN可把类别或图像作为条件，支持按类别生成和图像转换。

辨析与自测 自测：生成新图时一定要运行判别器吗？经典GAN通常只需生成器。GAN与扩散模型是否都是反复去噪？不是，GAN核心是对抗目标，扩散核心是逐步加噪及学习反向过程，两者属于不同生成机制。

本节来源：[43]。完整书目信息与链接见书末。

12.2 多模态技术

12.2.1 多模态基础（感知、数据）

考纲要求：知道

编者讲解 **模态**是信息被感知或表示的方式，例如文字、图像、语音、视频、深度和触觉。**多模态**人工智能在同一任务中利用两种或更多模态，以补充单一感知渠道缺失的信息。视听语音识别可结合声音和嘴唇运动，图文检索把一句描述与相应图片关联起来。多模态不等于简单地把多个文件放在一起，关键在于建立它们之间可用于任务的联系。

编者讲解 多模态数据首先涉及配对和**对齐**。图片与标题可能描述同一个对象，但细节不完全一致；视频画面与声音还需时间同步。每种模态通常先由适合的编码器转为向量，再通过拼接、交叉注意力或共享表示空间**融合**。CLIP以图文配对为监督，通过对比学习提高匹配图文的相似度、降低不匹配组合的相似度，是跨模态对齐的典型例子；它本身不等同于能生成所有模态的大模型。

应用与边界 例如一个安全巡检系统同时得到“异常摩擦声”和设备图像。声音提示可能发生接触故障，图像帮助定位区域；若摄像头被遮挡，系统仍应标记图像缺失并合理使用声音，而不是把缺失值当正常画面。相反，若音画时间错位，把旧图像与新声音拼接可能产生错误结论，因此数据质量必须在融合前检查。

辨析与自测 自测：多模态一定比单模态更准确吗？不一定，额外模态可能嘈杂、缺失或含有与目标无关的捷径。训练和评估应考虑单**模态缺失**、模态冲突、时间错位和不同群体的数据覆盖情况，同时保护音视频中可能包含的个人信息。

本节来源：[17] [44]。完整书目信息与链接见书末。

12.3 分布式机器学习与联邦学习

12.3.1 分布式机器学习基础

考纲要求：知道

每个GPU根据分配给它的小批量子集，计算模型参数的损失和梯度；

原文选读 [45] 12.5.2 数据并行性

编者讲解 分布式机器学习把训练或推理任务分配到多个计算设备，目的可能是缩短时间，也可能是容纳单设备放不下的模型或数据。**数据并行**在多个设备上保存相同模型，各自处理不同样本，再聚合梯度或参数；**模型并行**把模型的不同部分放在不同设备，前后部分需要传递中间结果。**流水线并行**把阶段划分与小批量调度结合，是模型并行的一种组织方式。

编者讲解 **同步**数据并行中，各设备以同一版参数计算本轮梯度，聚合后再更新；**异步**训练允许设备更独立地提交更新，但可能使用较旧参数计算的梯度。**通信**会带来成本，同步还可能受最慢设备拖延。设备增加不保证速度成比例提高：小任务可能主要耗在通信和等待上，显存、网络、数据加载也会成为瓶颈。

例解 两设备分别处理2条和6条样本，得到各自的平均梯度$g_1=1$和$g_2=3$。若希望等价于8条样本总体平均，聚合应为$(2\times1+6\times3)/8=2.5$，直接把两设备平均成2会改变样本权重。若两边样本数相等，普通平均才与总体平均一致。这个例子说明聚合算法必须考虑本地统计量的定义。

辨析与自测 自测：增加数据并行设备是否一定能训练更大的单个模型？通常每台仍需放下一份模型，单纯复制并不能解决模型本身的容量限制。分布式训练也不自动等于联邦学习：前者重点是**计算协作**，后者还特别关注分散数据的本地保留、跨主体约束和参与设备差异。

本节来源：[45]。完整书目信息与链接见书末。

12.3.2 联邦学习基础

考纲要求：知道

编者讲解 **联邦学习**让多个参与方协同训练模型，同时让原始训练数据主要保留在各自**本地**。常见流程是服务器下发当前模型，参与方用本地数据训练若干步，再上传**模型更新**，由服务器聚合后进入下一轮。它可用于手机终端或多个机构协作；“数据不集中”是组织方式的重要特点，但不表示所有中间信息都没有隐私风险。

例解 FedAvg是典型方法：各客户端从共同模型开始，在本地执行若干步优化，再按其样本量等权重平均模型参数。假设甲有100条样本、本地某参数为2，乙有300条样本、对应参数为4；本轮简单按样本量**聚合**得(100×2+300×4)/400=3.5。该计算只说明参数平均，不证明在非凸模型上其效果等价于把全部样本集中训练。

编者讲解 联邦环境常有**非独立同分布**数据：不同医院的病人构成或不同手机的文字习惯不一样；参与方还可能网络不稳定、性能不同、临时掉线。本地训练过多会加大各模型差异，通信过频又会增加成本，需要在收敛、通信和参与公平性之间权衡。横向联邦通常指样本不同而特征空间相近，纵向联邦通常指部分实体重合但特征分散。

辨析与自测 **梯度和参数更新仍可能泄露训练信息，恶意参与者也可能提交有害更新。安全聚合**限制服务器看到单个客户端更新，**差分隐私**通过适当随机化限制个体影响，访问控制与审计则约束参与和使用；这些措施有不同假设与代价，不能用“联邦”一词代替具体保护证明。自测：既然不上传原图，是否就绝对不会泄密？答案是否，应检查整个协议与攻击面。

本节来源：[46] [50]。完整书目信息与链接见书末。

12.4 生成式大模型技术

12.4.1 基本三要素（数据、算法、算力）

考纲要求：知道

编者讲解 生成式大模型的发展依赖**数据、算法、算力**相互配合。数据决定模型能够观察到什么：不仅包括数量，还包括**内容质量**、语言和领域覆盖、去重、标注或配对质量以及使用权限。大量重复、错误或偏斜数据可能浪费计算并强化偏差；测试题出现在训练数据中还会让评估看起来过高，因此需要控制**污染**。

编者讲解 算法包括模型结构、训练目标、优化方法以及训练组织方式。比如自回归语言模型通过预测后续词元学习序列分布，架构和优化器影响其表示能力与学习效率。算力不仅是芯片数量，也包括实际运算吞吐、显存容量、设备间通信、存储和软件效率；理论峰值高不代表整个训练过程能维持同样速度。

编者讲解 三者存在配比问题。固定计算预算下，把**参数**规模翻倍而显著缩短训练，未必胜过较小但训练充分的模型。关于计算最优训练的研究说明，应把模型大小和训练数据量共同安排；其经验规律来自特定模型与实验范围，不能当作任何领域永不变化的定律。做方案题时应先确定任务与评价标准，再判断瓶颈究竟在数据、方法还是资源。

辨析与自测 例如校内课程问答系统只有少量经过审核的文档，却有一台可用设备。直接从头训练超大模型往往不是合理默认方案；可利用合适的已有模型，加检索和有针对性的适配，并用课程题集评估。此例强调**资源与目标匹配**，不要求背诵某种模型参数量。自测：算力增加能否自动纠正错误标签？不能，更多计算也可能把错误学得更牢。

本节来源：[45] [47]。完整书目信息与链接见书末。

12.4.2 预训练概念

考纲要求：知道

编者讲解 **预训练**是在正式目标任务之前，先利用较大规模或较广范围数据学习通用表示与参数。语言模型常从文本内部构造训练目标，不必逐句人工标注：**自回归**目标预测下一个词元，**掩码语言模型**根据上下文预测被遮盖的词元。这类自监督信号来自数据本身，“没有人工任务标签”并不意味着训练没有目标或损失。

编者讲解 预训练得到的参数可作为后续任务的起点。**微调**是在目标任务数据上继续更新部分或全部参数；冻结编码器则保持主体参数不变，只训练附加预测层。提示词使用和上下文示例可以在不更新参数的情况下影响模型输出，因此与微调不同。若在专业领域语料上继续预训练，再用任务标注微调，是两个目标不同的阶段。

例解 例如原文本为“机器学习需要数据”，掩码任务可遮住“数据”，根据上下文训练恢复；自回归任务则在看到前面词元时预测接下来的词元。词元可能是字、子词或其他分词单位，不保证等于自然语言的完整词。BERT是双向编码器预训练的代表，而生成式自回归模型采用的上下文可见范围不同，不能把两者训练目标互换。

辨析与自测 预训练知识不等于可查询、永久正确的事实数据库：内容可能过时、记忆不完整或受语料偏差影响。迁移效果还取决于源数据与目标任务的相关性，目标数据少时也可能过拟合。自测：把用户资料粘进提示词后，模型是否已完成一次微调？通常没有，除非另行执行了**参数更新；上下文使用与权重学习应明确区分。**

本节来源：[47] [48]。完整书目信息与链接见书末。

12.4.3 检索增强生成（RAG）概念

考纲要求：知道

> models which combine pre-trained parametric and non-parametric memory for language generation.

原文选读 [49] 摘要，RAG定义片段

编者讲解 **检索增强生成**把外部资料检索与语言生成结合。**参数化记忆**指存放在模型权重中的知识，**非参数化记忆**可以是可更新的文档库及索引。用户提出问题后，系统先找相关资料，把它们

作为上下文交给生成模型，再形成答案及来源提示。其优势之一是资料库可以独立更新，不必为了每一条新事实重新训练整个生成模型。

编者讲解 常见工程流程包括文档清洗与分块、建立关键词或向量索引、查询**检索**、候选重排、**上下文**拼接和答案生成。向量检索利用语义相似性寻找候选，关键词检索则对精确名称、编号等可能更有帮助，两者可以组合。分块太短会缺上下文，太长则可能稀释相关信息；检索到的段落数量也受上下文长度和噪声影响。

例解 例如问“本学期实验报告何时提交”，系统应检索本学期对应课程的通知，检查发布时间和适用班级，再依据正文回答。如果只检索到上一学期通知，即使生成语言流畅、附了链接，仍可能错误。检索召回率、重排质量、回答是否忠实于证据和证据是否支持结论应分别评估；不能仅凭有引用标记就认定答案可靠。

辨析与自测 自测：RAG是否保证模型不再编造？不能，检索可能漏掉关键资料，生成也可能错误组合证据。**权限过滤**应在检索阶段执行，文档中的命令性文字应当作资料而非系统指令；缺少足够证据时应明确不足。**RAG提供外部事实，微调改变模型参数与行为，两者可以互补而非互相替代。**

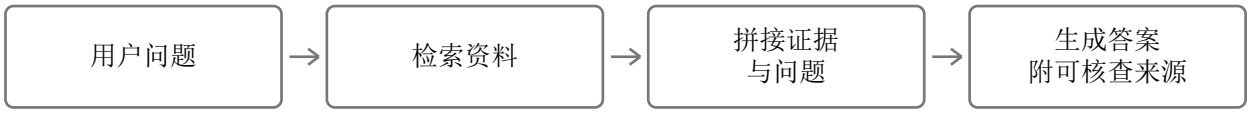


图12-1 检索增强生成的基本过程

本节来源：[49] [50]。完整书目信息与链接见书末。

综合模块

第13章 人工智能安全与伦理

13.1 可信人工智能

13.1.1 可信人工智能的可解释性、安全性、公正性、隐私性

考纲要求：理解

编者讲解 可信人工智能要求系统在具体使用情境中能够被合理依赖，而不是只在一个平均准确率数字上表现良好。**可解释性**关注人能否理解模型如何产生结果及其依据；**安全性**涉及正常使用、失误和攻击下的伤害控制；**公正性**关注不同人群是否受到不合理差别影响；隐私性关注个人信息的采集、使用、披露和推断是否受到保护。这些要求贯穿设计、数据、训练、部署和后续监测。

编者讲解 可解释模型如较小决策树能够直接呈现规则；事后解释方法则在模型训练后描述局部特征影响。解释应面向使用者的知识水平，并检查是否忠实反映模型，而不是只提供听起来合理的理由。安全性还要区分意外造成伤害的安全问题与恶意攻击造成的安全问题：输入扰动、数据投毒、系统越权和分布变化都可能让正常测试成绩不足以代表实际风险。

案例分析 公正性不能只看总体准确率。假设A组100人中90人判断正确，B组20人中只有10人正确，总体正确率为100/120约83.3%，却掩盖B组仅50%的问题。还应按任务比较误报率、漏报率、受益机会等，并考虑样本量和不确定性。不同公平指标可能不能同时达到，需结合应用目标及受影响者说明采用何种标准，不能用删除敏感属性一招保证公平，因为其他变量可能成为代理。

编者讲解 隐私保护应从最少必要数据、明确使用目的、权限控制和保留期限开始，再考虑去标识化、安全聚合或差分隐私等技术。去掉姓名并不保证匿名，多个普通字段组合仍可能重识别个人；只保存模型也不代表绝不泄露训练信息。具体机制要结合威胁模型评估，例如攻击者能看到哪些数据、可查询多少次以及是否能读取参数。

辨析与自测 可信特征之间存在**权衡**：公开过多训练细节可能帮助解释，却泄露私人信息；强化隐私随机化可能降低小群体的预测精度。应记录设计选择，进行**分组**与**压力测试**，设置人工复核和申诉入口，并持续监测上线后的变化。自测：高准确率能否推出安全、公正、可解释、隐私保护都合格？不能，这些是需要分别验证且共同治理的性质。

本节来源：[50] [51]。完整书目信息与链接见书末。

13.2 人工智能伦理

13.2.1 人工智能的伦理和安全挑战

考纲要求：理解

At its core, it states that AI must respect human rights and human dignity.

原文选读 [51] Recommendation on the Ethics of Artificial Intelligence，导言

编者讲解 人工智能伦理讨论技术应当服务哪些目标、如何分配收益与风险以及谁应承担**责任**。安全挑战包括误判与系统故障导致的实际损害，也包括滥用、欺骗和操纵；伦理问题还涉及**尊严**、**自主权**、歧视、劳动影响和环境负担。因此“技术上能做”不等于“在任何场景都应做”，系统的用途、对象和后果需要与性能一起评价。

编者讲解 数据偏差可能把历史上的不平等待遇带入模型，自动决策又可能扩大其覆盖范围。生成内容容易被误当成真实记录，引发虚假信息、冒名和误导；训练材料与输出还涉及著作权和署名等问题。具体法律结论因司法辖区和事实而异，本节讲伦理分析框架，不把某种技术一概认定合法或违法。大规模训练与部署也消耗能源、水及硬件资源，评价收益时应考虑资源效率。

案例分析 以学校用模型筛选奖学金申请为例，不能只问“排名准不准”。还应检查经济困难学生的资料是否被充分覆盖、历史获奖标签是否存在偏差、学生能否知晓自动系统参与、错误是否有复核和申诉渠道，以及最终决定由谁负责。若模型把缺少某类证明材料直接当作低潜力，可能把信息缺失转化为不公正结论，应先审查数据采集与规则设计。

编者讲解 责任安排需要明确开发者、部署机构与使用者各自职责。人工监督应是真实可行的复核能力：审核人需要足够时间、信息和推翻建议的权限，而不是被迫形式化点击确认。重要决策应留下可追溯记录，出现事件时能够定位模型版本、数据来源和操作流程。技术保障可包括访问限制、风险测试、内容来源标识与异常监测，组织保障还包括培训、申诉和定期独立审查。

辨析与自测 安全评估应区分**发生概率和损害严重性**，先识别受影响群体，再考虑预防、发现、**响应与恢复**。即使风险概率较低，后果严重的用途仍需要更强验证；场景变化后应重新检查原来的假设。自测：让系统声明“结果仅供参考”是否足以免除管理责任？不能，说明文字不能替代合理的**数据治理**、验证、监督和纠错安排。伦理要求最终应落实到可检查的实际措施。

本节来源：[50] [51]。完整书目信息与链接见书末。

综合模块

第14章 计算机视觉

14.1 计算机视觉基础

14.1.1 特征表示与滤波

考纲要求：理解

编者讲解 数字图像可表示为规则网格上的数值。灰度图常用高×宽的数组，彩色图增加颜色通道；把一张图直接摊平能得到像素向量，却会弱化相邻位置的结构。**特征表示**把任务相关信息整理成便于比较的形式，例如颜色直方图反映颜色分布，局部梯度反映亮度变化，**卷积**网络逐层学习纹理和形状组合。好的特征应保留判别信息，同时尽可能减少与任务无关的变化。

编者讲解 **滤波**用像素邻域计算新的像素值。线性平滑滤波对邻域加权求和，**归一化均值**滤波的权重相同，高斯滤波更重视中心附近。它们可以抑制某些高频噪声，也会模糊细节。中值滤波将邻域排序后取中间值，是非线性滤波，对孤立脉冲噪声往往更有效。保边滤波还会考虑像素值差异，避免把强边界两侧不加区别地混合。

例题与解析 设一个3×3灰度邻域八个像素为10，一个像素为250。均值为(8×10+250)/9≈36.67，**中值**为10。若250是噪声，中值更接近背景；若250是真实的小亮点，去掉它反而损失信息。这说明滤波没有脱离任务的绝对最优选择。核的尺寸越大，一般平滑范围越大；**边界**处还需明确补零、复制或反射等处理方式。

辨析与自测 自测：把颜色直方图相同的两张图片判成同一对象是否可靠？不可靠，直方图通常不充分保留空间排列。编程时还要注意无符号整数减法可能溢出，应先转换为合适数值类型；归一化尺度必须一致。读懂滤波题应依次辨认邻域、权重、边界与输出，而不是只记函数名称。

本节来源：[53] [54]。完整书目信息与链接见书末。

14.1.2 边缘检测与局部特征描述符

考纲要求：理解

编者讲解 边缘是图像亮度或其他性质发生显著变化的位置，可能来自物体边界、纹理或照明变化。**梯度**描述数值变化的方向与强度，常分别估计横向和纵向变化，再合成梯度幅值。**边缘检测**得到的是稀疏的轮廓线索，不会直接知道轮廓属于什么物体；阴影边缘也可能被检测出来，因此不能把边缘等同于语义边界。

编者讲解 Canny方法的基本思路是先平滑抑制噪声，再计算梯度，通过非极大值抑制把边缘变细，最后采用高低双阈值连接可信边缘。高阈值确定强边缘，低阈值提供可能与强边缘相连的弱边缘；

孤立弱响应可被排除。平滑过强会消除小结构，阈值过低会保留很多噪声，两者需要随图像条件调整。

编者讲解 **局部特征**方法先在图像中选取具有重复定位能力的**关键点**，再用**描述符**概括附近的结构，以便跨图像匹配。SIFT通过尺度空间寻找关键点、估计主方向，再统计局部梯度方向，增强对尺度与旋转变化的适应能力。描述符不是关键点坐标：坐标回答在哪里，描述符用于比较附近长什么样。匹配后仍常需要几何一致性检验来剔除误配。

辨析与自测 例如同一张海报在两幅照片中大小不同且发生旋转，直接比较相同坐标的像素会失败；先找关键点，再比较经过尺度与方向处理的描述符更合理。自测：相似描述符一定来自同一物体吗？不是，重复窗格、纹理和噪声均可能造成歧义。理解题应能说明**检测、描述、匹配、验证**四步的不同作用，并知道所谓**不变性**只在一定范围内有效。

本节来源：[55] [56]。完整书目信息与链接见书末。

14.2 计算机视觉方法与应用

14.2.1 图像分割与分类

考纲要求：掌握

实例分割不仅需要区分语义，还要区分不同的目标实例。

原文选读 [52] 13.9.1 图像分割和实例分割

编者讲解 **分类**学习图像到类别的映射，**分割**学习图像到空间标签的映射。在二分类任务中，模型可输出一个前景概率；多分类常输出各类别分数并选择最大者。**语义分割**将类似的分类决策施加到每个像素，但预测需要结合邻域和较大范围的上下文，不能把每个像素独立视作互不相关的样本。实例分割则还要区分同类目标的个体。

编者讲解 建立完整实验时，应先确定对象和标注粒度，再按拍摄对象、患者或场景划分训练与测试数据，防止同一对象的近重复照片同时出现在两边。对分割做裁剪、翻转等几何增广时，原图与标签必须同步变化；标签是类别编号，缩放时不能随意采用会混出新编号的插值。训练常使用逐像素交叉熵，也可结合重叠度损失；推断时输出标签图，再按任务处理小区域等。

编者讲解 分类可用混淆矩阵分析各类的正确与错误；分割除了像素准确率，还常计算前景的交并比**IoU**和**Dice**系数。背景占绝大多数时，即使完全漏掉前景，像素准确率也可能很高。因此评价应报告相关类别的重叠度，并说明是否平均、怎样处理没有出现的类别。图像的漂亮程度不能替代预测与标注的逐项比较。

例题与解析 独立例题：一幅4×4图有6个真实前景像素，预测前景有8个，其中5个正确。则真阳性TP=5、假阳性FP=3、假阴性FN=1、真阴性TN=7。前景IoU=5/(5+3+1)=5/9≈0.556；Dice=2×5/(2×5+3+1)=10/14≈0.714；像素准确率=(5+7)/16=0.75。三者不同是因为关注的错误与分母不同。

辨析与自测 若题目只要求按灰度**阈值**分割，可令像素大于阈值时为1，否则为0，并计算上述指标；这只是规则方法，不需要假装已经训练神经网络。自测：将阈值降低，预测前景通常增多，能否断言IoU必然增加？不能，新增区域可能是真前景，也可能是假阳性。应通过**验证集**选择阈值，最终测试集仅用于评价，不能反复调整到测试分数最好。

IoU = TP / (TP + FP + FN)；Dice = 2TP / (2TP + FP + FN)。TP、FP、FN分别表示正确前景、误报前景、漏报前景的像素数。

本节来源：[52] [54]。完整书目信息与链接见书末。

14.2.2 目标检测与识别

考纲要求：掌握

编者讲解 目标检测的训练数据包含图像及每个目标的类别和位置。模型通常同时优化**类别判断**与**位置回归**：前者使目标类别正确，后者使预测框接近真实框。**两阶段**方法先提出候选区域再细分和回归，一阶段方法在特征图上直接预测候选目标；不同方法在速度、精度、小目标处理和部署成本上有不同取舍，不能单靠网络名称判断适用性。

编者讲解 边界框可以表示为(x1,y1,x2,y2)，也可以表示为中心(cx,cy)及宽高(w,h)。在连续坐标约定下，w=x2-x1、h=y2-y1，cx=(x1+x2)/2、cy=(y1+y2)/2。使用像素索引的某些实现可能采用不同端点约定，因此面积计算必须全程一致。对图像缩放或裁剪后，标注坐标也要相应变换。

编者讲解 预测阶段往往会得到多个框。先按置信分数筛选，再进行**非极大值抑制NMS**：保留分数最高的框，对与它高度重叠的同类候选作抑制，再继续处理剩余框。重叠度通常采用交并比。NMS抑制重复预测，不会证明被保留框一定正确；如果相邻目标本来就拥挤，过强抑制也可能误删真实目标。

例题与解析 独立例题：A=(0,0,4,4)，分数0.9；B=(1,0,5,4)，分数0.8；C=(10,0,14,4)，分数0.7，三者类别相同。A与B交集面积为3×4=12，并集为16+16-12=20，**IoU**=0.6。设抑制条件为IoU>0.5，则先保留A并删去B；C与A不重叠，予以保留。最终输出A、C。若B属于不同类别，按类别执行的NMS通常不会用A将其抑制。

辨析与自测 评价时先规定匹配的类别和IoU阈值，预测与真值通常一对一匹配，重复预测可能计为假阳性；再随分数阈值计算精确率与召回率，形成PR曲线及**AP**。多类别或多IoU阈值平均可形成相应**mAP**，但必须说明具体口径。自测：mAP相同的检测器是否一定适合相同任务？不是，实时延迟、漏检关键对象、夜间表现和算力需求仍可能不同。

IoU(A,B) = area(A∩B) / [area(A)+area(B)-area(A∩B)]。无交集时分子为0；面积必须非负并使用同一坐标约定。

本节来源：[53]。完整书目信息与链接见书末。

14.2.3 生物特征识别

考纲要求：理解

编者讲解 生物特征识别利用人的生理或行为特征进行身份相关判断，常见对象有人脸、指纹、虹膜和声音。**验证**通常是一对一比较，回答“是否为声称的那个人”；识别通常是一对多检索，回答“最可能是谁”，并可能需要拒绝所有候选。**登记**阶段采集模板，使用阶段提取待测特征，与模板计算相似性，最后按阈值给出决策。

编者讲解 阈值决定两类错误的权衡。提高相似度要求通常会减少把不同人当成同一人的错误，同时增加拒绝同一人的风险。不同术语所用分母可能不同：特征比较层面的错误匹配率与完整认证流程的**错误接纳**率不一定等同。说明评价结果时，应交代样本采集条件、比较协议和人群构成，而不能只用一个总准确率。

例题与解析 独立例题：在3000次不同人的验证试验中错误通过6次，按此试验口径，错误接纳率为6/3000=0.2%；在200次本人的验证中错误拒绝12次，错误拒绝率为12/200=6%。这不表示任何未来用户都恰好具有同样风险，也不能把两个百分比直接相加作为总体错误率，因为两个试验集合的大小不同。

辨析与自测 采集质量、光照、遮挡、年龄变化与设备差异都会影响特征；还应考虑照片、录音等呈现攻击，必要时加入**活体**或多因素检查。自测：人脸相似分数超过阈值就能证明当前请求获得本人授权吗？不能，**身份相似、活体存在和行为授权是不同问题。模板**泄露也不像普通密码那样容易更换，因此系统应尽量减少不必要保存，设置访问控制并提供合理的替代验证路径。

本节来源：[57]。完整书目信息与链接见书末。

14.2.4 行为分析

考纲要求：知道

编者讲解 行为分析从连续观测中理解**动作**或**活动**，例如走路、举手、搬运物品或设备操作。单幅图像通常只呈现姿态，连续视频才包含顺序与运动信息。系统可使用连续图像、光流或人体关键点序列，分别描述外观变化、局部运动和身体结构。光流反映图像中表观运动，并不等于直接测得物体在三维空间中的真实速度。

编者讲解 动作识别给一段视频赋予动作类别，**时序**定位还要指出动作何时开始和结束，跟踪则关联不同帧中的同一对象。三者可以组合，却不能互相替代。一个人先弯腰再起身可能是捡东西、运动或其他活动，需结合时间和场景，不能仅凭某一帧就确定复杂意图。

辨析与自测 例如仓库系统可根据一段关键点轨迹判断是否完成规定的搬运动作；评价需要使用未参加训练的人员或场景，避免记住衣服和背景。自测：模型在画面中检测到有人躺下，能否直接断言该人摔倒或生病？不能，还需时序、场景和人工核验。行为分析应围绕可观察动作定义标签，对遮挡、多主体交互与摄像机运动造成的不确定性保持清楚区分。

本节来源：[58]。完整书目信息与链接见书末。

综合模块

第15章 语音处理

15.1 语音处理基础

15.1.1 基本概念（响度、共振峰、掩蔽效应、基音等）

考纲要求：理解

编者讲解 声音是介质中的压力变化，经麦克风转换后可记录成电信号。幅度或声压是物理量，**响度**是人对声音强弱的感受，两者有关但并非简单线性关系；频率、持续时间和听觉条件也影响响度。频率表示单位时间内振动的次数，单位为赫兹；**音高**是对高低的感知，也不能在所有复杂声音上与单个频率完全等同。

编者讲解 浊音中声带近似周期性振动，**基音**频率F0表示其基本重复频率，周期T0与之互为倒数。清音或噪声可能没有稳定的基音。**共振峰**是声道共振在频谱包络中形成的能量峰，其位置反映声道形状，对区分元音很重要。基音主要关联激励的周期，共振峰主要关联声道的滤波作用；频谱上间隔排列的谐波峰与共振峰也不是一回事。

编者讲解 **掩蔽效应**是某个声音降低另一个声音可听见程度的现象，可同时发生，也可能与前后时间相邻的声音有关。它说明感知并不是对各个频率分量分别做完全独立的测量。音频压缩可以利用听觉特性分配编码资源，但语音识别任务仍须验证压缩是否破坏了所需信息。

辨析与自测 独立例题：若某段浊音的重复周期约为5毫秒，则F0=1/0.005=200赫兹。若说话者改变口腔形状发另一元音，基音仍可能接近200赫兹，而共振峰位置发生变化。自测：把声音振幅增加一倍，能否说基音也增加一倍？不能，振幅与周期不同。答题时应明确**物理量与感知量**、激励与共振之间的区别，不能将响度、音高、**音色**混为一项。

F0 = 1/T0。T0以秒计，F0以赫兹计；这个关系用于近似周期性声段。

本节来源：[59] [60]。完整书目信息与链接见书末。

15.1.2 声音信号预处理与量化

考纲要求：理解

编者讲解 从连续声音进入计算机，首先涉及**采样**与**量化**。采样是在时间轴上按间隔取值，**采样率**决定每秒取得多少个样本；量化把连续幅值映射到有限的数值等级，位数决定可用等级数。**采样率影响能够表示的频率范围，量化精度影响幅值分辨率，二者不能相互替代。增加位数不能恢复采样时已经混叠的高频信息。**

编者讲解 对于已限制最高频率的信号，理想采样条件要求采样频率高于最高频率的两倍；实际采集还应使用抗**混叠**滤波并留出滤波器过渡带。均匀量化若覆盖范围固定，**位数**增加会缩小量化间隔，通常减少量化误差；但信号超出范围会削波，简单增加后续计算精度并不能挽回削波失真。

编者讲解 语音分析常先处理直流偏移、幅度尺度和明显噪声，再**分帧**、**加窗**。短帧使非平稳语音在局部近似稳定，加窗减少截断边界对频谱的影响；相邻帧可重叠以保留变化连续性。**预加重**是某些传统流程中的高频补偿步骤，但不是所有现代系统的强制要求。任何预处理都应与训练时的设置一致，防止输入分布改变。

辨析与自测 独立例题：单声道16千赫兹、16位的未压缩**PCM**录音持续2秒，不计文件头，数据量为16000×2×16/8=64000字节。若每帧25毫秒、帧移10毫秒，则每帧400个样本、相邻帧起点相差160个样本。自测：把8千赫兹录音插值成16千赫兹，能否恢复原来未记录的高频？不能，插值改变表示密度，不能凭空恢复缺失信息。

未压缩PCM字节数 = 采样率 × 秒数 × 声道数 × 每样本位数 / 8。

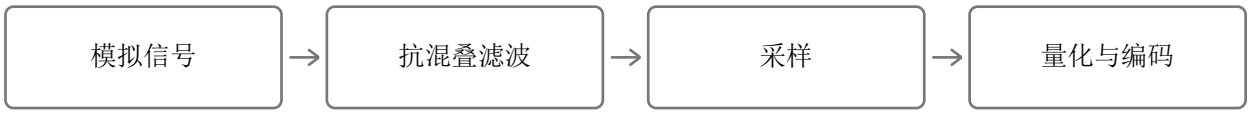


图15-1 声音数字化的基本步骤

本节来源：[59] [61]。完整书目信息与链接见书末。

15.1.3 常用时域、频域、声学特征

考纲要求：理解

编者讲解 时域特征直接由随时间变化的波形计算。**短时能量**反映一个帧内的幅度强弱，**过零率**反映相邻样本符号变化的频繁程度，**自相关**可用于寻找周期线索。它们计算简单，适用于粗略活动检测和声音分析，但单一特征通常不足以可靠区分复杂语音。噪声、录音增益和停顿都会改变特征值。

编者讲解 频域特征描述各频率成分的分布。对每一短时帧作傅里叶变换，可得到**频谱**；把多个帧的频谱沿时间排列形成声谱图。窗长增加通常提高频率分辨能力，却降低对快速时间变化的定位能力，因此需权衡。频谱幅值、功率谱、谱质心和频带能量从不同角度概括声音，不能简单将频谱图的横纵轴与普通波形图混用。

编者讲解 常用声学特征还包括Mel滤波器组能量及**梅尔**频率倒谱系数**MFCC**。传统MFCC流程通常对短时功率谱作Mel频带汇聚、取对数，再通过离散余弦变换获得较紧凑的谱包络表示；差分特征描述变化趋势。Mel表示强调非均匀频率尺度，MFCC则是由它进一步变换得到的系数。具体保留多少维、是否加能量和差分，要由模型约定。

辨析与自测 独立例题：四点帧x=[1,-1,1,-1]，能量和为4，平均平方为1；三个相邻间隔都变号，若按间隔数**归一化**，过零率为3/3=1。不同定义可能以帧长为分母，答题应先写清口径。自测：过零率高能否直接判成某个字？不能，它只描述波形变化的一方面。**训练、验证、部署应保持相同采样率、分帧、特征维数与归一化方式。**

本节来源：[60] [62]。完整书目信息与链接见书末。

15.2 语音处理方法与应用

15.2.1 常用模型（DNN-HMM、Attention、Transformer 等）

考纲要求：知道

编者讲解 **DNN-HMM**把深度神经网络与**隐马尔可夫模型**结合：网络根据声学特征估计与语音状态相关的概率信息，HMM描述状态随时间的转移，**解码**时再结合发音和语言约束搜索文字序列。隐状态不是录音中直接可见的标签；网络输出的状态后验与生成式声学似然也有区别，在传统混合系统中通常需要相应转换或校正。

编者讲解 注意力机制使解码某个字符或词时，能够对不同音频帧赋予不同权重，从而建立动态对齐。**Transformer**以自注意力建模序列内部关系，可在编码端处理声学表示，并在解码端生成词元。它不是语音专用结构，也不意味着完全没有顺序信息；位置表示或其他结构用于表达时序。长音频的计算量、流式延迟和噪声适应仍需专门处理。

辨析与自测 例如两个人说同一句话，音频长度不同，模型需要学习可变长声音与文字之间的对应。自测：识别输出与标准文本比较时，为什么不能只算句子是否完全相同？因为一个字错与整句错的程度不同。**词错误率**常用替换、删除、插入总数除以参考词数；中文也可按字计算**字符错误率**，但两种口径不能混用。基础识别正确率之外，还应检验口音、噪声和延迟条件。

> WER = (S + D + I) / N；S、D、I为替换、删除、插入词数，N为参考文本词数。插入很多时WER可超过1。

本节来源：[17] [59] [62] [79]。完整书目信息与链接见书末。

综合模块

第16章 自然语言处理

16.1 自然语言处理基础

16.1.1 词法（分词、词性标注、命名实体识别等）

考纲要求：理解

编者讲解 词法层面的处理先明确文本中的基本单位及其属性。**分词**确定词或**词元边界**；中文书写通常不靠空格标词，所以需要结合词典、统计或学习模型处理边界。词元也可以是字、子词或特殊符号，并不总等于日常语言中的完整词。词性标注进一步为词赋予名词、动词、形容词等语法类别；命名实体识别定位人名、地名、机构名等片段并标明类别。

编者讲解 同一个表面形式在不同上下文中可有不同角色。例如“学生研究问题”中的“研究”可作动词，“这项研究很重要”中的“研究”可作名词；只查一个固定词性表容易出错。命名实体的边界可能跨多个词，“华东师范大学”应作为机构整体识别，而不应把内部普通词随意拆成多个实体。分词、词性和实体识别相互影响，也可以由联合模型共同处理。

编者讲解 序列标注把每个输入位置映射成标签。实体识别可用BIO方案，B表示实体开始，I表示实体内部，O表示非实体，并附带PER、LOC等类别。模型除了判断单点标签，也要保持相邻标签组合合理。训练集应清楚约定实体边界、简称、嵌套结构和标点处理；否则不同标注者使用不同规则，会让评价失去可比性。

辨析与自测 独立例题：标准答案共有6个实体，系统输出5个，其中4个边界和类别都完全正确。实体级**精确率**为4/5=0.8，**召回率**为4/6≈0.667，F1=2×4/(5+6)=8/11≈0.727。自测：只把机构名最后两个字识别正确，能否算完整实体正确？在严格实体级评价中不能；字符级评价可能不同，必须写明口径。输出实体也不代表已经完成**实体链接**，后者还要判断它指向知识库中的哪一个对象。

本节来源：[63] [66]。完整书目信息与链接见书末。

16.1.2 句法（句子成分分析、生成式句法、依存式句法等）

考纲要求：理解

Syntactic parsing is the task of assigning a syntactic structure to a sentence.

原文选读 [64] Chapter 19, opening page

编者讲解 **句法**研究词怎样构成句子结构。**句子成分分析**关注主语、谓语、宾语以及定语、状语等关系；**短语结构分析**把词逐层组合成名词短语、动词短语和完整句子。形式化生成式语法通过

规则描述哪些结构能够组成合法句子。这里“生成式”强调语法规则对结构的刻画，不能与生成式大模型产生一段文本简单等同。

编者讲解 一个极简短语结构规则可写为S→NP VP，表示句子由名词短语与动词短语组成；VP→V NP可表示动词短语包含动词及宾语名词短语。这只是教学用的局部规则，不是汉语句法的完整理论。分析器面对句子可能得到多棵候选树，因为词的组合和修饰归属存在歧义；需要上下文或概率模型选择较合适的分析。

编者讲解 **依存**式句法直接表示词与词之间的**中心词**—从属词关系，通常用带标签的有向边描述主谓、动宾、修饰等关系。相比以短语为中间节点的结构树，它更直接地显示谁支配谁。“学生认真阅读教材”可把“阅读”作为主要中心，“学生”联系到主语位置，“教材”联系到宾语位置，“认真”作为修饰成分；标签名称应与采用的标注体系一致。

辨析与自测 自测：“用望远镜观察的学生”中，某个介词短语到底修饰谁，为什么不能只看相邻词？因为局部邻近并不总决定结构，词义和语境可能改变修饰关系。**句法正确也不保证事实正确**；“石头阅读教材”可具有清晰结构，却在通常语境中**语义**不合理。学习时应能画出简化结构或指出中心词，并解释句法分析为关系抽取和问答提供了哪些线索。

本节来源：[64] [65]。完整书目信息与链接见书末。

16.2 自然语言处理方法与应用

16.2.1 词表示（n-gram 语言模型、word2vec 等）

考纲要求：知道

将单词映射到实向量的技术称为词嵌入。

原文选读 [66] 14.1 导言

编者讲解 词表示把符号变成可计算对象。**独热向量**为每个词分配一个单独位置，不同词之间通常没有共享的几何相似信息；**稠密词向量**则用较短的实数向量表达分布特征。**word2vec**通过上下文预测学习词向量：跳元模型由中心词预测周围词，连续词袋模型由周围词预测中心词。向量相近往往意味着使用环境相近，不应直接解释成两个词在任何语境中同义。

编者讲解 **n-gram**语言模型给词序列赋予概率，常用有限长度历史近似完整上下文。二元模型近似用前一个词预测当前词，三元模型使用前两个词；统计计数有限时需要**平滑**，以免未见过的组合全部得到零概率。它主要是一种语言建模方法，不是word2vec那样的词嵌入方法。考纲把二者并列，学习时仍应区分概率模型与表示学习。

辨析与自测 独立例题：语料中“学习”后共出现10个词，其中4次是“数学”，未经平滑的二元估计为P(数学|学习)=4/10=0.4。自测：两个词向量的**余弦相似度**高，能否推出这两个词可以互相替换？不能，相反词也可能出现在类似上下文；一词多义还会让静态向量混合多种用法。评估应联系下游任务，而不是只展示几个看起来合理的近邻。

本节来源：[66] [67]。完整书目信息与链接见书末。

16.2.2 句子建模（RNN、LSTM、Transformer 等）

考纲要求：知道

编者讲解 句子建模需要同时处理词的内容、顺序和相互作用。把词向量简单平均可以得到固定长度表示，却常常弱化**词序**；“甲帮助乙”与“乙帮助甲”包含相同词，但角色不同。**RNN**按顺序更新**隐藏状态**，使后续计算能够利用前文；隐藏状态是对过去信息的压缩，不意味着原句的所有细节都被无损保存。

编者讲解 **LSTM**在循环结构中使用门控和记忆状态，控制信息写入、保留与输出，有助于学习较长依赖。**Transformer**通过注意力让各位置结合其他位置的信息，并使用位置相关表示表达顺序。并行计算、长距离联系和计算资源是比较模型时的重要方面；不能把LSTM说成没有遗忘，也不能把Transformer说成对任意长文本都没有代价。

辨析与自测 句子分类可把序列汇成一个表示后预测类别，**序列标注**为各位置预测标签，文本生成则预测后续词元。自测：训练逐词生成模型时，让当前词直接看到未来标准答案会怎样？会形成信息泄漏，训练条件与实际生成时不同，所以通常需要**因果掩码**。处理不同长度句子时，还应对**填充**位置作适当掩码，避免把补齐用的符号误当作真实内容。

本节来源：[17] [67]。完整书目信息与链接见书末。

综合模块

第17章 人工智能应用

17.1 智能社会

17.1.1 智能社会技术、应用

考纲要求：理解

编者讲解 智能社会方案应从公共问题出发，明确服务对象、决策目标与**责任主体**，再设计数据和模型。技术链条可分为数据采集与治理、**状态识别**、**风险预测**、方案建议、执行反馈。数据治理需要统一时间、位置和业务含义，处理重复与缺失，并限定访问权限；否则同一个“已处理”在两个部门代表不同状态，即使模型复杂也难以协同。

编者讲解 以社区公共设施维修为独立设计例：居民报修文本可通过自然语言处理识别设施和故障类型，图片可用于辅助判断破损程度，历史工单用于估计处理时长；排程模块根据紧急性、路程与人员技能提出派工建议。涉及安全的工单应设置人工确认和应急规则，执行结果进入闭环。模型要识别的是具体可操作问题，而不是给居民赋予笼统的价值评分。

编者讲解 假设一周有100张工单，系统判断20张紧急，复核发现其中15张确实紧急，另有5张紧急工单被分到普通队列。则紧急工单精确率为15/20=75%，召回率为15/(15+5)=75%。如果漏判紧急工单的后果更严重，可以调整阈值或增加人工复核；但调整后需要同时观察人员工作量，不能只提高一个指标。

辨析与自测 自测：处置时间缩短是否足以证明方案成功？不充分。还应比较问题是否真正解决、重复报修率是否下降、不同地区是否同样受益，以及不能熟练使用手机的人是否仍能获得服务。**因果评价**还需考虑人员增加、天气变化等其他因素。成熟方案应能说明数据出错、网络中断或模型不确定时如何回退，并向受影响的人提供可理解的反馈与**纠错途径**。

本节来源：[68]。完整书目信息与链接见书末。

17.2 智能交通

17.2.1 智能交通技术、应用

考纲要求：理解

编者讲解 智能交通系统常把**感知**、**预测**、**规划**和控制串联。感知从摄像机、雷达或定位信号估计道路参与者及状态；预测推断短期流量、行人或车辆的可能运动；规划在约束下选择路线或行动；控制再把计划变成转向、速度或信号灯指令。车路通信提供补充信息，但数据时间戳、定位误差和丢包都需要处理，不能假定所有设备共享完全准确的环境。

编者讲解 以路口信号优化为独立方案例：可用车辆计数、排队长度、公交位置以及行人请求作为输入，目标可包含平均延误、最大等待和安全约束。监督学习能够预测下一时段流量，优化算法或经过验证的策略据此分配绿灯；强化学习则可把信号相位作为动作、路况作为状态、负延误等作为奖励，但训练应在受控**仿真**等条件下进行，并限制不安全动作。

编者讲解 假设两个方案的车辆平均等待分别为30秒和25秒，后一方案看似更好；但如果它让少量行人等待从60秒增加到300秒，就不能仅凭车辆平均值决定采用。应同时检验行人最大等待、公交可靠性、拥堵传播及异常天气等情形。自动驾驶的训练资料则需要覆盖传感器观测与相应标签或专家行为，模拟数据可以补充稀有情形，但仍需检查仿真与真实道路的差异。

辨析与自测 自测：检测器在白天测试集上的精度提高，能否直接认定夜间制动更可靠？不能，完整系统还受感知延迟、目标距离估计、轨迹预测与执行误差影响。方案题应说明离线测试、仿真检验、受控场景验证和**持续监测**，并设定超出适用条件时的处理方式。**安全要求**是决策约束的一部分，不能只写成报告末尾的一句口号。

本节来源：[53] [69]。完整书目信息与链接见书末。

17.3 智能医疗

17.3.1 智能医疗技术、应用

考纲要求：理解

编者讲解 医疗AI方案首先要规定**使用场景**和输出作用。例如影像系统可以进行**病灶定位**、**区域分割**或风险排序；病历处理可以抽取药物名称和检查时间；时间序列模型可以辅助发现监测指标的异常趋势。不同任务需要不同标签和评价标准，不能把一个影像分类模型的成绩推广成“能够独立诊疗”的证据。

编者讲解 以影像复核队列为教学设计例，应由合适的专业人员制定标注规则，按患者而不是按单张图像划分数据，并尽可能检验不同医院、设备及人群。预处理、模型版本、输入质量检查和复核流程要共同记录。概率输出还应检查校准情况：预测0.8的样本组是否在相应条件下约有八成出现目标结果，不能把softmax数值直接当作可靠临床概率。

例题与解析 独立算例：假设1000例样本中100例为阳性，模型检出90例，并在900例阴性中误报90例。敏感度为90/100=90%，特异度为810/900=90%，但阳性预测值仅为90/(90+90)=50%。这说明相同的敏感度和特异度下，目标事件比例会影响阳性结果的解释。例中数字纯为教学构造，不能用于估计任何真实疾病或产品性能。

辨析与自测 自测：新医院只需沿用原阈值而不再评价吗？不应如此，数据与工作流程变化可能影响性能。系统应让使用者知道模型适用范围，保留**专业人员复核**和错误上报渠道，并检查长期**漂移**。高风险决策还需综合实际用途的**临床证据**与治理要求。

本节来源：[52] [70]。完整书目信息与链接见书末。

17.4 智能制造

17.4.1 智能制造技术、应用

考纲要求：理解

编者讲解 智能制造技术应与具体生产环节连接。**质量检测**可把产品图像映射为缺陷类别或缺陷区域，**预测性维护**可根据振动、电流、温度等序列估计故障风险，**排程**则在产能、工序先后和交期约束下安排任务。数据驱动模型也可与物理模型结合，避免把工艺上不可能的预测直接用于控制。

编者讲解 以轴承维护为独立设计例：先明确预测未来多久内的异常，采集同步的传感器、运行负载和维修记录，形成短时统计或频谱特征，再训练分类或寿命估计模型。训练与测试应按设备或时间划分，防止同一故障附近的相邻窗口混入两边。更换传感器或改变转速后，还要检查数据分布变化；模型可能学到工况区别而非故障本身。

编者讲解 假设人工检查一次成本10元，漏掉一次故障的平均损失暂按1000元估计。若某告警策略一天增加30次无效检查却减少1次实际漏检，按这个简化模型净收益为1000-30×10=700元。实际还需考虑停机、备件、产能与误触发等成本，因此不能只比较分类准确率。告警必须给出可执行的维护窗口，而不是在设备已经停机后才“预测”故障。

辨析与自测 自测：训练集缺陷率只有1%，把所有产品都判合格可得99%准确率，这样的检测器有用吗？没有完成缺陷发现目标。应分析**缺陷召回率**、**误剔率**和不同缺陷类别表现，并在**独立批次**验证。上线后还要监测告警负荷和工艺收益，设定人工确认、传感器失效和模型不可用时的安全流程，让算法评价与生产目标保持一致。

本节来源：[54] [71]。完整书目信息与链接见书末。

17.5 智能创意

17.5.1 智能创意技术、应用

考纲要求：理解

编者讲解 智能创意系统把创作目标转成可操作约束，再借助生成、编辑或检索方法产生候选。**文本条件生成**用提示描述主题、对象和风格；**局部重绘**对指定区域进行修改；**风格迁移**在保留内容结构与接近参考风格之间优化。方案应区分生成新内容、编辑已有内容和检索已有素材，因为三者对输入、控制与来源说明的要求不同。

编者讲解 以神经风格迁移为例，内容损失比较输出与内容图在选定网络层的特征，风格损失比较反映纹理关系的特征统计，还可加入使图像局部平滑的正则项。调整损失权重会改变结构保留与风格强度的平衡。这种机制解释了为什么“更像参考画风”可能伴随内容细节损失；并非所有用户目标都能用单一审美分数表达。

例题与解析 独立方案例：为科技展设计宣传材料，先确定活动事实、受众、版面比例和可用素材，生成构图候选后按信息层级与可读性筛选，再检查图像中的文字、对象关系和最终输出尺寸。如果要保持同一角色在多幅图中的一致性，应将角色特征与允许变化的部分分别记录，而不是每次重新给一个含糊提示。

辨析与自测 自测：自动评分更高的海报是否一定更适合活动？不一定，它可能偏向常见视觉风格，却不符合具体品牌或读者需要。评价可结合**约束满足率**、**人工盲评**与修改时间，并记录哪些内容来自参考、哪些经过生成修改。对事实、署名和人物音像的检查应与编辑流程一起完成；不能把模型的**来源**不确定性包装成已核验的原创性结论。

本节来源：[17] [72] [74]。完整书目信息与链接见书末。

17.6 智能推荐

17.6.1 智能推荐技术、应用

考纲要求：理解

编者讲解 推荐系统常采用**候选召回**、**排序**、**重排**三个阶段。召回从大量物品中找到较小候选集合，排序估计用户与候选的匹配程度，重排再考虑**多样性**、重复、业务约束和展示位置。**内容方法**依赖物品属性，协同过滤依赖用户与物品的交互结构；两者组合可以缓解部分冷启动问题，但没有交互不等于负面反馈。

编者讲解 矩阵分解将用户与物品分别表示为低维向量，用点积及偏置预测评分或相容程度。模型只在有意义的观测和训练目标上拟合，不能把所有未观察条目都当成真实的零评分。隐式反馈系统还需要考虑曝光机会、负样本选取和行为强弱。较高点击率可能来自展示位置或夸张标题，因此离线数据中的关联不一定能直接说明推荐带来的增益。

例题与解析 独立算例：用户向量u=(1,2)，物品A向量为(2,1)，B为(1,2)，忽略偏置时A得分为1×2+2×1=4，B得分为1×1+2×2=5，所以模型更倾向B。这只是潜在向量得分，不代表用户会给B打五星。若前5个推荐中有3个属于预先定义的相关集合，则Precision@5=3/5=0.6；若相关集合共有10个，Recall@5=3/10=0.3。

辨析与自测 自测：直接随机切分同一用户全部行为，是否总能模拟将来的推荐？不一定，可能让未来行为帮助预测过去。**时间划分、未见用户或新物品测试能分别考查不同能力**。线上可用受控比较评估点击、满意度或长期留存，还应观察多样性和重复曝光。方案题应明确推荐什么、何时推荐、相关性的定义以及评价窗口，避免只有“采用**协同过滤**”这一个方法名称。

> 预测评分的一种形式：r_hat(u,i) = 用户向量 • 物品向量 + 用户偏置 + 物品偏置 + 全局均值。点积是对应分量乘积之和。

本节来源：[73] [77]。完整书目信息与链接见书末。

17.7 智慧教育

17.7.1 智慧教育技术、应用

考纲要求：理解

编者讲解 智慧教育技术可围绕**诊断、干预和评价**形成闭环。**知识追踪**根据题目、作答结果和历史交互估计学生在知识点上的状态，**资源推荐**据此选择下一步学习材料，自动反馈解释错误并给出提示。模型观察到的是行为证据，不能直接测得理解，所以应区分学生不会、猜对、粗心、题目歧义和环境干扰等可能原因。

编者讲解 一个练习推荐方案应先建立题目与知识点的对应关系，记录题目难度与必要先修关系，再根据学生已有记录选择能促进学习或帮助诊断的题目。过易题目可能缺少学习收益，过难题目可能造成连续失败；仅追求下一题答对概率最大，会倾向一直推送简单题。推荐目标应与课程要求和长期学习效果一致，而不是只提高短期正确率。

例题与解析 独立例题：学生甲在10道简单题中答对8道，学生乙在10道较难题中答对6道，能否据80%与60%直接断定甲掌握更好？不能，题目难度与覆盖内容不同。可安排具有共同知识要求的诊断题，结合解题过程和后续表现再判断。若系统给出提示，应先帮助学生定位思路，再逐步解释，而不是立即替代所有推理。

辨析与自测 自测：系统上线后平均分提高，能否全部归因于AI推荐？不能，教学进度、学生选择和额外练习时间也会影响结果。可在可行条件下采用**对照设计**，并同时考查延迟测验、**迁移**题和教师工作负担。划分数据时要警惕同一学生或同一道题的**泄漏**。涉及自动批改时还应检查评分依据、允许申诉和教师修订，确保技术输出始终能回到具体教学目标。

本节来源：[74] [78]。完整书目信息与链接见书末。

17.8 机器人

17.8.1 机器人技术、应用

考纲要求：理解

编者讲解 机器人技术把环境感知、运动表示、**路径规划**和**反馈控制**连接起来。移动机器人需要估计自身位置并理解障碍，机械臂需要把目标位置转换为关节运动。**正运动学**由关节状态计算末端位姿，逆运动学由期望位姿求关节解；**逆解可能不存在，也可能有多个**。动力学还考虑质量、惯性和作用力，与只讨论几何关系的运动学不同。

编者讲解 路径规划寻找避障且满足约束的运动路径，轨迹规划进一步规定随时间怎样运动。控制器根据期望值和反馈误差调整执行器，例如比例控制根据位置误差计算控制量。感知误差、执行延迟、摩擦和外界干扰使真实机器人不可能完全按照理想模型行动，因此必须持续更新状态。定位与建图可以相互帮助，但地图和位置估计都有不确定性。

例题与解析 独立算例：平面二连杆机械臂两杆长均为1，第一关节角θ1=0，第二关节相对第一杆角θ2=π/2。末端x=cos0+cos(π/2)=1，y=sin0+sin(π/2)=1。这个计算只给出几何位置，并未判断这一路径是否碰撞，也未计算电机所需力矩。若目标点距离基座为3，则两杆总长2的机械臂无法在该平面伸到目标。

辨析与自测 自测：找到无碰撞路径后，能否任意提高速度执行？不能，速度、加速度、驱动力和制动距离都有约束。仓储搬运方案还需说明货物定位、抓取确认、失败重试和人员进入时的处理。评价可同时考查任务成功率、位置误差、完成时间和**异常恢复能力**；不能只用一次演示成功代替对重复运行与变化环境的检验。

> 平面二连杆：x=l1 cosθ1+l2 cos(θ1+θ2)，y=l1 sinθ1+l2 sin(θ1+θ2)。l1、l2为杆长，θ2为第二杆相对第一杆的转角。

本节来源：[53] [75] [80]。完整书目信息与链接见书末。

17.9 智能驱动科学研究

17.9.1 AI4Science 技术、应用

考纲要求：理解

> The AlphaFold network directly predicts the 3D coordinates of all heavy atoms for a given protein using the primary amino acid sequence and aligned sequences of homologues as inputs

原文选读 [76] The AlphaFold network；原句节选

编者讲解 科学研究中的AI可用于**性质预测**、计算**替代模型**、**逆向设计**和实验选择。性质预测由结构或条件预测结果；逆向设计从目标性质反推候选结构；替代模型用较低计算成本近似耗时模

拟。把守恒关系、几何对称或其他领域约束纳入模型，能够缩小不合理解的范围，但并不能保证模型在未见条件下仍然正确。

编者讲解 AlphaFold展示了如何把氨基酸序列及相关进化信息转成蛋白质三维结构预测。这里预测空间结构与直接测定所有生物功能仍有区别；使用者还需考虑置信程度、结构状态和实际实验问题。对其他科学任务也一样：模型给出的候选可能促进实验筛选，却不是独立完成了因果证明。评价数据应尽量反映真正的新对象或新条件，避免高度相近样本跨越训练与测试边界。

例题与解析 独立算例：某材料性质的三次预测为10、12、14，实测为11、10、15，则平均绝对误差为(1+2+1)/3=4/3。这个平均数没有说明哪个实验区间更可靠，也未反映极端失败。若实验预算只允许测两个新候选，可以结合预测性能和不确定性选取，而不是只重复测模型最有把握、却与已有材料几乎相同的对象。

辨析与自测 自测：预测误差很小，是否就能声称发现了普遍定律？不能，可能仅在有限数据范围内拟合得好。科学工作还需说明测量条件、**独立验证**、可复现流程和失败边界；**不确定性估计**本身也要检验。一个完整方案应写出数据来源、目标量、基准方法、评价划分、**实验验证**以及新结果如何回流，形成模型与实验相互修正的循环。

本节来源：[76]。完整书目信息与链接见书末。

附录一 考纲样例的阅读与勘误

使用说明 以下核对针对用户提供的2025版考纲样例，不改变原题填空要求。原文定位同时给出印刷页和PDF物理页；若考场题目明确要求只补空，不应自行修改不在填空范围内的代码。

文件名引号 印刷页135（PDF第12页）的 xlrd.open_workbook(sandianshuju.xlsx') 缺少开引号。作为完整程序学习时应写为 xlrd.open_workbook('sandianshuju.xlsx')，并确认文件位置与数据表头。

两列特征的排列 同页先构造 np.array([Density, Sugar]) 再 reshape(17, 2) 会把原本分成两行的特征按元素顺序重排，无法保证每一行对应同一人的两个属性。应使用 np.column_stack((Density, Sugar)) 或先构造两行后转置。例如 Density=[1,2]、Sugar=[10,20] 时，正确样本应为 [[1,10],[2,20]]。

训练标签 印刷页136（PDF第13页）的 log_model.fit(X_train, X_test) 第二个参数应为训练标签 y_train。正确调用是 log_model.fit(X_train, y_train)。测试特征不能代替标签；测试集用于最终评估，不参与训练拟合。

绘图与图例 该样例使用 Matplotlib 绘制散点图；scikit-learn 用于划分数据和训练分类器。loc='upper right' 控制图例位于绘图区右上角，并非把散点图移动到屏幕右上方。

Excel读取版本 xlrd 官方变更记录说明2.0.0起移除了.xls以外格式的支持。因此.xlsx读入存在版本条件。考纲未指定xlrd版本，不能直接断言考场必定报错。现代环境通常可使用支持.xlsx的读取引擎，但不应在不了解考场依赖时擅自改换。

旧式类别预测 印刷页138（PDF第15页）使用 model.predict_classes。TensorFlow 2.5.0官方源码仍保留该方法，但标为弃用；不能将它说成在2.5.0中不存在。单标签多分类可使用 np.argmax(model.predict(X_test_norm), axis=-1)。二分类sigmoid输出则应按阈值处理，不能机械套用单列argmax。

标准化流程 印刷页133—134（PDF第10—11页）的KNN样例在训练集上fit_transform，在测试集上transform，该步骤正确。若对完整数据先拟合标准化器再切分，会让测试集信息影响预处理参数。

题量表述 考纲正文对客观题包写“10—20道”，表1则写“10道选择题和3道程序改错选择题”。本书保留这一差异，不擅自将两种口径合并成确定题量。考试安排应以当次官方通知为准。

版本核对：xlrd 官方变更记录；TensorFlow v2.5.0 Sequential 源码。

附录二 综合程序流程示例

编者例题 例题要求：使用鸢尾花数据完成训练集与测试集切分、标准化、K近邻分类及性能评估。下面围绕考纲样例整理为完整流程，增加分层抽样和流水线。数据集由scikit-learn自带加载器提供，不需要外部表格。

```
from sklearn.datasets import load_iris
from sklearn.model_selection import train_test_split
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import confusion_matrix, classification_report

iris = load_iris()
X_train, X_test, y_train, y_test = train_test_split(
    iris.data, iris.target, test_size=0.3,
    random_state=8, stratify=iris.target
)
model = Pipeline([
    ('scale', StandardScaler()),
    ('knn', KNeighborsClassifier(n_neighbors=5))
])
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(
    y_test, y_pred, target_names=iris.target_names
))
```

逐步解释 iris.data的形状为(150,4)，每行一个样本、每列一个特征；iris.target含150个类别标签。test_size=0.3产生45个测试样本和105个训练样本。stratify按类别比例分层抽样，random_state使同一软件环境下的划分可以复现。

训练与预测 流水线fit时，标准化器只从训练集估计每列的均值和标准差，然后训练KNN。predict时重复使用同一组预处理参数，再在训练样本中寻找近邻。标准化能防止数值尺度较大的特征不合理地支配欧氏距离。

评价解释 混淆矩阵的一行对应一个真实类别，一列对应一个预测类别。主对角线是预测正确的个数。classification_report逐类显示precision、recall、F1和support。不能把某次随机划分的成绩当作固定承诺；若要选择K，应在训练数据内部做验证或交叉验证。

自测与答案 为什么不先对全部150条数据执行fit_transform？因为这样估计均值和方差时用了将来的测试集。为什么不能反复根据测试分数选择K？因为测试集会逐渐变为调参集，不能继续提供独立的最终评估。

接口核对：Pipeline；train_test_split。流程依据考纲印刷页132—134。

参考资料

以下列出正文实际使用的来源。教材章节、官方文档与论文分别注明类型；在线阅读不自动意味着允许全文转载。来源编号在正文中按首次汇总分配，同一网址重复出现时合并。所有链接的核对日期为2026年10月12日。

[1] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 1.1 What is Artificial Intelligence?．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch1.S1.html
引用说明：CC BY-NC-ND 4.0；仅摘录原文，讲解独立标注

[2] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 1.2 A Brief History of Artificial Intelligence．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch1.S2.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[3] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 1.4 Prototypical Applications．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch1.S4.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[4] 阿斯顿・张、李沐、扎卡里・C.立顿、亚历山大・J.斯莫拉．动手学深度学习，第1章 引言．开放教材。
https://zh.d2l.ai/chapter_introduction/index.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[5] NumPy 开发团队．NumPy v1.20 Manual: NumPy quickstart．官方文档。
https://numpy.org/doc/1.20/user/quickstart.html
引用说明：仅作概念/API核对，无长篇转载

[6] pandas 开发团队．pandas 1.2.5: Intro to data structures．官方文档。
https://pandas.pydata.org/pandas-docs/version/1.2/user_guide/dsintro.html
引用说明：仅作概念/API核对，无长篇转载

[7] Matplotlib 开发团队．Matplotlib 3.4.2: Usage Guide．官方文档。
https://matplotlib.org/3.4.2/tutorials/introductory/usage.html
引用说明：仅作概念/API核对，无长篇转载

[8] scikit-learn 开发团队．scikit-learn 0.24.2: Common pitfalls and recommended practices．官方文档。
https://scikit-learn.org/0.24/common_pitfalls.html
引用说明：仅作概念/API核对，无长篇转载

[9] scikit-learn 开发团队．scikit-learn 0.24.2: Nearest Neighbors．官方文档。
https://scikit-learn.org/0.24/modules/neighbors.html
引用说明：仅作概念/API核对，无长篇转载

[10] scikit-learn 开发团队．scikit-learn 0.24.2: Clustering．官方文档。
https://scikit-learn.org/0.24/modules/clustering.html
引用说明：仅作概念/API核对，无长篇转载

[11] scikit-learn 开发团队．scikit-learn 0.24.2: Decomposing signals in components．官方文档。
https://scikit-learn.org/0.24/modules/decomposition.html
引用说明：仅作概念/API核对，无长篇转载

[12] 阿斯顿·张、李沐、扎卡里·C.立顿、亚历山大·J.斯莫拉．动手学深度学习，3.1 线性回归．开放教材。
https://zh.d2l.ai/chapter_linear-networks/linear-regression.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[13] scikit-learn 开发团队．scikit-learn 0.24.2: Metrics and scoring．官方文档。
https://scikit-learn.org/0.24/modules/model_evaluation.html
引用说明：仅作概念/API核对，无长篇转载

[14] 阿斯顿·张、李沐、扎卡里·C.立顿、亚历山大·J.斯莫拉．动手学深度学习，4.1 多层感知机．开放教材。
https://zh.d2l.ai/chapter_multilayer-perceptrons/mlp.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[15] 阿斯顿·张、李沐、扎卡里·C.立顿、亚历山大·J.斯莫拉．动手学深度学习，4.4 模型选择、欠拟合和过拟合．开放教材。
https://zh.d2l.ai/chapter_multilayer-perceptrons/underfit-overfit.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[16] 阿斯顿·张、李沐、扎卡里·C.立顿、亚历山大·J.斯莫拉．动手学深度学习，4.7 前向传播、反向传播和计算图．开放教材。
https://zh.d2l.ai/chapter_multilayer-perceptrons/backprop.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[17] 阿斯顿·张、李沐、扎卡里·C.立顿、亚历山大·J.斯莫拉．动手学深度学习，10.7 Transformer．开放教材。
https://zh.d2l.ai/chapter_attention-mechanisms/transformer.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[18] François Chollet / TensorFlow．TensorFlow Guide: The Sequential model．官方文档。
https://www.tensorflow.org/guide/keras/sequential_model
引用说明：网页内容 CC BY 4.0；例程按考试版本独立编写

[19] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 15.3 Predicate Calculus．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch15.S3.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[20] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 15.5 Proofs and Substitutions．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch15.S5.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[21] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 9.1 Probability．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch9.S1.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[22] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 5.4 Querying the User．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch5.S4.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[23] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed., 16.1 Knowledge Graphs．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch16.S1.html
引用说明：CC BY-NC-ND 4.0；讲解为独立编写

[24] W3C RDF Working Group．RDF 1.1 Primer．官方文档。
https://www.w3.org/TR/rdf11-primer/
引用说明：仅作标准概念核对，无长篇转载

[25] W3C OWL Working Group．OWL 2 Web Ontology Language Primer, Second Edition．官方文档。
https://www.w3.org/TR/owl2-primer/
引用说明：仅作标准概念核对，无长篇转载

[26] 阿斯顿・张、李沐、扎卡里・C.立顿、亚历山大・J.斯莫拉．动手学深度学习，3.4 softmax回归．开放教材。
https://zh.d2l.ai/chapter_linear-networks/softmax-regression.html
引用说明：正文 CC BY-SA 4.0；引文保持原样，补充讲解另标

[27] scikit-learn developers．scikit-learn User Guide：Logistic regression．官方文档。
https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
引用说明：BSD；本书仅作技术核对

[28] scikit-learn developers．scikit-learn User Guide：Decision Trees．官方文档。
https://scikit-learn.org/stable/modules/tree.html
引用说明：BSD；原文短引

[29] scikit-learn developers．scikit-learn User Guide：Support Vector Machines．官方文档。
https://scikit-learn.org/stable/modules/svm.html
引用说明：BSD；本书仅作技术核对

[30] scikit-learn developers．scikit-learn User Guide：Hierarchical clustering．官方文档。
https://scikit-learn.org/stable/modules/clustering.html#hierarchical-clustering
引用说明：BSD；本书仅作技术核对

[31] scikit-learn developers．scikit-learn User Guide：Ensemble methods．官方文档。
https://scikit-learn.org/stable/modules/ensemble.html
引用说明：BSD；本书仅作技术核对

[32] scikit-learn developers．scikit-learn User Guide：Linear and Quadratic Discriminant Analysis．官方文档。
https://scikit-learn.org/stable/modules/lda_qda.html
引用说明：BSD；本书仅作技术核对

[33] scikit-learn developers．scikit-learn User Guide：Naive Bayes．官方文档。
https://scikit-learn.org/stable/modules/naive_bayes.html
引用说明：BSD；本书仅作技术核对

[34] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed.，第13章 Reinforcement Learning．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch13.html
引用说明：CC BY-NC-ND 4.0；仅短引，讲解独立撰写

[35] David L. Poole、Alan K. Mackworth．Artificial Intelligence: Foundations of Computational Agents, 3rd ed.，13.4 Learning from Experiences．开放教材。
https://artint.info/3e/html/ArtInt3e.Ch13.S4.html
引用说明：CC BY-NC-ND 4.0；本书仅作技术核对

[36] 阿斯顿・张等．动手学深度学习，11.3 梯度下降．开放教材。
https://zh.d2l.ai/chapter_optimization/gd.html
引用说明：正文 CC BY-SA 4.0

[37] 阿斯顿·张等．动手学深度学习，6.6 卷积神经网络（LeNet）．开放教材。
https://zh.d2l.ai/chapter_convolutional-neural-networks/lenet.html
引用说明：正文 CC BY-SA 4.0

[38] 阿斯顿·张等．动手学深度学习，7.6 残差网络（ResNet）．开放教材。
https://zh.d2l.ai/chapter_convolutional-modern/resnet.html
引用说明：正文 CC BY-SA 4.0

[39] 阿斯顿·张等．动手学深度学习，8.4 循环神经网络．开放教材。
https://zh.d2l.ai/chapter_recurrent-neural-networks/rnn.html
引用说明：正文 CC BY-SA 4.0

[40] 阿斯顿·张等．动手学深度学习，9.2 长短期记忆网络（LSTM）．开放教材。
https://zh.d2l.ai/chapter_recurrent-modern/lstm.html
引用说明：正文 CC BY-SA 4.0

[41] 阿斯顿·张等．动手学深度学习，9.1 门控循环单元（GRU）．开放教材。
https://zh.d2l.ai/chapter_recurrent-modern/gru.html
引用说明：正文 CC BY-SA 4.0

[42] Jonathan Ho、Ajay Jain、Pieter Abbeel．Denoising Diffusion Probabilistic Models．原始论文。
https://arxiv.org/html/2006.11239v2
引用说明：公开论文；仅短引或独立讲解

[43] Ian Goodfellow 等．Generative Adversarial Nets．原始论文。
https://arxiv.org/html/1406.2661v1
引用说明：公开论文；仅短引或独立讲解

[44] Alec Radford 等．Learning Transferable Visual Models From Natural Language Supervision．原始论文。
https://arxiv.org/html/2103.00020v1
引用说明：公开论文；仅作技术核对

[45] 阿斯顿·张等．动手学深度学习，12.5 多GPU训练．开放教材。
https://zh.d2l.ai/chapter_computational-performance/multiple-gpus.html
引用说明：正文 CC BY-SA 4.0

[46] H. Brendan McMahan 等．Communication-Efficient Learning of Deep Networks from Decentralized Data．原始论文。
https://proceedings.mlr.press/v54/mcmahan17a.html
引用说明：PMLR公开论文；仅作技术核对

[47] Jordan Hoffmann 等．Training Compute-Optimal Large Language Models．原始论文。
https://arxiv.org/html/2203.15556v1
引用说明：公开论文；仅作技术核对

[48] 阿斯顿·张等．动手学深度学习，14.8 来自Transformers的双向编码器表示（BERT）．开放教材。
https://zh.d2l.ai/chapter_natural-language-processing-pretraining/bert.html
引用说明：正文 CC BY-SA 4.0

[49] Patrick Lewis 等．Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks．原始论文。
https://arxiv.org/html/2005.11401v4
引用说明：公开论文；仅短引或独立讲解

[50] 美国国家标准与技术研究院（NIST）．AI Risk Management Framework 1.0，第3部分 AI Risks and Trustworthiness．机构资料。
https://airc.nist.gov/airmf-resources/airmf/3-sec-characteristics/
引用说明：机构公开资料；仅短引与独立案例

[51] 联合国教科文组织（UNESCO）. Recommendation on the Ethics of Artificial Intelligence. 机构资料。
https://www.unesco.org/en/artificial-intelligence/recommendation-ethics
引用说明：机构公开资料；仅短引与独立案例

[52] Aston Zhang、Zachary C. Lipton、Mu Li、Alexander J. Smola. 动手学深度学习 • 13.9 语义分割和数据集. 开放教材。
https://zh.d2l.ai/chapter_computer-vision/semantic-segmentation-and-dataset.html
引用说明：CC BY-SA 4.0；中文仓库 config.ini 声明

[53] Aston Zhang、Zachary C. Lipton、Mu Li、Alexander J. Smola. 动手学深度学习 • 13.3 目标检测和边界框. 开放教材。
https://zh.d2l.ai/chapter_computer-vision/bounding-box.html
引用说明：CC BY-SA 4.0

[54] OpenCV. OpenCV 3.4.12 Tutorials: Smoothing Images. 官方文档。
https://docs.opencv.org/3.4.12/d4/d13/tutorial_py_filtering.html
引用说明：仅作核对；未摘录原文

[55] OpenCV. OpenCV Tutorials: Canny Edge Detection. 官方文档。
https://docs.opencv.org/3.4.20/da/d22/tutorial_py_canny.html
引用说明：仅作核对；未摘录原文

[56] OpenCV. OpenCV Tutorials: Introduction to SIFT. 官方文档。
https://docs.opencv.org/3.4.20/da/df5/tutorial_py_sift_intro.html
引用说明：仅作核对；未摘录原文

[57] NIST. A Tale of Two Errors: Measuring Biometric Algorithms. 机构资料。
https://www.nist.gov/blogs/taking-measure/tale-two-errors-measuring-biometric-algorithms
引用说明：仅作核对；未摘录原文

[58] Karen Simonyan、Andrew Zisserman. Two-Stream Convolutional Networks for Action Recognition in Videos. 原始论文。
https://arxiv.org/abs/1406.2199
引用说明：仅作核对；未摘录原文

[59] Daniel Jurafsky、James H. Martin. Speech and Language Processing • Automatic Speech Recognition and Text-to-Speech（2024-08-20草稿）. 机构资料。
https://web.stanford.edu/~jurafsky/slp3/old_aug24/16.pdf
引用说明：版权保留；仅作核对，不作长篇转载

[60] Steven W. Smith. The Scientist and Engineer's Guide to Digital Signal Processing • Chapter 22 Audio Processing. 机构资料。
https://www.dspguide.com/CH22.PDF
引用说明：版权保留；仅作核对，不作长篇转载

[61] Steven W. Smith. The Scientist and Engineer's Guide to Digital Signal Processing • Chapter 3 ADC and DAC. 机构资料。

https://www.dspguide.com/CH3.PDF
引用说明：版权保留；仅作核对

[62] Daniel Jurafsky、James H. Martin. Speech and Language Processing • Automatic Speech Recognition（2026-08-19草稿）. 机构资料。
https://web.stanford.edu/~jurafsky/slp3/16.pdf
引用说明：版权保留；仅作核对

[63] Daniel Jurafsky、James H. Martin．Speech and Language Processing • Sequence Labeling for Parts of Speech and Named Entities．机构资料。
https://web.stanford.edu/~jurafsky/slp3/18.pdf
引用说明：版权保留；仅作核对

[64] Daniel Jurafsky、James H. Martin．Speech and Language Processing • Context-Free Grammars and Constituency Parsing．机构资料。
https://web.stanford.edu/~jurafsky/slp3/19.pdf
引用说明：版权保留；本稿仅短引13个英文词

[65] Daniel Jurafsky、James H. Martin．Speech and Language Processing • Dependency Parsing．机构资料。
https://web.stanford.edu/~jurafsky/slp3/20.pdf
引用说明：版权保留；仅作核对

[66] Aston Zhang、Zachary C. Lipton、Mu Li、Alexander J. Smola．动手学深度学习 • 14.1 词嵌入（word2vec）．开放教材。
https://zh.d2l.ai/chapter_natural-language-processing-pretraining/word2vec.html
引用说明：CC BY-SA 4.0

[67] Aston Zhang、Zachary C. Lipton、Mu Li、Alexander J. Smola．动手学深度学习 • 8.3 语言模型和数据集．开放教材。
https://zh.d2l.ai/chapter_recurrent-neural-networks/language-models-and-dataset.html
引用说明：CC BY-SA 4.0

[68] ITU-T．Smart sustainable cities: A guide for city leaders（Y Supplement 32）．机构资料。
https://www.itu.int/epublications/publication/itu-t-y-suppl-32-2020-07-itu-t-y-4000-series-smart-sustainable-cities-a-guide-for-city-leaders
引用说明：仅作核对；未摘录原文

[69] U.S. Department of Transportation．How Connected Vehicles Work．机构资料。
https://www.transportation.gov/research-and-technology/how-connected-vehicles-work
引用说明：仅作核对；未摘录原文

[70] World Health Organization．Ethics and governance of artificial intelligence for health．机构资料。
https://www.who.int/publications/i/item/9789240029200
引用说明：仅作核对；未摘录原文

[71] NIST．Industrial Artificial Intelligence Management and Metrology．机构资料。
https://www.nist.gov/programs-projects/industrial-artificial-intelligence-management-and-metrology-iaimm
引用说明：仅作核对；未摘录原文

[72] Aston Zhang、Zachary C. Lipton、Mu Li、Alexander J. Smola．Dive into Deep Learning • 14.12 Neural Style Transfer．开放教材。
https://d2l.ai/chapter_computer-vision/neural-style.html
引用说明：CC BY-SA 4.0；英文仓库 README 许可声明

[73] Aston Zhang 等．Dive into Deep Learning • 21.1 Overview of Recommender Systems．开放教材。
https://d2l.ai/chapter_recommender-systems/recsys-intro.html
引用说明：CC BY-SA 4.0

[74] Fengchun Miao、Wayne Holmes；UNESCO．Guidance for generative AI in education and research（2023）．机构资料。
https://www.unesco.org/en/articles/guidance-generative-ai-education-and-research?hub=387
引用说明：仅作核对；未摘录原文

[75] Kevin M. Lynch、Frank C. Park．Modern Robotics: Mechanics, Planning, and Control • Book Resources．机构资料。
https://modernrobotics.northwestern.edu/nu-gm-book-resource/
引用说明：作者公开阅读教材；本稿未摘录原文

[76] John Jumper 等．Highly accurate protein structure prediction with AlphaFold（2021）．原始论文。
https://www.nature.com/articles/s41586-021-03819-2
引用说明：CC BY 4.0；仅短引并独立讲解

[77] Aston Zhang 等．Dive into Deep Learning • 21.3 Matrix Factorization．开放教材。
https://d2l.ai/chapter_recommender-systems/mf.html
引用说明：CC BY-SA 4.0

[78] Chris Piech 等．Deep Knowledge Tracing（2015）．原始论文。
https://arxiv.org/abs/1506.05908
引用说明：仅作核对；未摘录原文

[79] Geoffrey Hinton、Li Deng、Dong Yu 等．Deep Neural Networks for Acoustic Modeling in Speech Recognition（2012）．原始论文。
https://www.microsoft.com/en-us/research/wp-content/uploads/2016/02/HintonDengYuEtAl-SPM2012.pdf
引用说明：版权保留；仅作核对，未摘录原文

[80] Kevin M. Lynch、Frank C. Park．Modern Robotics • Chapter 6: Inverse Kinematics of Open Chains．机构资料。
https://modernrobotics.northwestern.edu/nu-gm-book-resource/inverse-kinematics-of-open-chains/
引用说明：作者教学资料；仅作核对，未摘录原文